

Depuración información del portal de Datos Abiertos

2024-11-13

Contents

Información de la base de datos	2
Lectura de la base de datos	2
Depuración de la base de datos	3
Selección casos de mujeres	3
Variable orden y mes	3
Variables de tipo factor	3
Variable hora_hecho (hora del hecho)	13
Variable fecha del hecho	13
Valores faltantes	13
Registros duplicados	17
Base de datos depurada	17

Información de la base de datos

La base de datos, titulada *04. Violencia de Género e Intrafamiliar de enero 2015 a marzo 2023 - Semana Epidemiológica 12*, está alojada en el portal de Datos Abiertos de Colombia (Ver). Este recurso recopila información sobre los casos de violencia de género atendidos en instituciones prestadoras de salud (IPS) entre 2015 y 2023. Los casos registrados se dieron o son notificados principalmente en **Santander**.

- **Fuente:** Secretaría de Salud y Ambiente de Bucaramanga.
- **Entidad responsable del alojamiento en el portal:** Alcaldía de Bucaramanga.
- **Frecuencia de actualización:** Semestral.
- **Última actualización:** 25 de marzo de 2023.

Además de la base de datos, en el anterior enlace se encuentran los siguientes recursos:

- Tablero interactivo desarrollado por el Centro de Analítica de la Alcaldía de Bucaramanga, con el objetivo de analizar los casos de violencia de género en la ciudad (Ver).
- Calendario epidemiológico del año 2023

Lectura de la base de datos

```
data <- load_data("datos_abiertos_2015_2023.csv", type = "raw")
```

```
# Estructura de la base de datos  
str(data)
```

```
## 'data.frame': 12161 obs. of 32 variables:  
## $ Orden : int 1 2 3 4 5 6 7 8 9 10 ...  
## $ Departamento : chr "SANTANDER" "SANTANDER" "SANTANDER" "SANTANDER" ...  
## $ Municipio : chr "BUCARAMANGA" "BUCARAMANGA" "BUCARAMANGA" "BUCARAMANGA" ...  
## $ semana : int 23 5 29 16 44 45 47 45 26 17 ...  
## $ año : int 2015 2015 2015 2015 2015 2015 2015 2015 2015 2015 ...  
## $ Grupo.edad : chr "12 a 17" "12 a 17" "12 a 17" "12 a 17" ...  
## $ Ciclo.de.vida : chr "Adolescencia" "Adolescencia" "Adolescencia" "Adolescencia" ...  
## $ sexo_ : chr "Masculino" "Masculino" "Femenino" "Femenino" ...  
## $ area_ : chr "CABECERA MUNICIPAL" "CABECERA MUNICIPAL" "CABECERA MUNICIPAL" "CA...  
## $ Barrio : chr "Transicion I-V" "Betania" "GIRON" "Maria Paz" ...  
## $ Comuna : chr "02. NORORIENTAL" "01. NORTE" "GIRON" "01. NORTE" ...  
## $ Tipo.de.Seguridad.Social: chr "No asegurado" "Subsidiado" "Subsidiado" "Subsidiado" ...  
## $ pac_hos_ : int 2 2 1 2 2 2 2 1 2 2 ...  
## $ con_fin_ : int 1 1 1 1 1 1 1 1 1 1 ...  
## $ version : chr "SIVIGILA - 2015 - 15.1.3" "SIVIGILA - 2015 - 15.1.1" "SIVIGILA - ...  
## $ naturaleza : int 3 1 3 1 4 4 1 3 3 1 ...  
## $ def_naturaleza : chr "Negligencia y abandono" "Violencia fisica" "Negligencia y abandon...  
## $ actividad : int 26 24 26 24 26 24 24 24 24 26 ...  
## $ nom_actividad : chr "Otro" "Estudiante" "Otro" "Estudiante" ...  
## $ edad_agre : int 33 27 13 14 0 15 32 38 36 27 ...  
## $ sexo_agre : chr "M" "M" "F" "F" ...
```

```
## $ parentezco_vict      : chr  "Padre" "Otros" "Madre" "Otros" ...
## $ sust_vict           : int   2 2 2 2 2 2 2 2 2 2 ...
## $ fec_hecho           : chr   "12/06/2015" "04/02/2015" "21/07/2015" "22/04/2015" ...
## $ hora_hecho          : chr   "1899-12-31T06:30:00.000" "1899-12-31T10:00:00.000" "1899-12-31T08
## $ escenario           : int   1 1 2 1 7 7 3 1 2 2 ...
## $ zona_conf           : int   2 2 2 2 2 2 2 2 2 2 ...
## $ nom_eve             : chr   "VIGILANCIA EN SALUD PÚBLICA DE LAS VIOLENCIAS DE GÉNERO" "VIGILAN
## $ nom_upgd            : chr   "SERVICLINICOS DROMEDICA SA" "HOSPITAL LOCAL DEL NORTE" "HOSPITAL U
## $ ndep_resi           : chr   "SANTANDER" "SANTANDER" "SANTANDER" "SANTANDER" ...
## $ nmun_resi           : chr   "BUCARAMANGA" "BUCARAMANGA" "BUCARAMANGA" "BUCARAMANGA" ...
## $ MES                 : chr   "06. Junio" "02. Febrero" "07. Julio" "04. Abril" ...
```

Depuración de la base de datos

Selección casos de mujeres

```
data <- data %>% filter(sexo_ == "Femenino")
```

La base de datos tiene un total de 12161 casos de violencia de género donde 8406 corresponden a mujeres. De aquí adelante se trabaja solo con estos casos.

Variable orden y mes

La variable orden no aporta información útil al estudio, solo es de identificación y la variable mes está mal creada, no coincide con el mes de la fecha. Por lo tanto, se eliminan.

```
data <- data %>%
  select(-Orden, -MES)
```

Variables de tipo factor

Variable departamento

```
unique(data$Departamento)
```

```
## [1] "SANTANDER"      "NORTE SANTANDER" "CESAR"
## [4] "BOLIVAR"        "CAQUETA"         "BOYACA"
## [7] "DEPTO DESCONOCIDO" "CORDOBA"         "BOGOTA"
## [10] "ATLANTICO"      "ARAUCA"          "BARRANQUILLA"
## [13] "ANTIOQUIA"      "STA MARTA D.E."  "ZULIA"
## [16] "NARIÑO"         "APURE"           "SUCRE"
## [19] "CASANARE"       "MAGDALENA"       "ARAGUA"
## [22] "CARABOBO"       "TACHIRA"         "YARACUY"
## [25] "VARGAS"         "PORTUGUESA"      "CUNDINAMARCA"
## [28] "META"          "TOLIMA"          "BOLÍVAR"
```

La variable **departamento** presenta algunas inconsistencias en la escritura de los nombres, por lo que se han corregido los errores ortográficos en aquellos casos que pertenecen al mismo departamento. Además, se ha asignado a las ciudades de Barranquilla y Bogotá sus respectivos departamentos, para evitar que se consideren como departamentos diferentes.

```
data <- data %>%
  mutate(
    Departamento = recode(
      Departamento,
      "BOLIVAR" = "BOLÍVAR",
      "STA MARTA D.E." = "MAGDALENA",
      "NORTE SANTANDER" = "NORTE DE SANTANDER",
      "BARRANQUILLA" = "ATLÁNTICO",
      "BOGOTA" = "CUNDINAMARCA",
      "ATLANTICO" = "ATLÁNTICO",
      "CORDOBA" = "CÓRDOBA",
      "CAQUETA" = "CAQUETÁ",
      "BOYACA" = "BOYACÁ"
    )
  )
```

Por otro lado, se han identificado algunas filas que contenían nombres que no coinciden con departamentos de Colombia, y dado que esta columna corresponde al lugar de procedencia/ocurrencia del hecho y tras investigar, se determinó que algunos correspondían a estados de Venezuela, que no están en la frontera con Colombia. Estos registros se han clasificado solamente como “Depto[Venezuela]”. Lo mismo para departamentos de otros países. También, hay una categoría denominada “DEPTO DESCONOCIDO”, que relacionada con la columna **municipio** se encontró que corresponde a departamentos de otros países. Por lo tanto, se renombra estos casos como “Depto[País]”.

```
data <- data %>%
  mutate(
    # Arreglar formato mayúsculas:
    Departamento = str_to_title(Departamento),
    Municipio = str_to_title(Municipio),

    # Quitar asteriscos de nombres de países
    Municipio = str_replace(Municipio, "\\*", ""),

    # Cambiar "DEPTO DESCONOCIDO" por "Depto[País]" de acuerdo al valor que se
    # tiene en Municipio
    Departamento = ifelse(
      Departamento == "Depto Desconocido",
      paste0("Depto[", str_extract(Municipio, "[^ -]+"), "]"),
      Departamento
    ),

    # Arreglar a Depto[Estados Unidos] manualmente
    Departamento = ifelse(
      Departamento == "Depto[Estados]",
      paste0("Depto[Estados Unidos]"),
      Departamento
    ),

    # Modificar el departamento en los casos donde el municipio indica que no es de Colombia
```

```

Municipio = stri_trans_general(Municipio, "NFKD"),
# Normalizar caracteres Unicode
Departamento = ifelse(
  Municipio %in% c("Caroní (Ciudad Guayana).", "Sucre (Cumaná)."),
  "Depto[Venezuela]",
  Departamento
),

# Identificar departamentos que no son de Colombia y cambiar por Depto[País]
Departamento = case_when(
  Departamento %in% c(
    "Zulia",
    "Apure",
    "Aragua",
    "Carabobo",
    "Tachira",
    "Yaracuy",
    "Vargas",
    "Portuguesa"
  ) ~ "Depto[Venezuela]",
  TRUE ~ Departamento
)
)

```

Variable municipio

Los registros que tenían como valor el nombre de algún país se cambia por “Mun[País]”. Además, los registros que indican que no se conocía el municipio se asignó NA.

```

data <- data %>%
  mutate(
    Municipio = case_when(
      # Cambiar por NA los casos donde no se conoce el municipio
      str_detect(Municipio, "Municipio Desconocido") ~ NA_character_,

      # Asignar a casos con Depto[País] un valor de Mun[País] para esta variable
      str_detect(Departamento, "^Depto\\[(.*)\\]$") ~ str_replace(Departamento, "Depto\\[(.*)\\]", "Mun[

      # Corrección de nombres de municipios
      Municipio == "Ocana" ~ "Ocaña",
      Municipio == "Abrego" ~ "Ábrego",
      Municipio == "Abriaquí" ~ "Abriaquí",
      Municipio == "Charala" ~ "Charalá",
      Municipio == "Curumani" ~ "Curumaní",
      Municipio == "El Carmen De Chucuri" ~ "El Carmen De Chucurí",
      Municipio == "El Playon" ~ "El Playón",
      Municipio == "Fundacion" ~ "Fundación",
      Municipio == "Monteria" ~ "Montería",
      Municipio == "Samaca" ~ "Samacá",
      Municipio == "San Vicente De Chucuri" ~ "San Vicente De Chucurí",
      Municipio == "Santa Helena Del Opon" ~ "Santa Helena del Opón",
      Municipio == "Velez" ~ "Vélez",
      Municipio == "Chia" ~ "Chía",

```

```

Municipio == "Ibague" ~ "Ibagué",
Municipio == "Cucuta" ~ "Cúcuta",
Municipio == "Bogota" ~ "Bogotá",
Municipio == "Medellin" ~ "Medellín",
Municipio == "Tibu" ~ "Tibú",
Municipio == "Giron" ~ "Girón",
TRUE ~ Municipio
)
)

```

Variable Grupo de edad

Se modifica la escritura de algunos niveles.

```

data <- data %>%
  mutate(Grupo.edad = recode(Grupo.edad, "7 a 11" = "7 a 11", "60 y mas" = "60 y más"))

```

Variable ciclo de vida

Se modifica la escritura de algunos niveles.

```

data <- data %>%
  mutate(Ciclo.de.vida = recode(Ciclo.de.vida, "Jovenes" = "Jóvenes"))

```

Variable barrio

Se convirtieron los niveles “SIN INFORMACIÓN” a NA y se estandarizaron los niveles a minúsculas para evitar niveles repetidos. Además, para los casos con barrio “GRON” se encuentra que es un error tipográfico y se refiere es a Girón, municipio del área metropolitana de Bucaramanga.

```

data <- data %>%
  mutate(
    Barrio = recode(
      Barrio,
      "SIN INFORMACION" = NA_character_,
      "GRON" = "GIRÓN",
      "GIRON" = "GIRÓN"
    ),
    Barrio = tools::toTitleCase(tolower(Barrio))
  )

```

Variable comuna

Algunos niveles de esta variable corresponde a municipios y otros inician con un número indicativo. Por lo tanto, se remueve el indicativo y se convirtieron los niveles “SIN INFORMACIÓN”, “MONTE CRUZ” y “SANTOS BAJOS” a NA. Los últimos niveles debido a que no corresponden a una comuna ni a un municipio de Colombia.

```
unique(data$Comuna)
```

```
## [1] "GIRON" "01. NORTE" "03. SAN FRANCISCO"
## [4] "04. OCCIDENTAL" "SIN INFORMACION" "02. NORORIENTAL"
## [7] "12. CABECERA DEL LLANO" "17. MUTIS" "07. LA CIUDELA"
## [10] "15. CENTRO" "CORREG. 1" "11. SUR"
## [13] "FLORIDABLANCA" "13. ORIENTAL" "08. SUR OCCIDENTE"
## [16] "05. GARCIA ROVIRA" "06. LA CONCORDIA" "08. SUROCCIDENTE"
## [19] "09. LA PEDREGOSA" "10. PROVENZA" "14. MORRORICO"
## [22] "CORREG. 2" "16. LAGOS DEL CACIQUE" "CORREG. 3"
## [25] "30. CORREG" "CHOCOA" "SANTOS BAJOS"
## [28] "SOCORRO" "PIEDECUUESTA" "MONTE CRUZ"
## [31] "20. CORREG. 3" "31. CORREG. 2" "18. CORREG. 1"
## [34] "CHIMITA"
```

```
data <- data %>%
  mutate(
    Comuna = str_remove(Comuna, "[0-9]+\\.\\.\\s*"),
    Comuna = tools::toTitleCase(tolower(Comuna)),
    Comuna = case_when(
      Comuna %in% c("Sin Informacion", "Monte Cruz", "Santos Bajos") ~ NA_character_,
      Comuna == "Giron" ~ "Girón",
      TRUE ~ Comuna
    )
  )
```

Variable tipo de seguridad social

```
unique(data$Tipo.de.Seguridad.Social)
```

```
## [1] "Subsidiado" "No asegurado" "Contributivo" "Excepción"
## [5] "Especial" "Indeterminado" "subsidiado" "no asegurado"
## [9] "No Afiliado" "No Asegurado"
```

Para esta variable existen inconsistencias en la escritura de las categorías. Por ejemplo, hay variaciones en el uso de mayúsculas y minúsculas, lo que genera duplicados, como “No asegurado”, “No Asegurado” y “no asegurado”. La categoría “No afiliado”, se recodifica a “No asegurado”, y así disminuye el número de niveles en esta variable.

```
data <- data %>%
  mutate(
    Tipo.de.Seguridad.Social = recode(
      Tipo.de.Seguridad.Social,
      "no asegurado" = "No asegurado",
      "No Asegurado" = "No asegurado",
      "subsidiado" = "Subsidiado",
      "No Afiliado" = "No asegurado",
      "Excepción" = "Excepción",
      "Indeterminado" = "Indeterminado",
      "Especial" = "Especial"
    )
  )
```

```
)
)
```

Variable version

Esta variable corresponde a la versión del formato de notificación utilizado para reportar el caso al SIVIGILA.

```
data <- data %>% mutate(
  version = case_when(
    version == "SIVIGILA - 2016 -16.1.3" ~ "SIVIGILA - 2016 - 16.1.3",
    version == "SIVIGILA - 2017 -17.1.0" ~ "SIVIGILA - 2017 - 17.1.0",
    version == "SIVIGILA - 2017 -17.1.1" ~ "SIVIGILA - 2017 - 17.1.1",
    version == "SIVIGILA - 2017 -17.1.2" ~ "SIVIGILA - 2017 - 17.1.2",
    version == "SIVIGILA - 2018 -18.1.4" ~ "SIVIGILA - 2018 - 18.1.4",
    version == "SIVIGILA - 2018 -18.1.5" ~ "SIVIGILA - 2018 - 18.1.5",
    TRUE ~ version
  )
)
```

Variable def_naturaleza (Modalidad de la violencia)

Se refiere a cualquier acción o conducta violenta desarrollada a partir de relaciones de poder basadas en el género.

```
unique(data$def_naturaleza)
```

```
## [1] "Negligencia y abandono"
## [2] "Violencia fisica"
## [3] "Abuso sexual"
## [4] "Violencia psicologica"
## [5] "Acoso sexual"
## [6] "Violacion"
## [7] "Actos sexuales violencia"
## [8] "Sin informacion"
## [9] "Otros actos sexuales"
## [10] "Explotacion sexual, comercial niños, adolescentes"
## [11] "Sin Informacion"
## [12] "Actos sexuales"
## [13] "Acceso carnal"
## [14] "Otras violencias sexuales"
## [15] "ERROR: #N/A"
## [16] "Trata de personas"
```

Se realizaron ajustes en la variable **def_naturaleza** para mejorar la calidad de los datos, corrigiendo inconsistencias y estandarizando categorías. Se reemplazaron valores erróneos o faltantes, como “Sin Informacion” y “ERROR: #N/A”, por NA para tratarlos como datos faltantes. Además, se unificaron categorías similares, como “Otros actos sexuales” y “Otras violencias sexuales”, bajo una sola etiqueta (“Otras violencias sexuales”) para simplificar el análisis. Estas modificaciones permiten una mejor interpretación y manejo de los datos, facilitando su análisis posterior.


```
data <- data %>%
  mutate(
    def_naturaleza = recode(
      def_naturaleza,
      "Sin Informacion" = NA_character_,
      "ERROR: #N/A" = NA_character_,
      "Sin informacion" = NA_character_,
      "Violencia fisica" = "Física",
      "Violencia psicologica" = "Psicológica",
      "Otros actos sexuales" = "Otras violencias sexuales",
      "Actos sexuales violencia" = "Actos sexuales",
      "Explotacion sexual, comercial niños, adolescentes" = "Explotación sexual"
    )
  )
```

Variable naturaleza (indicativo de modalidad de la violencia)

Esta variable está tomando un valor de 99 en algunos registros, de acuerdo a las fichas encontradas con las que se notifican los casos de violencia, en ninguna versión hay una naturaleza/modalidad de violencia identificada con este valor. Por lo tanto, se convierte en NA.

```
data <- data %>%
  mutate(naturaleza = recode(as.character(naturaleza), "99" = NA_character_))
```

Variable nom_actividad

Esta variable indica la actividad a la que se dedica la víctima, tiene niveles como “Reciclador”, “Maestro”, “Servidor publico” y “Fuerza publica”.

```
unique(data$nom_actividad)
```

```
## [1] "Otro"
## [2] "Estudiante"
## [3] "Trabajadora domestica"
## [4] "Servidor publico"
## [5] "Maestro"
## [6] "Reciclador"
## [7] "Ninguna"
## [8] "Fuerza publica"
## [9] "Persona dedicada al cuidado del hogar"
## [10] "Persona en situación de prostitución"
## [11] ""
```

Teniendo en cuenta que son pocos los registros y a partir de la ficha de notificación del SIVIGILA 2018 estas categorías no son incluidas, se decide pasarlas a la categoría “Otro”.

```
data <- data %>%
  mutate(
    nom_actividad = recode(
      nom_actividad,
      "Trabajadora domestica" = "Trabajador(a) doméstico(a)",
    )
  )
```

```

    "Maestro" = "Otro",
    "Servidor publico" = "Otro",
    "Fuerza publica" = "Otro",
    "Reciclador" = "Otro"
  )
)

```

Variable actividad (indicativo de actividad de la víctima)

Esta variable es un indicativo para la variable anterior, por lo tanto, se realiza el cambio para las 4 categorías.

```

data <- data %>%
  mutate(actividad = recode(
    as.character(actividad),
    "8" = "26",
    "15" = "26",
    "16" = "26",
    "17" = "26",
  ))

```

Variable edad_agre (Edad del agresor)

Se cambia a NA los casos en que la edad es de 0 años.

```

data <- data %>%
  mutate(edad_agre = na_if(edad_agre, 0))

```

Variable sexo_agre (sexo del agresor)

Esta variable toma los valores de “ ” y “SD” en algunos registros, por lo tanto, se cambia a NA. Teniendo en cuenta que “SD” de acuerdo a los formatos de notificación significan ausencia del dato.

```

data <- data %>% mutate(
  sexo_agre = case_when(
    sexo_agre == " " ~ NA_character_,
    sexo_agre == "SD" ~ NA_character_,
    TRUE ~ sexo_agre
  )
)

```

Variable parentesco_vict (Parentesco del agresor con la víctima)

```

unique(data$parentesco_vict)

```

```

## [1] "Madre"                "Otros"
## [3] "Esposo"               "Excompañero permanente"
## [5] "Padre"               "Novio(a)"
## [7] "Hermano (a)"         "Primo (a)"

```

```
## [9] "Compañero permanente"      "Tío (a)"
## [11] "Cuñado (a)"                "Padrasto"
## [13] "Hijo"                       "Abuelo (a)"
## [15] "Ex - novio"                 "Ex esposo(a)"
## [17] "Suegro (a)"                 "Madrasta"
## [19] "Encargado (a) del NNA/Adulto mayor" "Pareja"
## [21] "Ex pareja"                  "Familiar"
## [23] "Ninguno"                    "Ex - amante"
## [25] "Amante"
```

El cambio de valores como “Novio(a)” a “Pareja”, “Ex - amante” a “Ex pareja” y “Pareja” a “Amante” permite agrupar las distintas relaciones de parentesco o afectivas bajo un formato más consistente. Estas modificaciones ayudan a mejorar la precisión de las categorías, asegurando que las relaciones similares sean tratadas de manera coherente.

```
data <- data %>%
  mutate(
    parentezco_vict = recode(
      parentezco_vict,
      "Novio(a)" = "Pareja",
      "Ex - amante" = "Ex - pareja",
      "Pareja" = "Amante"
    )
  )
```

Variable ndep_resi (Departamento de residencia de la víctima)

Hay cinco registros que indican “Exterior” en el departamento y “COLOMBIA - SIN ESPECIFICACIÓN ADICIONAL DE LUGAR” en el municipio.

```
# Ver registros
data %>% filter(ndep_resi == "EXTERIOR" &
  nmun_resi == "COLOMBIA - SIN ESPECIFICACIÓN ADICIONAL DE LUGAR") %>%
  select(ndep_resi, nmun_resi)
```

```
##      ndep_resi                                nmun_resi
## 1 EXTERIOR COLOMBIA - SIN ESPECIFICACIÓN ADICIONAL DE LUGAR
## 2 EXTERIOR COLOMBIA - SIN ESPECIFICACIÓN ADICIONAL DE LUGAR
## 3 EXTERIOR COLOMBIA - SIN ESPECIFICACIÓN ADICIONAL DE LUGAR
## 4 EXTERIOR COLOMBIA - SIN ESPECIFICACIÓN ADICIONAL DE LUGAR
## 5 EXTERIOR COLOMBIA - SIN ESPECIFICACIÓN ADICIONAL DE LUGAR
```

Para estos casos se cambia ndep_resi a NA. Además, se corrigen errores ortográficos.

```
data <- data %>%
  mutate(
    ndep_resi = tools::toTitleCase(tolower(ndep_resi)),
    ndep_resi = case_when(
      ndep_resi == "Exterior" &
        nmun_resi == "COLOMBIA - SIN ESPECIFICACIÓN ADICIONAL DE LUGAR" ~ NA_character_,
      ndep_resi == "Bolívar" ~ "Bolívar",
      ndep_resi == "Valle" ~ "Valle del Cauca",
    )
  )
```

```

ndep_resi == "Norte Santander" ~ "Norte de Santander",
ndep_resi == "Bogota" ~ "Cundinamarca",
ndep_resi == "Boyaca" ~ "Boyacá",
TRUE ~ ndep_resi
)
)

```

Variable nmun_resi (Municipio de residencia de la víctima)

Para los cinco registros que indican “COLOMBIA - SIN ESPECIFICACIÓN ADICIONAL DE LUGAR” en municipio se cambio este valor a NA, al igual que los niveles que indicaban de otra forma desconocimiento del municipio.

```

data <- data %>% mutate(
  nmun_resi = tools::toTitleCase(tolower(nmun_resi)),
  nmun_resi = case_when(
    str_detect(nmun_resi, "Municipio Desconocido") ~ NA_character_,
    str_detect(nmun_resi, "Exterior") ~ "Exterior",
    nmun_resi == "Colombia - Sin Especificación Adicional De Lugar" ~ NA_character_,
    nmun_resi == "Contratacion" ~ "Contratación",
    nmun_resi == "Cucuta" ~ "Cúcuta",
    nmun_resi == "Bogota" ~ "Bogotá",
    nmun_resi == "Giron" ~ "Girón",
    nmun_resi == "El Playon" ~ "El Playón",
    nmun_resi == "San Vicente De Chucuri" ~ "San Vicente De Chucurí",
    nmun_resi == "Charala" ~ "Charalá",
    nmun_resi == "Santa Helena Del Opon" ~ "Santa Helena del Opón",
    TRUE ~ nmun_resi
  )
)

```

Finalmente, las variables como **hospitalización**, **condición al egresar**, **presencia de sustancias**, **escenario** y **zona de exposición** también son categóricas y representan distintas categorías sin un orden específico. Esta conversión facilita el análisis estadístico y la interpretación de los resultados futuros, para cuando se desee estudiar estas variables categóricas.

```

data <- data %>%
  mutate(across(
    c(
      Departamento,
      Municipio,
      año,
      Grupo.edad,
      Ciclo.de.vida,
      sexo_,
      area_,
      Barrio,
      Tipo.de.Seguridad.Social,
      pac_hos_,
      con_fin_,
      version,
      def_naturaleza,
    )
  ))

```

```

    actividad,
    sexo_agre,
    parentesco_vict,
    sust_vict,
    escenario,
    zona_conf,
    nom_eve,
    nom_upgd,
    ndep_resi,
    nmun_resi
  ),
  as.factor
))

```

Variable hora_hecho (hora del hecho)

Se realizó una transformación en la variable **hora_hecho** para extraer únicamente la hora de la cadena de texto, la cual está en formato de 24 horas y se convirtió en un objeto de tipo hms, lo que permite un manejo más eficiente de los tiempos. Este proceso garantiza que la variable esté en un formato uniforme y adecuado para su análisis.

```

data <- data %>%
  # Extraer solo la hora y convertirla a formato de tiempo con hms
  mutate(
    hora_hecho = hora_hecho %>%
      sub(".*T(\\d{2}:\\d{2}:\\d{2}).*", "\\1", .) %>%
      as.POSIXct(format = "%H:%M:%S") %>%
      format(format = "%H:%M:%S") %>%
      as_hms()
  )

```

Variable fecha del hecho

El formato de fecha inicial es dd/mm/yyyy pero al convertir a objeto Date se cambia al formato por defecto: yyyy-mm-dd.

```

# Cambiar tipo de dato a Date
data$fec_hecho <- as.Date(data$fec_hecho, format = "%d/%m/%Y")

```

Valores faltantes

##	Column	total_na	total_empty
## 1	Departamento	0	0
## 2	Municipio	3	0
## 3	semana	0	0
## 4	año	0	0
## 5	Grupo.edad	0	0
## 6	Ciclo.de.vida	0	0
## 7	sexo_	0	0
## 8	area_	0	0

## 9	Barrio	852	0
## 10	Comuna	853	0
## 11	Tipo.de.Seguridad.Social	0	0
## 12	pac_hos_	0	0
## 13	con_fin_	0	0
## 14	version	0	0
## 15	naturaleza	2190	0
## 16	def_naturaleza	544	0
## 17	actividad	0	0
## 18	nom_actividad	0	5697
## 19	edad_agre	5046	0
## 20	sexo_agre	102	0
## 21	parentezco_vict	0	0
## 22	sust_vict	0	0
## 23	fec_hecho	5	0
## 24	hora_hecho	4678	0
## 25	escenario	3	0
## 26	zona_conf	0	0
## 27	nom_eve	0	0
## 28	nom_upgd	0	0
## 29	ndep_resi	5	0
## 30	nmun_resi	16	0

De acuerdo a lo anterior son 14297 celdas NA y 5697 celdas que fueron definidas como vacías poniendo “.

Para un total de 6284 registros con valores faltantes y celdas vacías, lo que corresponde al 74.76% de la base de datos. Sin embargo, como hay columnas relacionadas, algunas celdas de una columna pueden recibir un valor a partir de otra columna.

Relacionar información para rellenar campos

```
# Variable Comuna a partir de barrio
row_na_empty %>%
  filter(!is.na(Barrio) |
         Barrio != "" & (is.na(Comuna) | Comuna == "")) %>%
  select(Barrio, Comuna)
```

##	Barrio	Comuna
## 1	Santos Bajos	<NA>
## 2	Monte Cruz	<NA>
## 3	Chapinero	<NA>
## 4	Girón	<NA>
## 5	Girón	<NA>
## 6	Girón	<NA>
## 7	Girón	<NA>

```
data <- data %>%
  mutate(
    Comuna = case_when(
      (is.na(Comuna) |
       Comuna == "") & Barrio == "Chapinero" ~ "San Francisco",
      (is.na(Comuna) |
```

```

        Comuna == "") & Barrio == "Santos Bajos" ~ "Provenza",
    (is.na(Comuna) |
        Comuna == "") & Barrio == "Monte Cruz" ~ "Morrórico",
    (is.na(Comuna) | Comuna == "") & Barrio == "Girón" ~ "Girón",
    TRUE ~ Comuna
  )
)

# Convertir a factor
data$Comuna <- as.factor(data$Comuna)

# Variable naturaleza a partir de def_naturaleza
row_na_empty %>% filter((!is.na(def_naturaleza) |
                        def_naturaleza != "") &
                        (is.na(naturaleza) |
                         naturaleza == "")) %>%
select(def_naturaleza, naturaleza) %>%
head(5)

##           def_naturaleza naturaleza
## 1             Física          <NA>
## 2 Negligencia y abandono          <NA>
## 3 Negligencia y abandono          <NA>
## 4             Física          <NA>
## 5             Física          <NA>

data <- data %>%
  mutate(
    naturaleza = case_when(
      (is.na(naturaleza) |
        naturaleza == "") & def_naturaleza == "Acceso carnal" ~ "6",
      (is.na(naturaleza) |
        naturaleza == "") & def_naturaleza == "Acoso sexual" ~ "5",
      (is.na(naturaleza) |
        naturaleza == "") & def_naturaleza == "Actos sexuales" ~ "12",
      (is.na(naturaleza) |
        naturaleza == "") &
        def_naturaleza == "Negligencia y abandono" ~ "3",
      (is.na(naturaleza) |
        naturaleza == "") &
        def_naturaleza == "Otras violencias sexuales" ~ "14",
      (is.na(naturaleza) |
        naturaleza == "") & def_naturaleza == "Trata de personas" ~ "10",
      (is.na(naturaleza) |
        naturaleza == "") & def_naturaleza == "Física" ~ "1",
      (is.na(naturaleza) |
        naturaleza == "") & def_naturaleza == "Psicológica" ~ "2",
      TRUE ~ naturaleza
    )
  )

# Convertir a factor
data$naturaleza <- as.factor(data$naturaleza)

```

```
# Variable nombre de actividad (nom_actividad) a partir del indicativo de actividad
row_na_empty %>% filter(!is.na(actividad) |
                        actividad != "" &
                        (is.na(nom_actividad) |
                         nom_actividad == "")) %>%
select(actividad, nom_actividad) %>%
head(5)
```

```
##   actividad nom_actividad
## 1         31
## 2         24
## 3         24
## 4         24
## 5         24
```

```
data <- data %>%
  mutate(
    nom_actividad = case_when(
      (is.na(nom_actividad) |
       nom_actividad == "") & actividad == "13" ~ "Líderes(as) cívicos",
      (is.na(nom_actividad) |
       nom_actividad == "") & actividad == "24" ~ "Estudiante",
      (is.na(nom_actividad) |
       nom_actividad == "") & actividad == "26" ~ "Otro",
      (is.na(nom_actividad) |
       nom_actividad == "") &
      actividad == "28" ~ "Trabajador(a) doméstico(a)",
      (is.na(nom_actividad) |
       nom_actividad == "") &
      actividad == "29" ~ "Persona en situación de prostitución",
      (is.na(nom_actividad) |
       nom_actividad == "") & actividad == "30" ~ "Campesino/a",
      (is.na(nom_actividad) |
       nom_actividad == "") &
      actividad == "31" ~ "Persona dedicada al cuidado del hogar",
      (is.na(nom_actividad) |
       nom_actividad == "") &
      actividad == "32" ~ "Persona que cuida a otras",
      (is.na(nom_actividad) |
       nom_actividad == "") & actividad == "33" ~ "Ninguna",
      TRUE ~ nom_actividad
    )
  )

# Convertir a factor
data$nom_actividad <- as.factor(data$nom_actividad)
```

Se puede observar que disminuyó la cantidad de celdas vacías.

```
##           Column total_na total_empty
## 1     Municipio         3           0
## 2       Barrio       852           0
```


## 3	Comuna	846	0
## 4	naturaleza	544	0
## 5	def_naturaleza	544	0
## 6	edad_agre	5046	0
## 7	sexo_agre	102	0
## 8	fec_hecho	5	0
## 9	hora_hecho	4678	0
## 10	escenario	3	0
## 11	ndep_resi	5	0
## 12	nmun_resi	16	0

Luego de rellenar las celdas vacías a partir de información relacionada queda un total de 5685 registros con celdas vacías, lo que corresponde al 67.63% de la base de datos. Es decir, se pueden utilizar 2721 registros completos.

Sin embargo, variables como **edad agresor** y **hora del hecho** no se encuentran en todas las fichas de notificación del SIVIGILA, lo que puede ser la razón por la cual hay tantas celdas vacías en estas columnas. Según lo investigado desde la ficha 2018 (inclusive) no se pide estas variables.

Si no se consideran estas columnas disminuye a 1426 registros con algún valor faltante.

```
data <- data %>%
  select(-edad_agre, -hora_hecho) %>%
  filter(complete.cases(.) &
    !apply(., 1, function(row)
      any(row == "")))
```

Al eliminar estos registros con algún valor faltante, se obtiene una base de datos con 6980 registros completos.

Registros duplicados

```
# Buscar registros duplicados
data %>%
  filter(duplicated(.)) %>%
  nrow()
```

```
## [1] 19
```

```
data <- data %>%
  distinct()
```

Finalmente, al eliminar los registros duplicados se obtiene una base de datos depurada con **6961 registros**.

Base de datos depurada

```
# Guardar base de datos
# save_data(data, "datos_abiertos_2015_2023_debugged", type = "interim", format = "csv")
```