

Depuración información del portal de datos públicos de Medellín
(MEData).

2024-11-13

Contents

Información de la base de datos	2
Lectura de la base de datos	2
Depuración de la base de datos	2
Clasificación del caso	3
Nacionalidad	3
Datos epidemiológicos (periodo_epid)	4
Fechas	4
Información de la víctima	5
Información del hecho	10
Información del agresor	12
Información de la atención/notificación	14
Valores faltantes	15
Registros duplicados	18
Conversión a factor	19
Orden de las columnas	19
Base de datos depurada	19

Información de la base de datos

La base de datos, titulada *Vigilancia Integrada de la Violencia de Género*, está alojada en el portal MEData (Ver). Este recurso recopila información sobre los casos sospechosos de violencia de género ocurridos en Antioquia, los cuales fueron reportados al SIVIGILA.

- **Última actualización:** 20 de septiembre de 2023.
- **Información sobre las variables:** Adicional al diccionario que aparece en MEData, el formato de notificación al SIVIGILA contiene indicaciones sobre muchas de las variables (Ver).

Lectura de la base de datos

Depuración de la base de datos

La base de datos está conformada por 118 variables, sin embargo, se elimina las siguientes variables por no ser de relevancia para el análisis:

1. Nombre de la Unidad Primaria Generadora de Datos(**nom_upgd**)
2. Código y nombre del evento (**cod_eve - nom_eve**)
3. Código asignado en el SGSSS a los prestadores de servicios de salud que se hayan registrado en el 'Registro Especial de Prestadores de Servicios de Salud' (**cod_pre**)
4. Código asignado en el SGSSS a los prestadores de servicios de salud que indica sede ó territorio (**cod_sub**)
5. Código Administradora responsable de la atención del paciente, asignado por MSP (**cod_ase**)
6. Número del certificado defunción (**cer_def__**)
7. fecha efectiva de digitación del registro o realizar un ajuste a un registro previo (**fec_aju__**)
8. Número de registros (**nreg**) - Estado de transformación de la notificación (**estadotran**)
9. Fuerza (**fm_fuerza**) - Código de la Unidad Militar según tabla de Unidades Militares (**fm_unidad**)
10. Código de la Grado Militar según tabla de Grados Militares (**fm_grado**)
11. Contexto de la notificación, sus categorías son: notificación rutinaria, búsqueda, activa Institucional, vigilancia intensificada, búsqueda activa Comunitaria, investigaciones (**Fuente**)

Dado que el interés son los casos de violencia en mujeres que ocurren en Colombia se filtra la base para analizar solo estos casos. Según el formato de notificación 2024 cuando la variable **identidad de género** (**ident_gene**) es igual a 2 corresponde a mujer y cuando es igual a 4 corresponde a mujer trans. Mientras que la variable **país de ocurrencia del caso** (**cod_pais_o**) igual a 170 representa a Colombia.

```
data <- data %>% filter((ident_gene == 2 | ident_gene == 4) & cod_pais_o == 170)
```

Se obtiene un total de 55556 registros, descartando 26467.

Clasificación del caso

La variable clasificación inicial del caso (**tip_cas__**) puede tomar los siguientes valores: 1 = Sospechoso, 2 = Probable, 3 = Confirmado por Laboratorio, 4 = Confirmado por Clínica, 5 = Confirmado por Nexo Epidemiológico.

```
##      1
## 55556
```

Todos los casos son sospechosos. Sin embargo, las variables seguimiento y clasificación final del caso (**ajuste__**) indica que la clasificación de algunos casos cambiaron.

```
##      0      7  NA's
## 50708 4837    11
```

El valor de **7** indica que se modificó algún campo de la ficha, los únicos que no se pueden modificar son código de evento, Upgd, numero de id, fecha de notificación.

Luego, la variable clasificación final (**clasificación_final**) indica que 5 de los registros sospechosos terminaron siendo probables.

```
##      1      2
## 55551      5
```

Dado que estás variables nos indican que la mayoría de casos no cambian de estado y los que sí, cambian a un estado similar, se decide eliminarlas.

Nacionalidad

Se cuenta con el código (**nacionali__**) y nombre de la nacionalidad (**nombre_nacionalidad**), que corresponde al estado o nación que pertenece la víctima según su documento de identificación.

##	Afganistán	Anguila
##	1	1
##	Antillas Neerlandesas	Bangladesh
##	1	3
##	Bélgica	Bosnia Y Herzegovina
##	2	7
##	Brasil	Camerún
##	1	1
##	Canadá	Colombia
##	1	34706
##	Comoras	Costa Rica
##	7	1
##	Croacia	Cuba
##	1	1
##	Ecuador	España
##	2	3
##	Estados Unidos De América	Federación De Rusia
##	8	1
##	Francia	Isla De Navidad
##	1	1

##	Madagascar	Malta
##	1	1
##	México	Montserrat
##	5	1
##	Myanmar	Países Bajos
##	1	1
##	Panamá	Perú
##	1	4
##	Reino Unido	República Centroafricana
##	1	2
##	República Democrática Del Congo	República Dominicana
##	1	1
##	Sudáfrica	Surinam
##	1	1
##	Uruguay	Venezuela
##	1	900
##	NA's	
##	19883	

Sin embargo, en la última variable el 35.789% de los casos son NA. Dado que es un porcentaje alto y no hay manera de relacionar con **nacionali__** porque tienen la misma cantidad de NA, se decide eliminarla.

Datos epidemiológicos (periodo_epid)

El periodo corresponde a cada 4 semanas completas del calendario epidemiológico. Son 13 periodos al año. Sin embargo, esta variable está tomando el valor de 16 en 876 registros

##	1	2	3	4	5	6	7	8	9	10	11	12	13	16
##	4309	4305	4440	2954	4491	4395	4397	4292	4303	4493	3869	4283	4149	876

Todos estos registros corresponden al año 2022 y toman en la **semana epidemiologica** valores de 13-16. Analizando con el calendario de este año, no existe periodo 16 y el periodo para esas semanas es el periodo número 4.

Con respecto a la semana y el año se encontraron inconsistencias. En esta base la semana epidemiológica corresponde a la semana en que se notificó el hecho. Sería de más utilidad en el análisis trabajar con la semana epidemiológica en la que ocurrió el hecho.

Dado a las inconsistencias y que se tiene la fecha exacta de notificación, se decide eliminar estas variables

Fechas

El formato inicial es dd/mm/yyyy pero al convertir a objeto Date se cambia al formato por defecto: yyyy-mm-dd.

Notificación (fec_not)

Consulta (fec_con_)

Fecha en la que consultó el paciente.

Inicio de síntomas (ini_sin_)

Fecha del primer día en que el paciente inició síntomas.

Hospitalización (fec_hos_)

Fecha en la que el paciente fue hospitalizado como consecuencia del event

Defunción (fec_def_)

Fecha en la que el paciente fallece como consecuencia del evento.

Nacimiento (fecha_nto_)

Hecho (fec_hecho)

Fecha en que ocurrió el hecho o evento.

Condiciones

El formato de notificación 2024 proporciona para la sistematización del caso una serie de condiciones que debe cumplirse en estas variables:

- La fecha de notificación debe ser mayor o igual a la fecha de inicio de síntomas y a la fecha de consulta.

199 registros no cumplen esta condición. Luego de descartarlos, se obtiene un total de 55357.

- La fecha de inicio de síntomas NO debe ser superior a la fecha de consulta.

3 registros no cumplen esta condición. Luego de descartarlos, se obtiene un total de 55354.

- La fecha de hospitalización NO puede ser inferior a la fecha de consulta, ni a la fecha de notificación.

3450 registros no cumplen esta condición. Luego de descartarlos, se obtiene un total de 51904.

- La fecha de nacimiento debe ser inferior a todas las demás fechas.

499 registros no cumplen esta condición. Luego de descartarlos, se obtiene un total de 51405.

Información de la víctima

Edad de la víctima (edad_,uni_med_,grupo_edad_ciclo,grupo_edad_quinque)

La edad de la víctima se registra en diferentes medidas (**uni_med**): años(1), meses(2), días(3), horas(4), minutos(5). Existen algunos casos donde la unidad de medida es 0, sin embargo, de acuerdo a la ficha de notificación 2024: “La unidad de medida 0=‘no aplica’, **solo puede ser utilizada para el evento 215 defectos congénitos**, cuando el diagnóstico se realiza prenatal”. Por lo tanto, se decide eliminar estos registros.

```
data <- data %>% filter(uni_med_ != 0)
```

Se eliminan 8 registros, quedando una base de datos de 51397. También se encuentra que para algunos registros la unidad de medida son incorrectas.

Las variables **edad_hecho** y **edad_notif** se calcularon como la diferencia en tiempo entre la fecha de nacimiento y la fecha del hecho y notificación, respectivamente, según la unidad de medida. Luego, si se compara la edad original con las edades calculadas la diferencia es evidente, demostrando que la unidad de medida es incorrecta.

##	uni_med_	edad_	edad_hecho	edad_notif	fecha_nto_	fec_hecho	fec_not
## 1	5	6	3172320	3548160	2012-01-22	2018-02-02	2018-10-21
## 2	5	1	879840	881280	2016-08-01	2018-04-04	2018-04-05
## 3	4	6	55176	60336	2011-09-16	2018-01-01	2018-08-04
## 4	4	9	6744	6768	2017-10-09	2018-07-17	2018-07-18
## 5	3	2	992	1083	2016-02-12	2018-10-31	2019-01-30

Luego, analizando la edad original, la edad al momento del hecho y al momento de notificación, se puede observar que en la mayoría de casos las tres edades son iguales porque sucedió y se notificó el evento el mismo día. O la edad coincide con la edad al momento de notificar

##	Ambas	Inconsistencia	Notificación	NA's
##	35064	2192	4861	9280

Los registros clasificados como inconsistencia, son registros donde la edad original no coincide con ninguna de las calculadas:

##	uni_med_	edad_	edad_hecho	edad_notif	fecha_nto_	fec_hecho	fec_not
## 1	3	3	1	1	2022-09-16	2022-09-17	2022-09-17
## 2	3	3	1	1	2022-09-16	2022-09-17	2022-09-17
## 3	3	15	11	11	2022-07-24	2022-08-04	2022-08-04
## 4	2	8	1	6	2020-07-27	2020-09-06	2021-02-15
## 5	3	28	5	26	2020-06-04	2020-06-09	2020-06-30

Teniendo en cuenta las inconsistencias mostradas, que se puede deducir que la edad corresponde a la edad al momento de notificación, y que el objetivo es prevenir, se decide calcular la edad en años al momento del hecho.

Sin embargo, 14196 registros parecen tomar fechas genéricas en la fecha de nacimiento (**fecha_nto_**) y además, tiene 9280 NA.

##	uni_med_	edad_	edad_hecho	edad_notif	fecha_nto_	fec_hecho	fec_not
## 1	1	55	10	10	2009-01-01	2019-03-31	2019-04-01
## 2	1	71	34	34	1985-01-01	2019-03-31	2019-04-01
## 3	1	18	14	14	2005-01-01	2019-03-30	2019-04-01
## 4	1	38	24	24	1995-01-01	2019-03-29	2019-04-01
## 5	1	22	27	27	1992-01-01	2019-03-24	2019-04-01

Mientras que la fecha del hecho (**fec_hecho**) tiene 0 NA y al parecer también tiene 2849 filas con fechas genéricas

##	uni_med_	edad_	fecha_	nto_	fec_hecho	fec_not
## 1	1	13	2005-01-18	2018-01-01	2018-09-26	
## 2	1	16	2006-08-14	2016-01-01	2022-11-05	
## 3	1	13	2008-10-20	2022-01-01	2022-03-05	
## 4	1	76	1945-12-09	1982-01-01	2022-03-05	
## 5	1	14	2006-07-03	2020-01-01	2020-09-28	

Por los valores faltantes no se podrían calcular la edad al momento del hecho para 9280 registros y las fechas genéricas podrían sesgar el calculo de la edad

Para manejar estas situaciones se decide:

- Dado que la edad original de la mayoría de registros con fechas genéricas fue registrada en años, si se tiene este caso y la diferencia entre la edad original y la edad calculada es mayor a 1, se conserva la edad original.
- Si la fecha de nacimiento es genérica o NA y la fecha del hecho y notificación es igual, se conserva la edad original pasada a años.

Finalmente, se reduce a 7438 registros con NA.

Edad agrupada (grupo_edad_quinque - grupo_edad_cliclo)

Se comprobó que estas variables tienen los cálculos erróneos, pues, al realizar el cálculo de forma manual desde la fecha de nacimiento hasta la fecha del hecho (o notificación), en ninguno de los dos casos, corresponde al grupo que se le asigna en cada una de estas variables. Así, resulta más óptimo eliminarlas.

Se construye una variable que representa el grupo etario de acuerdo a las etapas del ciclo de vida definidas por el MSPS (Ver)

```
data <- data %>% mutate(
  grupo_edad = case_when(
    edad >= 0 & edad < 6 ~ "0-5",
    edad >= 6 & edad < 12 ~ "6-11",
    edad >= 12 & edad < 19 ~ "12-18",
    edad >= 19 & edad < 27 ~ "19-26",
    edad >= 27 & edad < 60 ~ "27-59",
    edad >= 60 ~ "60 y más",
    TRUE ~ NA_character_
  )
)
```

Nombre del país de residencia (npais_resi)

Se cambia la estructura de escritura

Nombre del departamento de residencia (ndep_resi)

La variable presentaba errores de escritura en algunos nombres de departamentos, como la ausencia de tildes y nombres incompletos, estos errores fueron corregidos asegurando la consistencia de los nombres de los departamentos. Además, habían algunos niveles que representaban entidades por fuera de Colombia, como “COJEDES” (Venezuela) y “PANAMÁ” (Panamá), que fueron asignados como NA, al igual que el nivel de “DEPTO DESCONOCIDO”. Por último, los niveles que correspondían a ciudades específicas, como “BOGOTA”, “CARTAGENA” y “BARRANQUILLA”, fueron reemplazados por el nombre del departamento al que pertenecen.

Nombre del municipio de residencia (nmun_resi)

La variable presentaba inconsistencias en los nombres de los municipios. Se reemplazaron los niveles que no tenían un nombre específico de municipio o que eran desconocidos por NA, así como aquellos que correspondían a países o ciudades fuera de Colombia. Además, algunas filas correspondientes al municipio de Bogotá incluían nombres de barrios o localidades, por lo que se estandarizó asignando únicamente el nombre de la ciudad.

Nombre comuna de residencia

Esta variable sirve para imputar datos faltantes del municipio

Estrato (estrato_)

Esta variable es información de la ficha de datos básicos que se debe registrar para cualquier evento que se reporta al SIVIGILA. Sin embargo, se encontró una ficha del 2016 donde no se solicita y otra de 2019 donde sí, lo que puede explicar porqué la gran cantidad de NA

##	1	2	3	4	5	6	NA's
##	2864	10233	6091	387	90	71	31661

Orientación sexual (orient_sex)

De acuerdo a las fichas de notificación 2015-2022 y el diccionario de la base de datos, los niveles de esta variable son: homosexual(1),bisexual(2),heterosexual(5) y asexual(6). Sin embargo, esta variable también toma valor 3 y 4.

##	1	2	3	4	5	6
##	535	746	12	4347	44789	968

Al notificar un caso se llena una ficha de datos básicos y una ficha relacionada al evento. Ambas fichas en las versiones recientes piden la orientación sexual. Sin embargo, la clasificación en la ficha de datos tiene una codificación diferente: heterosexual(1), gay/lesbiana(2), bisexual(3) y otra(4)

Ocupación de la víctima (ocupacion_)

De acuerdo al diccionario en MEData la codificación de esta variable corresponde a la Clasificación Única de Ocupaciones para Colombia (CUOC). El valor que toma el código puede ser hasta de 5 dígitos, cada dígito asigna un adicional de precisión sobre la ocupación. Por ejemplo, “25120” corresponde a desarrolladores de software mientras que “251” es desarrolladores y analistas de software y multimedia.

Sin embargo, algunos registros no tienen ningún tipo de relación con la codificación.

##	ocupacion_
## 1	99999.01
## 2	LIM
## 3	99999.01
## 4	99999.01
## 5	99999.01
## 6	99999.01
## 7	99999.01
## 8	99999.01
## 9	CL

Entonces se verifica que los valores tomados en esta variable se encuentran en la clasificación mediante la siguiente base de datos que contiene las 676 ocupaciones posibles (código de 5 dígitos) y en caso que el valor de la variable no coincida con los códigos posibles se convierte el valor a NA.

Esta variable queda con 45912 celdas vacías. Pero puede servir para completar información de los niveles 26 (Otro) y 33 (Ninguna) de la variable **actividad**. Es importante resaltar que esta variable se pide en la ficha de datos básicos mientras que actividad en la ficha del evento.

Actividad

Esta variable es numérica pero se cambia a string para hacer la relación con **ocupación**

##	13	15	24	26	28	29	30	31	32	33
##	17	1	9689	16418	1774	113	21	9680	139	13545

```
data <- data %>%
  mutate(
    actividad = case_when(
      actividad == 13 ~ "Líderes(as) cívicos",
      actividad == 15 ~ "Maestro(a)",
      actividad == 24 ~ "Estudiante",
      actividad == 26 ~ "Otro",
      actividad == 28 ~ "Trabajador(a) doméstico(a)",
      actividad == 30 ~ "Campesino/a",
      actividad == 29 ~ "Persona en situación de prostitución",
      actividad == 31 ~ "Persona dedicada al cuidado del hogar",
      actividad == 32 ~ "Persona que cuida a otras",
      actividad == 33 ~ "Ninguna"
    )
  )
```

Son 4205 registros con valor “Otro” o “Ninguna” en **actividad** y que tienen valor en **ocupación**. Para evitar tantas categorías, se extrae el primer dígito que representa los 10 grupos principales de ocupaciones:

```
ocupaciones <- c(
  "0" = "Fuerzas militares",
  "1" = "Directores y gerentes",
  "2" = "Profesionales, científicos e intelectuales",
  "3" = "Técnicos y profesionales del nivel medio",
  "4" = "Personal de apoyo administrativo",
  "5" = "Trabajadores de los servicios y vendedores de comercios y mercados",
  "6" = "Agricultores y trabajadores calificados agropecuarios,forestales y pesqueros",
  "7" = "Oficiales, operarios, artesanos y oficios relacionados",
  "8" = "Operadores de instalaciones y máquinas y ensambladores",
  "9" = "Ocupaciones elementales"
)
```

Algunas categorías se cambian a su nombre equivalente en la CUOC:

- Maestro(a) a Profesionales, científicos e intelectuales
- Trabajador(a) doméstico(a) a Trabajador(a) doméstico(a) ~ “Ocupaciones elementales
- Campesino/a a Agricultores y trabajadores calificados agropecuarios,forestales y pesqueros

Grupo étnico (nom_grupo_)

Esta variable toma valor si la variable **Pertenencia étnica (per_etn_)** es igual a 1 (indígena), en caso contrario, se asigna “No aplica”.

Semanas de gestación (sem_ges_)

Esta variable toma valor si la variable **gp_gestan** es igual a 1 (Sí). Además, se verifica que dicho valor sea entre 1 y 45 ya que es lo esperado en tiempo de gestación.

Información del hecho

Lugar de ocurrencia del evento

La codificación de las variables código del departamento (**cod_dpto_o**) y municipio (**cod_mun_o**) de ocurrencia corresponde a la codificación Divipola (Ver) para departamentos y municipios de Colombia.

Para facilidad en la comprensión de los resultados y dado que la mayoría de las variables que representan lugares tiene su equivalente en nombre, se decide crear dos nuevas variables que tomen como valor el nombre del departamento y municipio de ocurrencia.

Ahora bien, el diccionario de la base de datos indica que hay variables del país, departamento y municipio de procedencia y del hecho. Lo considera como variables separadas para cada uno. Sin embargo, en la ficha solo se tiene un campo con el siguiente nombre: “**Departamento y municipio de procedencia/ocurrencia**” e indica que se refiere al lugar donde posiblemente el paciente adquirió o al cual se atribuye la exposición al agente o factor de riesgo que ocasionó el evento.

Se comprobó que estas variables son totalmente iguales, por lo tanto, se eliminan las variables relacionadas al departamento y municipio de procedencia y se deja las variables relacionadas al hecho.

Área y barrio

##	area_	localidad_	bar_ver_	cen_pobla_	vereda_
## 1	1	MEDELLIN			POPULAR
## 2	1	SD	LOPEZ DE MESA		
## 3	1	<NA>	CARPINELO		
## 4	1	<NA>	LLANADITAS		
## 5	1	<NA>	LA COLINA		
## 6	1	SANTA CRUZ	SANTA CRUZ		
## 7	1	MEDELLIN SANTO DOMINGO SAVIO N01			
## 8	2				ROBLEDO
## 9	2				BELLO
## 10	1	MEDELLIN	BELEN		

Con respecto a las variables **bar_ver_**, **vereda_**, **localidad_** y **cen_pobla_**, estas corresponden a la ubicación donde ocurrieron los hechos de violencia. Según las fichas de SIVIGILA, su uso depende de la variable **área_**, que clasifica el lugar del hecho en: (1) Cabecera municipal, (2) Centro poblado o (3) Rural disperso.

Cada variable tiene la siguiente función:

- **bar_ver_**: Barrio dentro de una cabecera municipal.
- **vereda_**: Vereda en un área rural dispersa.

- **localidad__**: Localidad en municipios sectorizados (como Medellín o Bogotá).
- **cen_pobla__**: Centro poblado en áreas rurales.

Con el fin de estandarizar la información, y manejar los datos faltantes, se realizaron algunos ajustes:

1. Limpieza de datos: Se reemplazaron por NA los valores que indicaban falta de información, tales como “SIN INFORMACIÓN”, “NO REGISTRA”, “DESCONOCIDO”, valores vacíos, entre otros.
2. Unificación de variables:
 - Se creó una nueva variable que fusiona **localidad__** y **bar_ver__**, dado que ambas se utilizan únicamente cuando **área__** = 1 (cabecera municipal).
 - Se combinó **vereda__** y **cen_pobla__**, asignando **vereda__** cuando **área__** = 3 (rural disperso) y **cen_pobla__** cuando **área__** = 2 (centro poblado).
3. Completado de valores faltantes:
 - Si **bar_ver__** estaba vacío en un área urbana (**área__** = 1), se completó con **cen_pobla__**, en caso de que esta última tuviera información.
4. Creación de la variable **lugar_hecho**:
 - Si el área es cabecera municipal (1), se asigna **bar_ver__** y, si está vacío, se usa **localidad__** / **cen_pobla__**.
 - Si el área es centro poblado (2), se usa **cen_pobla__**.
 - Si el área es rural disperso (3), se usa **vereda__**.
 - Si no hay información disponible, se asigna NA.
5. Eliminación de variables innecesarias:
 - Se eliminaron las variables originales (**bar_ver__**, **localidad__**, **cen_pobla__**, **vereda__**) después de construir la variable **lugar_hecho**.

Hora del hecho

Esta variable no se solicita en las versiones recientes de la ficha, lo que explica los 0 registros con NA.

Modalidad de la violencia (**naturaleza** y **nat_viosex**)

De acuerdo a las fichas de notificación existen dos grupos de modalidad: violencia no sexual y violencia sexual, cada una con diferentes tipos. Si la víctima sufrió violencia no sexual se registra el tipo en la variable **naturaleza** y si sufrió violencia sexual se registra el tipo en la variable **nat_viosex**.

Por facilidad en el análisis y evitando la mayor cantidad de celdas vacías posibles, se decide unificar la información de ambas variables en una variable llamada **def_naturaleza**.

Mecanismo utilizado para la agresión

Esta variable tiene 25731 NA.

Se observa que el uso de armas no es solo en violencia física, también en psicológica, abandono y otras violencias sexuales.

##											
##		1	2	3	4	11	12	13	14	15	16
##	1	986	336	15077	968	60	12	14	13	6299	12
##	2	0	0	9	23	10	0	0	0	1812	0
##	3	0	0	0	0	0	0	0	0	31	0
##	4	0	0	0	0	0	0	0	0	0	0
##	5	0	0	0	0	0	0	0	0	0	0
##	6	0	0	0	0	0	0	0	0	0	0
##	7	0	0	0	0	0	0	0	0	0	0
##	10	0	0	0	0	0	0	0	0	0	0
##	12	0	0	0	0	0	0	0	0	0	0
##	14	0	0	1	0	0	0	0	0	3	0

Entonces los casos donde la violencia sea física, que se sabe si o si implica una arma y tenga NA en armas se podrían cambiar a otro mecanismo (15). Pero para los otros casos no sabemos si se uso o no un arma como para poner “No aplica”.

Se recuperarían 779 NA al hacer esta asignación.

Quemaduras

En la base de datos, las variables relacionadas con quemaduras (por ejemplo, que_cara, que_cuello, etc.) solo contienen información relevante cuando la categoría de la variable armas corresponde a “Quemaduras por fuego o llama” (12), “Quemaduras por ácido, álcalis, o sustancias corrosivas” (13) y “Quemadura con líquido hirviente” (14). Sin embargo, en los casos en que no hay quemaduras, estas variables contienen valores faltantes (NA), lo que puede generar dificultades en los análisis. Entonces, se transforman los valores NA en una categoría explícita como “No aplica”.

Información del agresor

Sexo del agresor (sexo_agre)

Esta variable toma los valores de vacíos y de “SD” en algunos registros, por lo tanto, se cambia a NA. Teniendo en cuenta que “SD” de acuerdo a los formatos de notificación significan ausencia del dato.

Edad del agresor (edad_agre)

```
## [1] 0 2 14 61 35 25 27 99 40 17 21 63 8 33 28 45 24 16 38 29 22 36 32 18 64
## [26] 58 23 31 39 30 52 34 15 10 48 19 56 20 53 49 5 60 65 46 44 37 59 26 50 42
## [51] 9 43 6 78 12 70 54 11 62 55 13 71 69 57 66 79 68 41 47 7 82 81 85 51 80
## [76] 77 76 72 67 75 73
```

Se ve que esta variable (cuya unidad de medida es años), contiene edades de 0 y 2 años para el agresor, lo cual parece ser una inconsistencia en la variable. Además se encontró que es el 91.881% de los registros que

presentan este problema y de acuerdo con las fichas de notificación de violencia disponibles, la única ficha que incluye la pregunta de la edad del agresor es en el año 2015.

Por tanto los valores de 0 y 2 podrían corresponder a valores faltantes de los años restantes de notificaciones en las que no se pregunta esto. Así, la variable tiene bastantes valores faltantes, por lo tanto es necesario eliminarla del análisis.

Nota: Hay registros que se notificaron con valor en esta variable hasta 2018.

Relación del agresor con la víctima (r_fam_vic)

```
##      3      9      10      22      23      24      25  NA's
##      1 3134 2984 13239 6005 10061 15971      2
```

Relación del agresor con la víctima: no familiar (r_nofiliar)

```
##      1      2      3      4      6      7      8      9      10      11      12      13  NA's
##     142    1521    174    271    4625    1212    2731    1743    6087    138      7     79 32667
```

Esta variable toma el valor de 9 en algunos registros, de acuerdo a las fichas encontradas con las que se notifican los casos de violencia, este código corresponde a la respuesta “Sin información” sobre la relación no familiar que existe entre la víctima y el agresor. Así, este nivel se convierte en NA.

Unión de las variables de relación con el agresor

Las variables **r_fam_vic** (relación familiar) y **r_nofiliar** (relación no familiar) contienen información relacionada con el parentesco entre la víctima y el agresor. Por lo tanto, resulta útil unificar esta información en una sola variable llamada **parentezco_agresor**, con el propósito de simplificar y organizar los datos para facilitar futuros análisis.

En la variable **r_fam_vic**, el nivel 25 (“Ninguno”) indica que no existe una relación familiar con el agresor, y tiene una cantidad bastante grande de datos, alcanza a sumar casi el total de datos que hay en la variable de relación no familiar exceptuando los NA. Entonces, es razonable asumir que el parentesco (en nivel “Ninguno”) podría corresponder a alguno de los niveles presentes en la variable **r_nofiliar**. Sin embargo, para realizar esta unificación de manera adecuada, fue necesario recodificar los niveles de ambas variables. Esto se hizo para evitar duplicados o combinaciones incorrectas, ya que algunos niveles podrían compartir nombres similares pero referirse a descripciones diferentes.

La unificación de las variables se realizó aplicando la lógica de:

- Si **r_fam_vic** tenía un valor válido distinto de “Ninguno”, se priorizó ese valor.
- Si **r_fam_vic** era “Ninguno”, se utilizó el valor correspondiente de **r_nofiliar**.
- En los casos donde ambas variables eran NA, el resultado final también se dejó como NA.

Este proceso, además permitió reducir los NAs, que en ambas variables sumaban un total de 34412, y después de la transformación se reducen a 1696 para la nueva variable. Finalmente, se eliminan las variables originales **r_fam_vic** y **r_nofiliar**.

```
##
##      Amigo(a) Compañero(a) de estudio Compañero(a) de trabajo
##      1521                                271                    174
##      Conocido(a)          Desconocido(a)          Ex_Pareja
##      2731                                3600                    6005
```

##	Familiar	Jefe	Madre
##	10061	138	2984
##	Otro	Padre	Pareja
##	4419	3134	13240
##	Profesor(a)	Sacerdote/Pastor	Servidor(a) público
##	142	7	79
##	Vecino(a)	<NA>	
##	1212	1679	

Convivencia con el agresor

Se convierte a NA los casos en que se representan la ausencia del datos con “ ”

Información de la atención/notificación

Mes de reporte caso (mes_caso)

Esta variable podría ser una variable candidata a eliminar, pues no nos arriesgamos a que existan inconsistencias entre la fecha y el mes. Además tenemos algunos (aunque pocos valores faltantes). Una mejor opción es calcularla manualmente con la variable de la fecha. Al igual que el año y la semana

Nombre del departamento de notificación (ndep_noti)

Se cambia la estructura de escritura de las categorías.

##	[1]	"ANTIOQUIA"	" "	"CALDAS"	"SUCRE"
##	[5]	"ATLANTICO"	"NORTE SANTANDER"	"QUINDIO"	"SANTANDER"
##	[9]	"ARAUCA"	"NARIÑO"	"CORDOBA"	"VALLE"
##	[13]	"META"	"CUNDINAMARCA"	"RISARALDA"	"BOYACA"

Nombre municipio de notificación (nmun_noti)

##	[1]	"MEDELLIN"	"BELLO"	"ITAGUI"
##	[4]	" "	"ENVIGADO"	"MANIZALES"
##	[7]	"SAMPUES"	"COPACABANA"	"CALDAS"
##	[10]	"BARRANQUILLA"	"CUCUTA"	"GIRARDOTA"
##	[13]	"QUIMBAYA"	"BARBOSA"	"CARMEN DE VIBORAL"
##	[16]	"LA ESTRELLA"	"ARMENIA"	"SINCELEJO"
##	[19]	"SABANETA"	"APARTADO"	"ARAUCA"
##	[22]	"CONCORDIA"	"GUARNE"	"PASTO"
##	[25]	"ARANZAZU"	"LA UNION"	"AGUADAS"
##	[28]	"HISPANIA"	"GUARANDA"	"SOLEDADE"
##	[31]	"LA CEJA"	"LA DORADA"	"BUCARAMANGA"
##	[34]	"CAREPA"	"TIERRALTA"	"RIONEGRO"
##	[37]	"CALI"	"TAMESIS"	"AMALFI"
##	[40]	"CHIGORODO"	"VILLAVICENCIO"	"CHIA"
##	[43]	"PEREIRA"	"PUERTO BOYACA"	"LA VIRGINIA"
##	[46]	"BOLIVAR"		

Atención integral en salud

Este grupo de variables corresponden a las atenciones en salud que se le realizaron a las víctimas. La atención relacionada con profilaxis para VIH, HB, otras profilaxis, anticoncepción de emergencia, orientación IVE y recolección de evidencia medico legal solo se realizan en caso de violencias sexuales. Por lo tanto, en los casos que no son violencia sexual se asigna “No aplica” a las variables que las representa.

Condición final de la víctima al momento de la notificación (con_fin_)

Según los datos esta variable toma tres posibles valores: 0 = No sabe, no responde, 1 = Vivo, 2 = Muerto. Sin embargo, el formato de notificación 2024 indica que “0” solo aplica cuando se capte el caso por BAI (Brotos, Alertas e Incidencias) y se desconoce el dato, o para defectos congénitos cuando la unidad de medida es “0”. Dado que el evento de interés no es ninguno de los mencionados, se cambia los casos con “0” por NA.

Causa básica de defunción (cbmte_)

Esta variable corresponde al diagnóstico CIE-10 (Ver) que ocasionó la muerte de la víctima y que está relacionado con el evento de interés. Toma un valor si la variable **con_fin_** es igual a 2 (muerto), en caso contrario, se le asigna “No aplica” para no confundir con valores faltantes. Además, para los valores que no son un código válido se cambian a NA.

Valores faltantes

##	Column	total_na	total_empty	percent_na	percent_empty
## 1	hora_hecho	46553	0	90.58	0
## 2	lugar_hecho	39834	0	77.50	0
## 3	estrato_	31661	0	61.60	0
## 4	armas	25731	0	50.06	0
## 5	que_cara	25731	0	50.06	0
## 6	que_cuello	25731	0	50.06	0
## 7	que_mano	25731	0	50.06	0
## 8	que_pie	25731	0	50.06	0
## 9	que_pliegu	25731	0	50.06	0
## 10	que_genita	25731	0	50.06	0
## 11	que_tronco	25731	0	50.06	0
## 12	que_miesup	25731	0	50.06	0
## 13	que_mieinf	25731	0	50.06	0
## 14	cla_gra	25731	0	50.06	0
## 15	ext_que	25731	0	50.06	0
## 16	fecha_anto_	9280	0	18.06	0
## 17	edad	7438	0	14.47	0
## 18	grupo_edad	7438	0	14.47	0
## 19	zona_conf	5731	0	11.15	0
## 20	sexo_agre	5407	0	10.52	0
## 21	nombre_comuna	5200	0	10.12	0
## 22	npais_resi	3890	0	7.57	0
## 23	ac_anticon	3289	0	6.40	0
## 24	ac_ive	3289	0	6.40	0
## 25	sp_its	3101	0	6.03	0
## 26	prof_hep_b	3101	0	6.03	0
## 27	prof_otras	3100	0	6.03	0
## 28	evi_mlegal	3086	0	6.00	0

## 29	ini_sin_	3023	0	5.88	0
## 30	parentezco_agresor	1679	0	3.27	0
## 31	gp_mad_com	1502	0	2.92	0
## 32	gp_gestan	1442	0	2.81	0
## 33	ndep_notif	939	0	1.83	0
## 34	nmun_notif	939	0	1.83	0
## 35	gp_discapa	688	0	1.34	0
## 36	gp_desplaz	686	0	1.33	0
## 37	gp_carcela	685	0	1.33	0
## 38	gp_migrant	679	0	1.32	0
## 39	gp_indigen	676	0	1.32	0
## 40	gp_pobicbf	681	0	1.32	0
## 41	gp_desmovi	679	0	1.32	0
## 42	gp_psiquia	679	0	1.32	0
## 43	gp_vic_vio	670	0	1.30	0
## 44	nmun_resi	90	0	0.18	0
## 45	ndep_resi	50	0	0.10	0
## 46	cbmte_	36	0	0.07	0
## 47	gp_otros	29	0	0.06	0
## 48	con_fin_	30	0	0.06	0
## 49	nom_grupo_	26	0	0.05	0
## 50	nmun_hecho	15	0	0.03	0
## 51	fec_con_	11	0	0.02	0
## 52	escenario	5	0	0.01	0
## 53	area_	2	0	0.00	0
## 54	per_etn_	2	0	0.00	0
## 55	conv_agre	2	0	0.00	0
## 56	nombre_barrio	0	2	0.00	0
## 57	ndep_hecho	1	0	0.00	0

Con respecto a las variables **fec_hos_** y **fec_def_**, que toman un valor solo si la víctima fue hospitalizada o falleció, 1 registros no cuentan con un valor **fec_hos_** y 7 en **fec_def_**. En el caso de **sem_ges_** son 202 registros.

De acuerdo a lo anterior, son 506124 celdas NA y 2 celdas que fueron definidas como vacías poniendo “.”.

Para un total de 51397 registros con valores faltantes y celdas vacías, lo que corresponde al 100% de la base de datos. Sin embargo, como hay columnas relacionadas, algunas celdas de una columna pueden recibir un valor a partir de otra columna.

Relacionar información para rellenar campos vacíos

Variable **npais_resi** a partir de **ndep_resi**

Variable **ndep_resi** a partir de **nmun_resi** y **npais_resi**

##	npais_resi	ndep_resi	nmun_resi
## 1	<NA>	<NA>	<NA>
## 2	<NA>	<NA>	<NA>
## 3	<NA>	<NA>	<NA>
## 4	<NA>	<NA>	<NA>
## 5	<NA>	<NA>	<NA>
## 6	<NA>	<NA>	<NA>


```
## 7      <NA>      <NA>      <NA>
## 8      España    <NA> Mun[España]
## 9      <NA>      <NA>      <NA>
## 10     <NA>      <NA>      <NA>
```

Vemos que únicamente es posible imputar el departamento de residencia para aquellas observaciones a las cuales se les conoce el país de residencia y todos resultan ser extranjeros, entonces se adapta la misma estructura Mun[País]

Variable npais_resi a partir de nmun_resi

```
##      npais_resi ndep_resi nmun_resi
## 1      <NA> Antioquia    <NA>
## 2      <NA>      <NA>    <NA>
## 3      <NA>      <NA>    <NA>
## 4      <NA> Antioquia    <NA>
## 5      <NA>      <NA>    <NA>
## 6      <NA>      <NA>    <NA>
## 7      <NA> Antioquia    <NA>
## 8      <NA>      <NA>    <NA>
## 9      <NA>      <NA>    <NA>
## 10     <NA>      <NA>    <NA>
```

Variable armas a partir de que_., cla_gra y ext_que No se puede porque no hay registros vacíos en armas que tenga algún valor en que_

Se puede observar que disminuyó la cantidad de celdas vacías.

```
##      Column total_na total_empty percent_na percent_empty
## 1      hora_hecho 46553      0      90.58      0
## 2      lugar_hecho 39834      0      77.50      0
## 3      estrato_    31661      0      61.60      0
## 4      armas      25731      0      50.06      0
## 5      que_cara    25731      0      50.06      0
## 6      que_cuello  25731      0      50.06      0
## 7      que_mano    25731      0      50.06      0
## 8      que_pie     25731      0      50.06      0
## 9      que_pliegu  25731      0      50.06      0
## 10     que_genita  25731      0      50.06      0
## 11     que_tronco  25731      0      50.06      0
## 12     que_miesup  25731      0      50.06      0
## 13     que_mieinf  25731      0      50.06      0
## 14     cla_gra     25731      0      50.06      0
## 15     ext_que     25731      0      50.06      0
## 16     fecha_ento_ 9280      0      18.06      0
## 17     edad        7438      0      14.47      0
## 18     grupo_edad  7438      0      14.47      0
## 19     zona_conf   5731      0      11.15      0
## 20     sexo_agre   5407      0      10.52      0
## 21     nombre_comuna 5200      0      10.12      0
## 22     ac_anticon  3289      0      6.40      0
## 23     ac_ive      3289      0      6.40      0
## 24     sp_its      3101      0      6.03      0
```

## 25	prof_hep_b	3101	0	6.03	0
## 26	prof_otras	3100	0	6.03	0
## 27	evi_mlegal	3086	0	6.00	0
## 28	ini_sin_	3023	0	5.88	0
## 29	parentezco_agresor	1679	0	3.27	0
## 30	gp_mad_com	1502	0	2.92	0
## 31	gp_gestan	1442	0	2.81	0
## 32	ndep_notif	939	0	1.83	0
## 33	nmun_notif	939	0	1.83	0
## 34	gp_discapa	688	0	1.34	0
## 35	gp_desplaz	686	0	1.33	0
## 36	gp_carcela	685	0	1.33	0
## 37	gp_migrant	679	0	1.32	0
## 38	gp_indigen	676	0	1.32	0
## 39	gp_pobicbf	681	0	1.32	0
## 40	gp_desmovi	679	0	1.32	0
## 41	gp_psiquia	679	0	1.32	0
## 42	gp_vic_vio	670	0	1.30	0
## 43	ndep_resi	90	0	0.18	0
## 44	nmun_resi	90	0	0.18	0
## 45	npais_resi	45	0	0.09	0
## 46	cbmte_	36	0	0.07	0
## 47	gp_otros	29	0	0.06	0
## 48	con_fin_	30	0	0.06	0
## 49	nom_grupo_	26	0	0.05	0
## 50	nmun_hecho	15	0	0.03	0
## 51	fec_con_	11	0	0.02	0
## 52	escenario	5	0	0.01	0
## 53	area_	2	0	0.00	0
## 54	per_etn_	2	0	0.00	0
## 55	conv_agre	2	0	0.00	0
## 56	nombre_barrio	0	2	0.00	0
## 57	ndep_hecho	1	0	0.00	0

Luego de rellenar las celdas vacías a partir de información relacionada queda un total de 51397 registros con celdas vacías, lo que corresponde al 100% de la base de datos. Es decir, se pueden utilizar 0 registros completos.

Ahora, algunas variables tienen más del 50% de los registros con celdas vacías, ya sea porque no se registró la información o porque esa variable no es considerada en todas las fichas de notificación del SIVIGILA. Como es el caso de **edad agresor**, **estrato_**, y **hora del hecho** que según lo investigado no se piden en fichas recientes.

Las variables son:

```
## [1] "hora_hecho" "lugar_hecho" "estrato_" "armas" "que_cara"
## [6] "que_cuello" "que_mano" "que_pie" "que_pliegu" "que_genita"
## [11] "que_tronco" "que_miesup" "que_mieinf" "cla_gra" "ext_que"
```

Al eliminar estas variables, se obtiene una base de datos con **49717 registros**.

Registros duplicados

```
## [1] 359
```

Finalmente, al eliminar los registros duplicados se obtiene una base de datos depurada con **49358 registros**, y las siguientes variables:

## [1]	"fec_not"	"sexo_"	"area_"
## [4]	"tip_ss_"	"per_etn_"	"nom_grupo_"
## [7]	"gp_discapa"	"gp_desplaz"	"gp_migrant"
## [10]	"gp_carcela"	"gp_gestan"	"sem_ges_"
## [13]	"gp_indigen"	"gp_pobicbf"	"gp_mad_com"
## [16]	"gp_desmovi"	"gp_psiquia"	"gp_vic_vio"
## [19]	"gp_otros"	"fec_con_"	"ini_sin_"
## [22]	"pac_hos_"	"fec_hos_"	"con_fin_"
## [25]	"fec_def_"	"fecha_nto_"	"cbmte_"
## [28]	"actividad"	"orient_sex"	"consum_spa"
## [31]	"mujer_cabf"	"antec"	"sust_vict"
## [34]	"sexo_agre"	"conv_agre"	"zona_conf"
## [37]	"fec_hecho"	"escenario"	"ambito_lug"
## [40]	"sp_its"	"prof_hep_b"	"prof_otras"
## [43]	"ac_anticon"	"ac_ive"	"ac_mental"
## [46]	"remit_prot"	"inf_aut"	"evi_mlegal"
## [49]	"npais_resi"	"ndep_resi"	"nmun_resi"
## [52]	"ndep_notif"	"nmun_notif"	"nombre_barrio"
## [55]	"nombre_comuna"	"edad"	"grupo_edad"
## [58]	"ndep_hecho"	"nmun_hecho"	"def_naturaleza"
## [61]	"parentezco_agresor"	"semana_hecho"	"mes_hecho"
## [64]	"año_hecho"		

Importante: Si se seleccionan las filas con registros totalmente completos se tiene una base de datos con **24406 filas**.

Conversión a factor

A excepción de edad, semana del hecho, y fechas.

Orden de las columnas

Se establece un nuevo orden en la base de datos para mayor facilidad en el proceso de análisis.

Base de datos depurada

```
## Archivo guardado exitosamente en:  
## C:/Users/sofia/Desktop/Proyecto-Orquideas/data/interim/medata_1900_2022_debugged.csv
```