

Depuración información del portal de datos públicos de Medellín
(MEData).

2024-11-13

Contents

Información de la base de datos	2
Lectura de la base de datos	2
Depuración de la base de datos	2
Filtros	2
Clasificación del caso	3
Nacionalidad	4
Datos epidemiológicos	4
Fechas	5
Información de la víctima	6
Información del hecho	18
Información del agresor	23
Información de la atención/notificación	26
Valores faltantes	27
Registros duplicados	36
Conversión a factor	37
Orden de las columnas	37
Base de datos depurada	37
Resumen	37

Información de la base de datos

La base de datos, titulada *Vigilancia Integrada de la Violencia de Género*, está alojada en el portal MEData (Ver). Este recurso recopila información sobre los casos sospechosos de violencia de género que fueron reportados al SIVIGILA.

- **Última actualización:** 20 de septiembre de 2023.
- **Información sobre las variables:** Adicional al diccionario que aparece en MEData, el formato de notificación al SIVIGILA contiene indicaciones sobre muchas de las variables (Ver).

Lectura de la base de datos

Depuración de la base de datos

La base de datos está conformada por 118 variables, sin embargo, se elimina las siguientes variables por no ser de relevancia para el análisis:

1. Nombre de la Unidad Primaria Generadora de Datos(**nom_upgd**)
2. Código y nombre del evento (**cod_eve - nom_eve**)
3. Código asignado en el SGSSS a los prestadores de servicios de salud que se hayan registrado en el 'Registro Especial de Prestadores de Servicios de Salud' (**cod_pre**)
4. Código asignado en el SGSSS a los prestadores de servicios de salud que indica sede ó territorio (**cod_sub**)
5. Código Administradora responsable de la atención del paciente, asignado por MSP (**cod_ase**)
6. Número del certificado defunción (**cer_def__**)
7. Fecha efectiva de digitación del registro o realizar un ajuste a un registro previo (**fec_aju__**)
8. Número de registros (**nreg**) - Estado de transformación de la notificación (**estadotran**)
9. Fuerza (**fm_fuerza**) - Código de la Unidad Militar según tabla de Unidades Militares (**fm_unidad**)
10. Código de la Grado Militar según tabla de Grados Militares (**fm_grado**)
11. Contexto de la notificación, sus categorías son: notificación rutinaria, búsqueda, activa Institucional, vigilancia intensificada, búsqueda activa Comunitaria, investigaciones (**Fuente**)

Filtros

Dado que el interés son los casos de violencia en mujeres que ocurren en Colombia se filtra la base para analizar solo estos casos. Según el formato de notificación 2024 cuando la variable **identidad de género** (**ident_gene**) es igual a 2 corresponde a mujer y cuando es igual a 4 corresponde a mujer trans. Mientras que la variable **país de ocurrencia del caso** (**cod_pais_o**) igual a 170 representa a Colombia.

```
data <- data %>% filter((ident_gene == 2 | ident_gene == 4) & cod_pais_o == 170)
```

Se obtiene un total de 55556 registros, descartando 26467.

Luego, se encuentran casos que no fueron notificados en Medellín, como era de esperarse dado lo indicado en el diccionario de la base y que la fuente corresponde al portal de datos de Medellín

##	AGUADAS	AMALFI	APARTADO	ARANZAZU
##	1	1	1	1
##	ARAUCA	ARMENIA	BARBOSA	BARRANQUILLA
##	2	2	1	1
##	BELLO	BOLIVAR	BUCARAMANGA	CALDAS
##	163	1	1	6
##	CALI	CAREPA	CARMEN DE VIBORAL	CHIA
##	2	2	2	1
##	CHIGORODO	CONCORDIA	COPACABANA	CUCUTA
##	1	1	4	4
##	ENVIGADO	FLORIDABLANCA	GIRARDOTA	GUARANDA
##	73	1	7	1
##	GUARNE	HISPANIA	ITAGUI	LA CEJA
##	1	1	211	1
##	LA DORADA	LA ESTRELLA	LA UNION	LA VIRGINIA
##	1	4	1	1
##	MANIZALES	MEDELLIN	PASTO	PEREIRA
##	3	54023	2	1
##	PUERTO BOYACA	QUIMBAYA	RIONEGRO	SABANETA
##	1	1	4	18
##	SAMPUES	SINCELEJO	SOLEDAD	TAMESIS
##	1	2	2	1
##	TIERRALTA	VILLAVICENCIO	NA's	
##	1	2	993	

Se decide entonces filtrar los casos donde la notificación se hizo en Medellín

```
data <- data %>% filter(nmun_notif == "MEDELLIN")
```

Se obtiene un total de 54023 registros, descartando 1533.

Nota 1: Una vez filtrados los casos que se notificaron en Medellín, se elimina las variables **nmun_notif** y **ndep_notif**

Clasificación del caso

La variable clasificación inicial del caso (**tip_cas_**) puede tomar los siguientes valores: 1 = Sospechoso, 2 = Probable, 3 = Confirmado por Laboratorio, 4 = Confirmado por Clínica, 5 = Confirmado por Nexo Epidemiológico.

```
##      1
## 54023
```

Todos los casos son sospechosos. Sin embargo, las variables seguimiento y clasificación final del caso (**ajuste_**) indica que la clasificación de algunos casos cambiaron.

```
##      0      7  NA's
## 49264 4748    11
```

El valor de **7** indica que se modificó algún campo de la ficha, los únicos que no se pueden modificar son código de evento, Upgd, numero de id, fecha de notificación.

Luego, la variable clasificación final (**clasificación_final**) indica que 5 de los registros sospechosos terminaron siendo probables.

```
##      1      2
## 54018      5
```

Dado que estas variables nos indican que la mayoría de casos no cambian de estado y los que sí, cambian a un estado similar, se decide eliminarlas.

Nacionalidad

Se cuenta con el código (**nacionali__**) y nombre de la nacionalidad (**nombre__nacionalidad**), que corresponde al estado o nación que pertenece la víctima según su documento de identificación.

```
##      Anguila      Antillas Neerlandesas      Bangladesh
##      1          1          3
##      Bélgica      Bosnia Y Herzegovina      Brasil
##      1          7          1
##      Camerún      Canadá      Colombia
##      1          1      33559
##      Comoras      Costa Rica      Croacia
##      7          1          1
##      Cuba      Ecuador      España
##      1          2          3
## Estados Unidos De América      Federación De Rusia      Francia
##      8          1          1
##      Isla De Navidad      Madagascar      Malta
##      1          1          1
##      México      Montserrat      Myanmar
##      5          1          1
##      Países Bajos      Panamá      Perú
##      1          1          2
##      Reino Unido      República Centroafricana      República Dominicana
##      1          2          1
##      Sudáfrica      Surinam      Uruguay
##      1          1          1
##      Venezuela      NA's
##      868      19534
```

Sin embargo, en la última variable el 36.159% de los casos son NA. Dado que es un porcentaje alto y no hay manera de relacionar con **nacionali__** porque tienen la misma cantidad de NA, se decide eliminar ambas variables.

Datos epidemiológicos

La variable **año** corresponde al año asociado a la semana epidemiológica.

```
## 2016 2017 2018 2019 2020 2021 2022
##      2 4034 9799 11273 8026 9437 11452
```

La variable **semana** corresponde a la semana epidemiológica.

```
##      1      2      3      4      5      6      7      8      9     10     11     12     13     14     15     16
## 1648  739  900  935 1000 1063 1072 1072 1131 1015 1135 1037  787 1130  905  893
```

```
##   17   18   19   20   21   22   23   24   25   26   27   28   29   30   31   32
## 1008 1072 1159 1140 1118 1069  994 1093 1078 1027 1071 1092 1027 1072 1064 1009
##   33   34   35   36   37   38   39   40   41   42   43   44   45   46   47   48
## 1020  972 1113 1075 1117 1103 1036 1104  955  869  923 1009 1066 1010 1036 1037
##   49   50   51   52   53
##  989 1016  959  953  106
```

El **periodo** corresponde a cada 4 semanas completas del calendario epidemiológico. Son 13 periodos al año. Sin embargo, esta variable está tomando el valor de 16 en 842 registros

```
##    1    2    3    4    5    6    7    8    9   10   11   12   13   16
## 4222 4207 4318 2873 4379 4274 4268 4172 4180 4360 3756 4149 4023  842
```

Esos registros corresponden al año 2022. Analizando con el calendario de este año, no existe periodo 16 y el periodo para esas semanas es el periodo número 4.

Estas variables según definición no deben coincidir con el año, semana, periodo calendario. Sin embargo, dado que no necesariamente corresponden al momento en que se dio el evento, sino que puede ser el momento de notificación, se decide descartas. Teniendo también en cuenta que ya se cuenta con la fecha exacta en que sucedió el hecho para extraer la información que se necesite.

Fechas

Se cuenta con las siguientes fechas:

- **Fecha de notificación (fec_not):** fecha en la que se está informando el evento al siguiente nivel por cualquier mecanismo, en especial para los eventos de notificación inmediata.
- **Consulta (fec_con):** fecha en la que consultó el paciente.
- **Inicio de síntomas (ini_sin):** fecha del primer día en que el paciente inició síntomas.
- **Hospitalización (fec_hos):** fecha en la que el paciente fue hospitalizado como consecuencia del evento.
- **Defunción (fec_def):** fecha en la que el paciente fallece como consecuencia del evento.
- **Nacimiento (fecha_anto):**
- **Hecho (fec_hecho):** fecha en que ocurrió el hecho o evento

El formato inicial es dd/mm/yyyy pero al convertir a objeto Date se cambia al formato por defecto: yyyy-mm-dd.

Inconsistencias

Se encontró que algunos registros parecen tomar fechas genéricas en la fecha de nacimiento (**fecha_anto**) y en la fecha del hecho (**fec_hecho**). Por ejemplo:

```
## # A tibble: 5 x 3
##   fecha_anto_ fec_hecho  fec_not
##   <date>      <date>    <date>
## 1 1957-01-01 2018-09-24 2018-09-26
## 2 1983-01-01 2018-09-24 2018-09-26
```

```
## 3 2012-01-01 2018-09-26 2018-09-26
## 4 2005-01-18 2018-01-01 2018-09-26
## 5 2016-01-01 2018-09-26 2018-09-26
```

Teniendo en cuenta lo anterior y que las demás fechas también presentan inconsistencias, se decide quedarse solo con la **fecha de notificación**

Nota: no se eliminan aún para analizar la edad de la víctima

Información de la víctima

Edad de la víctima (edad_,uni_med_,grupo_edad_ciclo,grupo_edad_quinque)

La edad de la víctima se registra en diferentes medidas (**uni_med**): años(1), meses(2), días(3), horas(4), minutos(5). Existen algunos casos donde la unidad de medida es 0, sin embargo, de acuerdo a la ficha de notificación 2024: “La unidad de medida 0=‘no aplica’, **solo puede ser utilizada para el evento 215 defectos congénitos**, cuando el diagnóstico se realiza prenatal”. Por lo tanto, se decide eliminar estos registros.

```
## # A tibble: 8 x 7
##   edad_ uni_med_ grupo_edad_ciclo grupo_edad_quinque fecha_nto_ fec_hecho
##   <dbl>   <dbl> <chr>                <chr>          <date>    <date>
## 1     0     0 0-5                0-4          2018-01-01 2018-05-30
## 2     0     0 0-5                0-4          2018-01-01 2018-03-09
## 3     0     0 0-5                0-4          2018-01-01 2018-03-15
## 4     0     0 0-5                0-4          2018-01-01 2018-05-15
## 5     0     0 0-5                0-4          2018-01-01 2018-03-15
## 6     0     0 0-5                0-4          2018-01-01 2018-01-18
## 7     0     0 0-5                0-4          2018-01-01 2018-02-21
## 8     0     0 0-5                0-4          2018-01-01 2018-05-23
## # i 1 more variable: fec_not <date>
```

```
data <- data %>% filter(uni_med_ != 0)
```

Se eliminan 8 registros, quedando una base de datos de 54015. También se encuentra que para algunos registros la unidad de medida son incorrectas.

Las variables **edad_hecho** y **edad_notif** se calcularon como la diferencia en tiempo entre la fecha de nacimiento y la fecha del hecho y notificación, respectivamente, según la unidad de medida. Luego, si se compara la edad original con las edades calculadas la diferencia es evidente, demostrando que la unidad de medida es incorrecta.

```
## # A tibble: 5 x 7
##   uni_med_ edad_ edad_hecho edad_notif fecha_nto_ fec_hecho fec_not
##   <dbl> <dbl>   <dbl>   <dbl> <date>    <date>    <date>
## 1     5     6   3172320   3548160 2012-01-22 2018-02-02 2018-10-21
## 2     5     1    879840    881280 2016-08-01 2018-04-04 2018-04-05
## 3     4     6    55176    60336 2011-09-16 2018-01-01 2018-08-04
## 4     4     9     6744     6768 2017-10-09 2018-07-17 2018-07-18
## 5     3     2      992     1083 2016-02-12 2018-10-31 2019-01-30
```

Dado que son pocos registros se decide eliminarlos.

Se eliminan 5 registros, quedando una base de datos de 54010. Además, para un mejor manejo se pasa la edad a años.

Edad agrupada (grupo_edad_quinque - grupo_edad_ciclo)

Se comprobó que estas variables tienen los cálculos erróneos para algunas filas, pues, al realizar el cálculo de forma manual de la edad desde la fecha de nacimiento hasta la fecha del hecho (o notificación), en ninguno de los dos casos, corresponde al grupo que se le asigna en cada una de estas variables.

Los niveles de estas variables (grupo_edad_quinque y grupo_edad_ciclo) son:

##	0-4	10-14	15-19	20-24	25-29	30-34	35-39	40-44
##	4070	7916	5268	6069	6324	5063	3781	2686
##	45-49	5-9	50-54	55-59	60-64	65-69	70-74	75-79
##	1994	4404	1831	1522	1080	724	504	323
##	80 y más							
##	451							
##	0-5	12-17	18-28	29-59	6-11	60 y más		
##	4987	9346	12968	18060	5567	3082		

En la primera agrupación los rangos son de 4 edades mientras que en el último no son de igual longitud.

En los boletines del INMLCF se presentan los análisis con la edad agrupada también en rango de 4 edades a excepción de la edad 15-19 que se divide en dos rangos. (*Ejemplo*). Teniendo en cuenta esto, y que se pasaron las edades a años, se decide agrupar la edad de igual manera que lo hace el INMLCF.

```
data <- data %>% mutate(  
  grupo_edad = case_when(  
    edad >= 0 & edad <= 4 ~ "0-4",  
    edad >= 5 & edad <= 9 ~ "5-9",  
    edad >= 10 & edad <= 14 ~ "10-14",  
    edad >= 15 & edad <= 17 ~ "15-17",  
    edad >= 18 & edad <= 19 ~ "18-19",  
    edad >= 20 & edad <= 24 ~ "20-24",  
    edad >= 25 & edad <= 29 ~ "25-29",  
    edad >= 30 & edad <= 34 ~ "30-34",  
    edad >= 35 & edad <= 39 ~ "35-39",  
    edad >= 40 & edad <= 44 ~ "40-44",  
    edad >= 45 & edad <= 49 ~ "45-49",  
    edad >= 50 & edad <= 54 ~ "50-54",  
    edad >= 55 & edad <= 59 ~ "55-59",  
    edad >= 60 & edad <= 64 ~ "60-64",  
    edad >= 65 & edad <= 69 ~ "65-69",  
    edad >= 70 & edad <= 74 ~ "70-74",  
    edad >= 75 & edad <= 79 ~ "75-79",  
    edad >= 80 ~ "80 y más",  
    TRUE ~ NA_character_  
  )  
)
```

Fecha de notificación

Se eliminan las columnas de fechas a excepción de fecha de notificación y se crea una nueva variable solo con el año de notificación llamada **año_not**

País de residencia

Se cuenta con el código y el nombre del país donde reside la víctima. El código corresponde a la norma ISO 3166-1 numérico *Ver*

##													
##		BANGLADESH	COLOMBIA	ESLOVENIA	ESPAÑA	ESTADOS UNIDOS	DE AMÉRICA	MONTSERRAT					
##	50	4	0	0	0			0		0			
##	170	0	49892	0	0			0		0			
##	500	0	0	0	0			0		1			
##	591	0	0	0	0			0		0			
##	705	0	0	1	0			0		0			
##	724	0	0	0	1			0		0			
##	840	0	0	0	0			1		0			
##													
##		PANAMÁ											
##	50	0											
##	170	0											
##	500	0											
##	591	1											
##	705	0											
##	724	0											
##	840	0											

Se verificó que los códigos son correctos y están bien relacionados con su respectivo nombre. Solo se cambia la escritura de algunos nombres

Departamento de residencia

ndep_resi representa el nombre del departamento. Esta variable presentaba los siguientes problemas:

- Niveles como “ ” o DEPTO DESCONOCIDO”. Fueron cambiados a NA
- Algunos niveles que representaban entidades por fuera de Colombia, como “COJEDES” (Venezuela) y “PANAMÁ” (Panamá). Fueron cambiados a “Depto[País]”
- En algunos nombres ausencia de tildes y nombres incompletos
- Niveles que correspondían a ciudades específicas, como “CARTAGENA” y “BARRANQUILLA”. Fueron reemplazados por el nombre del departamento al que pertenecen.

Luego, **cod_dpto_r** representa el código Divipola de cada departamento presente en la base

##	01	05	08	11	13	14	15	17	25	27	41	44	48
##	42	53939	2	6	1	1	1	1	1	1	3	1	1
##	50	68	70	76	AY	NA's							
##	2	3	1	2	1	1							

Ese par de niveles que son letras se cambian a NA, teniendo en cuenta que es una cantidad mínima de registros. Además, en los casos de departamentos fuera de Colombia se cambia **cod_dpto_r** a 0 para indicar que no aplica

Ahora, se verifica la concordancia de los códigos y nombres con ayuda de la codificación Divipola.

1. Al analizar que códigos no están en la lista, se encontraron los siguientes:

```
## # A tibble: 10 x 3
##   cod_dpto_r ndep_resi cantidad
##   <chr>      <chr>      <int>
## 1 0          Depto[Bangladés] 4
## 2 0          Depto[Eslovenia] 1
## 3 0          Depto[España] 1
## 4 0          Depto[Estados Unidos] 1
## 5 0          Depto[Montserrat] 1
## 6 01         <NA> 34
## 7 14         Bolívar 1
## 8 48         Magdalena 1
## 9 <NA>       Depto[Panamá] 1
## 10 <NA>      <NA> 1
```

En los casos de departamentos fuera de Colombia se cambia **cod_dpto_r** a 0 para indicar que no aplica. Cuando el código es 01 y departamento NA, se cambia a NA en código. Y en los demás casos se verificó que esos códigos efectivamente no corresponden a los códigos de esos departamentos. Se cambia a los códigos correctos

2. Los departamentos que no se encuentran en la lista son:

```
## # A tibble: 8 x 3
##   cod_dpto_r ndep_resi cantidad
##   <chr>      <chr>      <int>
## 1 0          Depto[Bangladés] 4
## 2 0          Depto[Eslovenia] 1
## 3 0          Depto[España] 1
## 4 0          Depto[Estados Unidos] 1
## 5 0          Depto[Montserrat] 1
## 6 0          Depto[Panamá] 1
## 7 05         <NA> 11
## 8 <NA>       <NA> 35
```

Se observa que los nombres que no están en la lista son los correspondientes a departamentos de otros países y NA. Los únicos casos que se pueden cambiar son los casos en que el código es 05 (Antioquia) y el departamento NA

3. Los casos donde hay discordancia entre el código y el nombre del departamento son:

```
## # A tibble: 0 x 3
## # i 3 variables: cod_dpto_r <chr>, ndep_resi <chr>, cantidad <int>
```

No hay discordancias.

Municipio de residencia

nmun_resi representa el nombre del municipio. Esta variable presentaba inconsistencias en los nombres de los municipios. Se reemplazaron los niveles que no tenían un nombre específico de municipio o que eran desconocidos por NA, así como aquellos que correspondían a países fuera de Colombia se cambiaron a Mun[País]

También se cuenta con la columna **cod_mun_r**, que representa el código Divipola (últimos tres dígitos) de cada municipio presente en la base.

```
## [1] "001" "088" "042" "138" "266" "002" "670" "000" "170" "360" "607" "380"
## [13] "129" "631" "078" "724" "418" "347" "501" "079" "021" "690" "887" "212"
## [25] "206" "318" "819" "045" "081" "697" "197" "440" "705" "615" "034" "104"
## [37] "840" "150" "572" "500" NA      "050" "148" "376" "845" "240" "030" "308"
## [49] "036" "761" "004" "134"
```

Ahora, se verifica la concordancia de los códigos y nombres con ayuda de la codificación Divipola:

1. Al analizar que códigos no están en la lista, se encontraron los siguientes:

```
## # A tibble: 12 x 5
##   cod_mun_r nmun_resi      cod_dpto_r ndep_resi      cantidad
##   <chr>      <chr>      <chr>      <chr>      <int>
## 1 000      <NA>      05      Antioquia      31
## 2 000      <NA>      17      Caldas         1
## 3 000      <NA>      44      La Guajira     1
## 4 000      <NA>      <NA>      <NA>         1
## 5 004      Mun[Panamá]    0      Depto[Panamá]  1
## 6 050      Mun[Bangladés]  0      Depto[Bangladés] 4
## 7 170      <NA>      <NA>      <NA>        33
## 8 500      Mun[Montserrat] 0      Depto[Montserrat] 1
## 9 705      Mun[Eslovenia]  0      Depto[Eslovenia]  1
## 10 724      Mun[España]     0      Depto[España]     1
## 11 840      Mun[Estados Unidos] 0      Depto[Estados Unidos] 1
## 12 <NA>      <NA>      <NA>      <NA>         1
```

En los casos de municipios fuera de Colombia se cambia **cod_mun_r** a 0 para indicar que no aplica y cuando el código es “000” a NA, ya que no hay códigos existentes para esa combinación. También en el caso de “170” porque no hay información suficiente para determinar el municipio

Nota: Una vez verificados los códigos, se transforma esta variable para que tome como valor el código completo (5 dígitos)

2. Los municipios que no se encuentran en la lista son:

```
## # A tibble: 7 x 2
##   nmun_resi      cantidad
##   <chr>      <int>
## 1 Mun[Bangladés]      4
## 2 Mun[Eslovenia]     1
## 3 Mun[España]        1
## 4 Mun[Estados Unidos] 1
## 5 Mun[Montserrat]    1
## 6 Mun[Panamá]        1
## 7 <NA>             102
```

Se observa que los nombres que no están en la lista son los correspondientes a Municipios de otros países y NA. Los últimos casos se tratan en la sección de valores faltantes

3. Los casos donde hay discordancia entre el código y el nombre del municipio son:

```
## # A tibble: 0 x 3
## # i 3 variables: cod_mun_r <chr>, nmun_resi <chr>, cantidad <int>
```

No hay discordancias.

Comuna de residencia

En la ficha de notificación no se encuentra campo para ingresar comuna y barrio de residencia pero sí se solicita la dirección, lo que puede suponer que estas columnas fueron creadas para la publicación de la base en el portal MEData. En este caso, se cuenta con el código y el nombre de la comuna.

```
## [1] "01" "07" "90" "15" "04" "99" "60" "16" "09" "05" "03" "06" "02" "08" "12"
## [16] "11" "80" "13" "10" "14" "70" "50"
```

```
## [1] "01 Popular"
## [2] "07 Robledo"
## [3] "90 Corregimiento de Santa Elena"
## [4] "15 Guayabal"
## [5] "04 Aranjuez"
## [6] "Sin información"
## [7] "60 Corregimiento de San Cristobal"
## [8] "16 Belén"
## [9] "09 Buenos Aires"
## [10] "05 Castilla"
## [11] "03 Manrique"
## [12] "06 Doce De Octubre"
## [13] "02 Santa Cruz"
## [14] "08 Villa Hermosa"
## [15] "12 La America"
## [16] "11 Laureles"
## [17] "80 Corregimiento de San Antonio de Prado"
## [18] "13 San Javier"
## [19] "10 La Candelaria"
## [20] "14 El Poblado"
## [21] "70 Corregimiento de Altavista"
## [22] "50 Corregimiento de Palmitas"
```

Se observa que en el nombre de la comuna también se especifica el código, se comprueba que en todos los casos ese código coincida con el que aparece en **codigo_comuna**

```
## # A tibble: 1 x 3
##   codigo_comuna nombre_comuna cantidad
##   <chr>          <chr>          <int>
## 1 99            Sin información    5269
```

Los únicos casos donde no hay coincidencia es cuando no hay información. Por lo tanto, se cambia este código y nombre a NA, además, se elimina el código del nombre.

```
## [1] "Popular"
## [2] "Robledo"
## [3] "Corregimiento de Santa Elena"
```

```
## [4] "Guayabal"
## [5] "Aranjuez"
## [6] NA
## [7] "Corregimiento de San Cristobal"
## [8] "Belén"
## [9] "Buenos Aires"
## [10] "Castilla"
## [11] "Manrique"
## [12] "Doce De Octubre"
## [13] "Santa Cruz"
## [14] "Villa Hermosa"
## [15] "La America"
## [16] "Laureles"
## [17] "Corregimiento de San Antonio de Prado"
## [18] "San Javier"
## [19] "La Candelaria"
## [20] "El Poblado"
## [21] "Corregimiento de Altavista"
## [22] "Corregimiento de Palmitas"
```

Ahora, todos los nombres corresponden a comunas de Medellín, sin embargo, se encontraron casos donde la víctima reside en otros municipios de Colombia. Por ejemplo:

```
## # A tibble: 5 x 5
##   cod_mun_r nmun_resi      codigo_comuna nombre_comuna cantidad
##   <chr>      <chr>      <chr>          <chr>          <int>
## 1 05002    Abejorral      08            Villa Hermosa      1
## 2 05042    <NA>             13            San Javier        2
## 3 05615    Rionegro          11            Laureles          1
## 4 05036    Angelópolis       14            El Poblado        1
## 5 05148    El Carmen De Viboral 14            El Poblado        2
```

Esta situación de inconsistencia entre el municipio y la comuna no es extraña bajo el contexto del problema, ya que el experto de metroSalud explicó que cuando no se especifica información como la dirección de residencia en la ficha, se pone en la plataforma de SIVIGILA información sobre el lugar de notificación. Entonces estas inconsistencias puede deberse en que se puso en SIVIGILA la dirección del lugar de notificación en Medellín y al crear las variables comuna y barrio claramente serían de Medellín.

Para tratar de garantizar un poco la calidad de la información, se decide cambiar a NA el valor de comuna para estos casos y quedarse entonces con la información que brinda el municipio y departamento. Además, se pone NA y 0 en nombre y código, respectivamente, para los casos donde la residencia sea en el exterior

Ahora, se verifica que haya concordancia entre el código y el nombre de la comuna. El recurso utilizado para la verificación proviene del portal *GeoMedellín*

```
## Reading layer 'comunas_y_corregimientos_' from data source
## 'C:\Users\sofia\Desktop\Proyecto-Orquideas\data\auxiliary\comunas_corregimientos_Medellin'
## using driver 'ESRI Shapefile'
## Simple feature collection with 23 features and 8 fields
## Geometry type: MULTIPOLYGON
## Dimension: XY
## Bounding box: xmin: 4699257 ymin: 2239727 xmax: 4726591 ymax: 2263174
## Projected CRS: MAGNA-SIRGAS 2018 / Origen-Nacional
```

1. Al analizar que códigos no están en la lista, se encontraron los siguientes:

```
## # A tibble: 7 x 3
##   codigo_comuna nombre_comuna      cantidad
##   <chr>          <chr>          <int>
## 1 0            Exterior[Bangladés]      4
## 2 0            Exterior[Eslovenia]      1
## 3 0            Exterior[España]        1
## 4 0            Exterior[Estados Unidos]  1
## 5 0            Exterior[Montserrat]     1
## 6 0            Exterior[Panamá]        1
## 7 <NA>         <NA>          5356
```

2. Las comunas que no se encuentran en la lista son:

```
## # A tibble: 10 x 3
##   codigo_comuna nombre_comuna      Cantidad
##   <chr>          <chr>          <int>
## 1 0            Exterior[Bangladés]      4
## 2 0            Exterior[Eslovenia]      1
## 3 0            Exterior[España]        1
## 4 0            Exterior[Estados Unidos]  1
## 5 0            Exterior[Montserrat]     1
## 6 0            Exterior[Panamá]        1
## 7 11           Laureles             1159
## 8 12           La America            1095
## 9 50           Corregimiento de Palmitas    33
## 10 60          Corregimiento de San Cristobal 2318
```

Las inconsistencias corresponden a escritura, por ende, solo se cambia a como aparece en la base auxiliar

3. Los casos donde hay discordancia entre el código y el nombre del municipio son:

```
## # A tibble: 0 x 3
## # i 3 variables: codigo_comuna <chr>, nombre_comuna <chr>, cantidad <int>
```

No hay inconsistencias entre el código y el nombre.

Barrio de residencia

En la ficha de notificación no se encuentra campo para ingresar comuna y barrio de residencia pero si se solicita la dirección, lo que puede suponer que estas columnas fueron creadas para la publicación de la base en el portal MEData. En este caso, se cuenta con el código y el nombre del barrio o vereda. Para comenzar se cambian los indicativos de falta de información por NA y se unifica escritura en el variable **nombre_barrio**.

Luego, se encontró que en algunos casos el barrio no tiene coherencia con el municipio de residencia. Por ejemplo:

```
## # A tibble: 5 x 5
##   cod_mun_r nmun_resi      codigo_barrio nombre_barrio      n
##   <chr>      <chr>      <chr>          <chr>          <int>
## 1 05266     Envigado      1014          Las Palmas        1
## 2 05148     El Carmen De Viboral 0911          Gerona            1
## 3 50150     Castilla La Nueva  1107          Bolivariana       1
## 4 05042     <NA>           0112          Carpinelo         1
## 5 05030     Amagá          1019          La Candelaria     1
```

Para tratar de garantizar un poco la calidad de la información, se decide cambiar a NA el valor de barrio para estos casos y quedarse entonces con la información que brinda el municipio y departamento. Además, se pone NA y 0 en nombre y código, respectivamente, para los casos donde la residencia sea en el exterior

Después, se verifica que haya concordancia entre el código y el nombre del barrio. El recurso utilizado para la verificación proviene del portal *GeoMedellín*.

Nota: Se selecciona este recurso en vez de un recurso que indica barrios y veredas a nivel nacional, porque se comprobó que esta variable tendrá solo barrios de Medellín como sucede con la variable de comuna

```
## Reading layer 'barrios_y_veredas_mr' from data source
## 'C:\Users\sofia\Desktop\Proyecto-Orquideas\data\auxiliary\barrios_veredas_Medellin'
## using driver 'ESRI Shapefile'
## Simple feature collection with 332 features and 9 fields
## Geometry type: MULTIPOLYGON
## Dimension: XY
## Bounding box: xmin: 4699257 ymin: 2239727 xmax: 4726591 ymax: 2263174
## Projected CRS: MAGNA-SIRGAS 2018 / Origen-Nacional
```

1. Al analizar que códigos no están en la lista, se encontraron por ejemplo:

```
## # A tibble: 5 x 4
##   nmun_resi codigo_barrio nombre_barrio cantidad
##   <chr>      <chr>      <chr>      <int>
## 1 Medellín  0506      Plaza de Ferias      7
## 2 Medellín  1501      El Rodeo             14
## 3 Medellín  0417      Parque Norte        7
## 4 Medellín  1009      La Alpujarra        33
## 5 Medellín  0416      Jardín Botánico      1
```

Se busca en el *catálogo geográfico de Medellín* estos casos tanto por código como nombre para verificar que está generando la inconsistencia y se encontró que:

- El prefijo “Suburbano” es para referirse a veredas de las 5 corregimientos. Se elimina de los nombres
- Medellín cuenta con 20 Áreas institucionales (urbanas) que en la base auxiliar se codifican como “Inst_[#]”, diferente a la base que codifica solo con números. Dado que no se encontró la codificación DIVIPOLA para comunas y barrios entonces se cambian los códigos para que sea acorde a la codificación de Medellín
- En los casos donde el código no se encuentra en el listado auxiliar y tampoco se encontró en el geoportal, se cambia el código al que aparece en el listado oficial según el nombre del barrio/vereda

2. Los nombres de barrios que no se encuentran en la lista son:

```
## # A tibble: 5 x 4
##   codigo_comuna codigo_barrio nombre_barrio Cantidad
##   <chr>      <chr>      <chr>      <int>
## 1 08          0806      Piedras Blancas      4
## 2 0           0       Exterior[Eslovenia]    1
## 3 90          9011      Piedras Blancas Represa 1
## 4 60          6017      La Loma Oriental      15
## 5 01          0112      Piedras Blancas      1
```

La inconsistencia se debe en la mayoría de casos a la escritura.

3. Los casos donde hay discordancia entre el código y el nombre del barrio son 1771. Por ejemplo:

```
## # A tibble: 5 x 5
##   codigo_barrio nombre_barrio nombre      codigo_comuna Cantidad
##   <chr>          <chr>      <chr>      <chr>          <int>
## 1 0304          El Raizal    Santa Inés  03              5
## 2 1201          El Pesebre    Ferrini     12              3
## 3 1209          Santa Teresita Santa Mónica 12              1
## 4 6017          La Loma       El Llano    60             15
## 5 1312          Belencito     Betania     13              5
```

Muchos de estos casos se debe a la diferencia de codificación que se ha tratado de corregir en toda esta sección, por lo tanto, se decide cambiar el código al código de la codificación de Medellín en estos casos

Luego de esto, se siguen encontrando casos donde el nombre del barrio no coincide con el código. Estos casos se diferencian de los anteriores en que el código y el nombre son de diferentes comunas:

```
## # A tibble: 5 x 5
##   codigo_barrio nombre_barrio nombre      codigo_comuna Cantidad
##   <chr>          <chr>      <chr>      <chr>          <int>
## 1 0103          La Isla     Popular     01              1
## 2 0402          La Rosa     San Isidro  04              1
## 3 6097          Calasanz    Área de Expansión San Cris~ 60              4
## 4 7005          Altavista    Altavista Sector Central 70              3
## 5 9002          El Llano     Media Luna  90              1
```

Por lo tanto, se cambia al nombre según el código

4. Se encontraron casos donde el barrio no pertenece a la comuna especificada

```
## # A tibble: 5 x 4
##   codigo_barrio nombre_barrio      codigo_comuna cant
##   <chr>          <chr>      <chr>          <int>
## 1 <NA>          Prado       08              1
## 2 <NA>          Santa Lucía 13              3
## 3 <NA>          Juan XXIII La Quiebra 60              1
## 4 <NA>          Antonio Nariño 60              1
## 5 <NA>          Picachito    60              1
```

Se decide cambiar el valor de código y nombre comuna según el nombre del barrio, teniendo en cuenta que se busca rescatar la mayor cantidad posible de información

Estrato (estrato__)

Esta variable es información de la ficha de datos básicos que se debe registrar para cualquier evento que se reporta al SIVIGILA. Sin embargo, se encontró una ficha del 2016 donde no se solicita y otra de 2019 donde sí, lo que puede explicar porqué la gran cantidad de NA

```
##   1      2      3      4      5      6 NA's
## 2900 11658 6408 388   86   67 32503
```

```
##
##      2016 2017 2018 2019 2020 2021 2022 2023
##  1      0    0  503  629  624  583  557    4
##  2      0    0 1917 2611 1944 2323 2842   21
##  3      0    0  575 1112 1213 1490 2000   18
##  4      0    0   54   73   51   80  126    4
##  5      0    0   19   18    8   22   18    1
##  6      0    0   14   19   13    7   14    0
```

Sexo (sexo__)

```
##      F      M
## 53150   860
```

Orientación sexual (orient__sex)

De acuerdo a las fichas de notificación 2015-2022 y el diccionario de la base de datos, los niveles de esta variable son: homosexual(1),bisexual(2),heterosexual(5) y asexual(6). Sin embargo, esta variable también toma valor 3 y 4.

```
##      1      2      3      4      5      6
##  548   766   12  4632 46932  1120
```

Al notificar un caso se llena una ficha de datos básicos y una ficha relacionada al evento. Ambas fichas en las versiones recientes piden la orientación sexual. Sin embargo, la clasificación en la ficha de datos tiene una codificación diferente: heterosexual(1), gay/lesbiana(2), bisexual(3) y otra(4). Para evitar cruces se reduce a dos categorías: Orientación Sexual, Identidad y expresiones de género no hegemónicas (OSIEG no Hegemónicas), y heterosexual.

Ocupación de la víctima (ocupacion__)

De acuerdo al diccionario en MEData la codificación de está variable corresponde a la *Clasificación Única de Ocupaciones para Colombia (CUOC)*. El valor que toma el código puede ser hasta de 5 dígitos, cada dígito asigna un adicional de precisión sobre la ocupación. Por ejemplo, “25120” corresponde a desarrolladores de software mientras que “251” es desarrolladores y analistas de software y multimedia.

Sin embargo, algunos registros no tienen ningún tipo de relación con la codificación.

```
## # A tibble: 9 x 1
##   ocupacion_
##   <chr>
## 1 99999.01
## 2 LIM
## 3 99999.01
## 4 99999.01
## 5 99999.01
## 6 99999.01
## 7 99999.01
## 8 99999.01
## 9 C1
```


Entonces se verifica que los valores tomados en esta variable se encuentran en la clasificación mediante una base de datos que contiene las 676 ocupaciones posibles (código de 5 dígitos) y en caso que el valor de la variable no coincida con los códigos posibles se convierte el valor a NA.

Esta variable queda con 48532 celdas vacías. Pero puede servir para completar información de los niveles 26 (Otro) y 33 (Ninguna) de la variable **actividad**. Es importante resaltar que esta variable se pide en la ficha de datos básicos mientras que actividad en la ficha del evento.

Actividad

Esta variable es numérica pero se cambia a string para hacer la relación con **ocupación**

##	13	15	24	26	28	29	30	31	32	33
##	19	1	10608	17438	1767	138	23	9851	143	14022

```
data <- data %>%
  mutate(
    actividad = case_when(
      actividad == "13" ~ "Líderes(as) cívicos",
      actividad == "15" ~ "Maestro(a)",
      actividad == "24" ~ "Estudiante",
      actividad == "26" ~ "Otro",
      actividad == "28" ~ "Trabajador(a) doméstico(a)",
      actividad == "30" ~ "Campesino/a",
      actividad == "29" ~ "Persona en situación de prostitución",
      actividad == "31" ~ "Persona dedicada al cuidado del hogar",
      actividad == "32" ~ "Persona que cuida a otras",
      actividad == "33" ~ "Ninguna",
      TRUE ~ actividad
    )
  )
```

Son 4191 registros con valor “Otro” o “Ninguna” en **actividad** y que tienen valor en **ocupación**. Por lo tanto, se completa entre sí. Para evitar tantas categorías, se extrae el primer dígito que representa los 10 grupos principales de ocupaciones:

```
ocupaciones <- c(
  "0" = "Fuerzas militares",
  "1" = "Directores y gerentes",
  "2" = "Profesionales, científicos e intelectuales",
  "3" = "Técnicos y profesionales del nivel medio",
  "4" = "Personal de apoyo administrativo",
  "5" = "Trabajadores de los servicios y vendedores de comercios y mercados",
  "6" = "Agricultores y trabajadores calificados agropecuarios, forestales y pesqueros",
  "7" = "Oficiales, operarios, artesanos y oficios relacionados",
  "8" = "Operadores de instalaciones y máquinas y ensambladores",
  "9" = "Ocupaciones elementales"
)
```

Algunas categorías se cambian a su nombre equivalente en la CUOC:

- Maestro(a) a Profesionales, científicos e intelectuales
- Trabajador(a) doméstico(a) a Trabajador(a) doméstico(a)” a “Ocupaciones elementales
- Campesino/a a Agricultores y trabajadores calificados agropecuarios, forestales y pesqueros

Grupo étnico (nom_grupo_)

Esta variable toma valor si la variable **Pertenencia étnica (per_etn_)** es igual a 1 (indígena), en caso contrario, se asigna “No aplica”.

Semanas de gestación (sem_ges_)

Esta variable toma valor si la variable **gp_gestan** es igual a 1 (Sí). Además, se verifica que dicho valor sea entre 1 y 45 ya que es lo esperado en tiempo de gestación.

Información del hecho

Lugar de procedencia/ocurrencia del hecho

Se refiere al lugar donde posiblemente el paciente adquirió o al cual se atribuye la exposición al agente o factor de riesgo que ocasionó el evento.

País: se cuenta tanto con el código como con el nombre. Todos los casos son de Colombia

```
## 170
## 54010

## Colombia NA's
## 49976 4034
```

Departamento: se cuenta tanto con el código como con el nombre

```
## 01 05 13 23 25 27 47 48 50 66
## 1 53997 1 2 1 2 1 1 1 3

## ANTIOQUIA BOLIVAR CHOCO CORDOBA
## 53997 1 2 2
## CUNDINAMARCA DEPTO DESCONOCIDO MAGDALENA META
## 1 1 1 1
## RISARALDA STA MARTA D.E.
## 3 1
```

Se comienza modificando la escritura de los niveles y cambiando a NA el nivel “DEPTO DESCONOCIDO”
Luego, se verifica la concordancia de los códigos y nombres con ayuda de la codificación Divipola.

1. Al analizar que códigos no están en la lista, se encontraron los siguientes:

```
## # A tibble: 2 x 3
## cod_dpto_o ndep_proce Cantidad
## <chr> <chr> <int>
## 1 01 <NA> 1
## 2 48 Magdalena 1
```

Estos códigos no existen. El primer caso se cambia a NA y el segundo a 47 que es el código DIVIPOLA correspondiente a Magdalena

2. Los departamentos que no se encuentran en la lista son:

```
## # A tibble: 1 x 3
##   cod_dpto_o ndep_proce      n
##   <chr>      <chr>      <int>
## 1 <NA>      <NA>          1
```

3. Los casos donde hay discordancia entre el código y el nombre del departamento son:

```
## # A tibble: 0 x 3
## # i 3 variables: cod_dpto_o <chr>, ndep_proce <chr>, n <int>
```

No hay discordancias.

Municipio: se cuenta tanto con el código como con el nombre. La variable **nmun_proce** correspondiente al nombre tomaba en algunos casos nombres de departamento o que indicaban desconocimiento del municipio, por ende, se cambian a NA

Luego, se verifica la concordancia de los códigos y nombres con ayuda de la codificación Divipola:

1. Al analizar que códigos no están en la lista, se encontraron los siguientes:

```
## # A tibble: 4 x 4
##   cod_mun_o nmun_proce ndep_proce cantidad
##   <chr>      <chr>      <chr>      <int>
## 1 000      <NA>      Antioquia      12
## 2 000      <NA>      Chocó          2
## 3 000      <NA>      Magdalena      1
## 4 170      <NA>      <NA>           1
```

Todos los casos se cambian a NA por indicar que no se conoce el municipio

Nota: Una vez verificados los códigos, se transforma esta variable para que tome como valor el código completo (5 dígitos)

2. Los nombre de los municipios que no se encuentran en la lista auxiliar son:

```
## # A tibble: 2 x 3
##   cod_mun_o nmun_proce cantidad
##   <chr>      <chr>      <int>
## 1 05042      <NA>          3
## 2 <NA>      <NA>         16
```

3. Los casos donde hay discordancia entre el código y el nombre del municipio son:

```
## # A tibble: 0 x 3
## # i 3 variables: cod_mun_o <chr>, nmun_proce <chr>, cantidad <int>
```

No hay discordancias.

Área y barrio:

```
## # A tibble: 5 x 5
##   area_ localidad_ bar_ver_      cen_pobla_ vereda_
##   <dbl> <chr>      <chr>      <chr>      <chr>
## 1     1 <NA>        <NA>        <NA>        <NA>
## 2     1 <NA>      CASTILLA    <NA>        <NA>
## 3     1 <NA>    VILLA HERMOSA <NA>        <NA>
## 4     1 MEDELLIN  MORAVIA     <NA>        <NA>
## 5     1 <NA>      KENEDY     <NA>        <NA>
```

Con respecto a las variables **bar_ver_**, **vereda_**, **localidad_** y **cen_pobla_**, estas corresponden a la ubicación donde ocurrieron los hechos de violencia. Según las fichas de SIVIGILA, su uso depende de la variable **área_**, que clasifica el lugar del hecho en: (1) Cabecera municipal, (2) Centro poblado o (3) Rural disperso.

Cada variable tiene la siguiente función:

- **bar_ver_**: Barrio dentro de una cabecera municipal.
- **vereda_**: Vereda en un área rural dispersa.
- **localidad_**: Localidad en municipios sectorizados (como Medellín o Bogotá).
- **cen_pobla_**: Centro poblado en áreas rurales.

Con el fin de estandarizar la información, y manejar los datos faltantes, se realizaron algunos ajustes:

1. **Limpieza de datos:** Se reemplazaron por NA los valores que indicaban falta de información, tales como “SIN INFORMACIÓN”, “NO REGISTRA”, “DESCONOCIDO”, valores vacíos, valores inconsistentes, entre otros
2. **Unificación de variables:**
 - Se creó una nueva variable que fusiona **localidad_** y **bar_ver_**, dado que ambas se utilizan únicamente cuando **área_** = 1 (cabecera municipal).
 - Se combinó **vereda_** y **cen_pobla_**, asignando **vereda_** cuando **área_** = 3 (rural disperso) y **cen_pobla_** cuando **área_** = 2 (centro poblado).
3. **Completado de valores faltantes:**
 - Si **bar_ver_** estaba vacío en un área urbana (**área_** = 1), se completó con **cen_pobla_**, en caso de que esta última tuviera información.
4. **Creación de la variable lugar_hecho:**
 - Si el área es cabecera municipal (1), se asigna **bar_ver_** y, si está vacío, se usa **localidad_ / cen_pobla_**.
 - Si el área es centro poblado (2), se usa **cen_pobla_**.
 - Si el área es rural disperso (3), se usa **vereda_**.
 - Si no hay información disponible, se asigna NA.
5. **Eliminación de variables innecesarias:**
 - Se eliminaron las variables originales (**bar_ver_**, **localidad_**, **cen_pobla_**, **vereda_**) después de construir la variable **lugar_hecho**.

6. **Depuración variable final:** la variable **lugar_hecho** sería entonces el equivalente a **barrio de ocurrencia** pero queda con un 23.301% de NA. Este es un motivo por el cual se decide unificar más adelante esta variable con **barrio de residencia**, para ello se debe hacer una limpieza de **lugar_hecho**.

- Se unifica la escritura para evitar repeticiones
- Como se vio en secciones anteriores, la mayoría de los casos ocurrieron en Medellín entonces se comienza verificando si los barrios/veredas sí corresponden a Medellín y en caso de que no, cuando se trata de barrios/veredas de otros municipios:

Son 18466 casos donde no se conoce el barrio de residencia de la víctima y el hecho ocurrió en barrios/veredas que aparentemente no pertenecen a Medellín. Por ejemplo:

```
## # A tibble: 5 x 6
##   lugar_hecho      nombre_barrio codigo_barrio nmun_proce ndep_proce cantidad
##   <chr>          <chr>      <chr>      <chr>      <chr>      <int>
## 1 San Cristobal  Área de Expa~ <NA>      Medellín  Antioquia      1
## 2 La Bahia      <NA>         <NA>      Medellín  Antioquia      1
## 3 San Javier    Palenque      0716      Medellín  Antioquia      1
## 4 Belllo        La Milagrosa  0910      Medellín  Antioquia      1
## 5 Corregimiento San ~ Perpetuo Soc~ 1012      Medellín  Antioquia      1
```

Se encontró que estas inconsistencias están dadas por: diferencia de escritura con la base de barrios auxiliar, se registro fue nombres de municipios o lugares específicos como edificios, parques o calles y en los demás casos Sí corresponden a barrios/veredas de municipios diferentes a Medellín. Se procede a arreglar estas inconsistencias.

- Luego, es necesario verificar que el barrio/vereda si sea coherente con el municipio

```
## # A tibble: 560 x 4
##   lugar_hecho nmun_proce cod_mun_o    n
##   <chr>      <chr>      <chr>  <int>
## 1 12 De Octubre Medellín  05001    3
## 2 12 De Cotubre Medellín  05001    1
## 3 12 De Ctubre Medellín  05001    1
## 4 12 De Octubre Medellín  05001   158
## 5 12 De Octubtre Medellín  05001    1
## 6 12 De Ocyubre Medellín  05001    1
## 7 12 Octubre Medellín  05001   22
## 8 12-Oct Medellín  05001    4
## 9 7 De Agosto Bogotá, D.C. 11001    1
## 10 Aguas Frías Medellín  05001   38
## # i 550 more rows
```

- Finalmente, se corrigen algunos casos donde el área no es coherente con el barrio/vereda. Por ejemplo:

```
## # A tibble: 5 x 4
##   lugar_hecho area_ nmun_proce    n
##   <chr>      <dbl> <chr>      <int>
## 1 El Cacique 2 Puerto Berrío    1
## 2 Manchester 1 Bello            1
## 3 <NA>        1 Copacabana      11
## 4 La Francia 2 Medellín          1
## 5 Guayaquil 1 Medellín          1
```

Para determinar si el tipo de área era o no correcta, se utilizó este *recurso*

Luego de este tratamiento, la columna quedó con un 24.02 de valores faltantes. Cabe resaltar que se está tomando algunos valores correspondientes a comunas ya que pueden servir más adelante para completar.

Además, existen algunos casos donde se especifica como lugar de hecho *Habitante de Calle*, por lo tanto, al no indicar un lugar concreto se utiliza esta información para completar en la variable **Actividad** cuando sea *habitante de calle* y actividad sea *Ninguna* u *Otra*

```
## # A tibble: 6 x 3
##   lugar_hecho      nmun_proce actividad
##   <chr>          <chr>      <chr>
## 1 Habitante de Calle Medellín  Ninguna
## 2 Habitante de Calle Medellín  Persona en situación de prostitución
## 3 Habitante de Calle Medellín  Ninguna
## 4 Habitante de Calle Medellín  Ninguna
## 5 Habitante de Calle Medellín  Estudiante
## 6 Habitante de Calle Medellín  Otro
```

Hora del hecho

Esta variable no se solicita en las versiones recientes de la ficha, lo que explica los 48867 registros con NA.

Modalidad de la violencia (naturaleza y nat_viosex)

De acuerdo a las fichas de notificación existen dos grupos de modalidad: violencia no sexual y violencia sexual, cada una con diferentes tipos. Si la víctima sufrió violencia no sexual se registra el tipo en la variable **naturaleza** y si sufrió violencia sexual se registra el tipo en la variable **nat_viosex**.

Por facilidad en el análisis y evitando la mayor cantidad de celdas vacías posibles, se decide unificar la información de ambas variables en una variable llamada **def_naturaleza**.

Mecanismo utilizado para la agresión

Se observa que en todos los casos de violencia física se utilizó un mecanismo. También en algunos casos de violencia psicológica, abandono y otras violencias sexuales.

```
##
##      1      2      3      4     11     12     13     14     15     16
##  1   939   340 15210 1040    79    21    16    16  6289    12
##  2     0     0     9    23    10     0     0     0  1825     0
##  3     0     0     0     0     0     0     0     0    31     0
##  4     0     0     0     0     0     0     0     0     0     0
##  5     0     0     0     0     0     0     0     0     0     0
##  6     0     0     0     0     0     0     0     0     0     0
##  7     0     0     0     0     0     0     0     0     0     0
## 10     0     0     0     0     0     0     0     0     0     0
## 12     0     0     0     0     0     0     0     0     0     0
## 14     0     0     1     0     0     0     0     0     3     0
```

Se tiene 28146 registros con valores faltantes en esta variable. Analizando el tipo de violencia de estos casos, se obtiene:

```
##      1      2      3      4      5      6      7     10     12     14
## 784 7136 4858 6630 1449 3951  136    13 1968 1221
```

Entonces se podría pensar que en los casos donde la violencia sea física, y tenga NA en armas, se cambie NA a otro mecanismo (15). Sin embargo, vemos que los casos donde no se conoce si utilizó un arma, son muy pocos de violencia física a comparación de los otros tipos de violencia

Se recuperarían 784 NA al hacer esta asignación.

Quemaduras

En la base de datos, las variables relacionadas con quemaduras (por ejemplo, que_cara, que_cuello, etc.) solo contienen información relevante cuando la categoría de la variable armas corresponde a “Quemaduras por fuego o llama” (12), “Quemaduras por ácido, álcalis, o sustancias corrosivas” (13) y “Quemadura con líquido hirviendo” (14). Sin embargo, en los casos en que no hay quemaduras, estas variables contienen valores faltantes (NA), lo que puede generar dificultades en los análisis. Entonces, se transforman los valores NA en una categoría explícita como “No aplica”.

Información del agresor

Sexo del agresor (sexo_agre)

Esta variable toma los valores de vacíos y de “SD” en algunos registros, por lo tanto, se cambia a NA. Teniendo en cuenta que “SD” de acuerdo a los formatos de notificación significan ausencia del dato.

Edad del agresor (edad_agre)

```
## [1]  0  2 14 61 35 25 27 99 40 17 21 63  8 33 28 45 24 16 38 29 22 18 36 31 32
## [26] 64 58 23 39 30 52 34 19 15 10 48 56 20 53 49  5 60 65 46 44 26 70 37 59 50
## [51] 55 42  9 43  6 78 12 54 11 62 13 71 69 57 66 79 68 41 47  7 82 81 85 51 80
## [76] 77 76 72 96 67 75 73
```

Se ve que esta variable (cuya unidad de medida es años), contiene edades de 0 y 2 años para el agresor, lo cual parece ser una inconsistencia en la variable. Además se encontró que es el 91.748% de los registros que presentan este problema y de acuerdo con las fichas de notificación de violencia disponibles, la única ficha que incluye la pregunta de la edad del agresor es en el año 2015.

Por tanto los valores de 0 y 2 podrían corresponder a valores faltantes de los años restantes de notificaciones en las que no se pregunta esto. Así, la variable tiene bastantes valores faltantes, por lo tanto es necesario eliminarla del análisis.

Nota: Hay registros que se notificaron con valor en esta variable hasta 2018.

```
##
##      2016  2017  2018  2019  2020  2021  2022  2023
## 0         0   516 4092 5404 4331 9430 11481   57
## 2         0     0 4603 6014 3625     0     0     0
## 5         0    18   3     0     0     0     0     0
## 6         0     5   1     0     0     0     0     0
## 7         0     6   0     0     0     0     0     0
## 8         0     8   7     0     0     0     0     0
## 9         0     7   1     0     0     0     0     0
```

##	10	0	10	2	0	0	0	0	0
##	11	0	7	3	0	0	0	0	0
##	12	0	27	6	0	0	0	0	0
##	13	0	37	7	0	0	0	0	0
##	14	0	41	15	0	0	0	0	0
##	15	0	59	25	0	0	0	0	0
##	16	0	72	22	0	0	0	0	0
##	17	0	78	39	0	0	0	0	0
##	18	0	98	27	0	0	0	0	0
##	19	0	76	22	0	0	0	0	0
##	20	0	106	32	0	0	0	0	0
##	21	0	69	21	0	0	0	0	0
##	22	0	99	28	0	0	0	0	0
##	23	0	105	16	0	0	0	0	0
##	24	0	78	28	0	0	0	0	0
##	25	0	149	53	0	0	0	0	0
##	26	0	78	24	0	0	0	0	0
##	27	0	95	18	0	0	0	0	0
##	28	0	91	36	0	0	0	0	0
##	29	0	77	19	0	0	0	0	0
##	30	0	222	85	0	0	0	0	0
##	31	0	40	18	0	0	0	0	0
##	32	1	69	30	0	0	0	0	0
##	33	0	71	25	0	0	0	0	0
##	34	0	44	28	0	0	0	0	0
##	35	0	115	23	0	0	0	0	0
##	36	0	55	16	0	0	0	0	0
##	37	0	52	20	0	0	0	0	0
##	38	0	47	24	0	0	0	0	0
##	39	0	48	14	0	0	0	0	0
##	40	0	119	45	0	0	0	0	0
##	41	0	19	6	0	0	0	0	0
##	42	0	19	15	0	0	0	0	0
##	43	0	22	10	0	0	0	0	0
##	44	0	18	9	0	0	0	0	0
##	45	0	53	14	0	0	0	0	0
##	46	0	18	5	0	0	0	0	0
##	47	0	22	3	0	0	0	0	0
##	48	0	18	8	0	0	0	0	0
##	49	0	10	3	0	0	0	0	0
##	50	0	49	15	0	0	0	0	0
##	51	0	9	3	0	0	0	0	0
##	52	0	22	4	0	0	0	0	0
##	53	0	16	6	0	0	0	0	0
##	54	1	22	8	0	0	0	0	0
##	55	0	19	7	0	0	0	0	0
##	56	0	6	4	0	0	0	0	0
##	57	0	6	1	0	0	0	0	0
##	58	0	14	3	0	0	0	0	0
##	59	0	8	3	0	0	0	0	0
##	60	0	30	8	0	0	0	0	0
##	61	0	6	5	0	0	0	0	0
##	62	0	6	3	0	0	0	0	0
##	63	0	5	2	0	0	0	0	0

##	64	0	4	1	0	0	0	0	0
##	65	0	9	1	0	0	0	0	0
##	66	0	3	0	0	0	0	0	0
##	67	0	1	1	0	0	0	0	0
##	68	0	2	1	0	0	0	0	0
##	69	0	4	1	0	0	0	0	0
##	70	0	17	2	0	0	0	0	0
##	71	0	5	3	0	0	0	0	0
##	72	0	3	0	0	0	0	0	0
##	73	0	0	1	0	0	0	0	0
##	75	0	3	0	0	0	0	0	0
##	76	0	3	0	0	0	0	0	0
##	77	0	2	0	0	0	0	0	0
##	78	0	2	2	0	0	0	0	0
##	79	0	2	1	0	0	0	0	0
##	80	0	3	0	0	0	0	0	0
##	81	0	2	0	0	0	0	0	0
##	82	0	2	0	0	0	0	0	0
##	85	0	2	0	0	0	0	0	0
##	96	0	1	0	0	0	0	0	0
##	99	0	498	150	0	0	0	0	0

Relación del agresor con la víctima (r_fam_vic)

##	3	9	10	22	23	24	25	NA's
##	1	3220	3632	13482	6059	10537	17076	3

Relación del agresor con la víctima: no familiar (r_nofiliar)

##	1	2	3	4	6	7	8	9	10	11	12	13	NA's
##	156	1654	190	293	5111	1332	2906	1753	6213	143	11	87	34161

Esta variable toma el valor de 9 en algunos registros, de acuerdo a las fichas encontradas con las que se notifican los casos de violencia, este código corresponde a la respuesta “Sin información” sobre la relación no familiar que existe entre la víctima y el agresor. Así, este nivel se convierte en NA.

Unión de las variables de relación con el agresor

Las variables **r_fam_vic** (relación familiar) y **r_nofiliar** (relación no familiar) contienen información relacionada con el parentesco entre la víctima y el agresor. Por lo tanto, resulta útil unificar esta información en una sola variable llamada **parentezco_agresor**, con el propósito de simplificar y organizar los datos para facilitar futuros análisis.

En la variable **r_fam_vic**, el nivel 25 (“Ninguno”) indica que no existe una relación familiar con el agresor, y tiene una cantidad bastante grande de datos, alcanza a sumar casi el total de datos que hay en la variable de relación no familiar exceptuando los NA. Entonces, es razonable asumir que el parentesco (en nivel “Ninguno”) podría corresponder a alguno de los niveles presentes en la variable **r_nofiliar**. Para realizar esta unificación de manera adecuada, fue necesario recodificar los niveles de ambas variables. Esto se hizo para evitar duplicados o combinaciones incorrectas, ya que algunos niveles podrían compartir nombres similares pero referirse a descripciones diferentes.

La unificación de las variables se realizó aplicando la lógica de:

- Si `r_fam_vic` tenía un valor válido distinto de “Ninguno”, se priorizó ese valor.
- Si `r_fam_vic` era “Ninguno”, se utilizó el valor correspondiente de `r_nofiliar`.
- En los casos donde ambas variables eran NA, el resultado final también se dejó como NA.

Este proceso, además permitió reducir los NAs, que en ambas variables sumaban un total de 35917, y después de la transformación se reducen a 1696 para la nueva variable. Finalmente, se eliminan las variables originales `r_fam_vic` y `r_nofiliar`.

```
##
##           Amigo(a) Compañero(a) de estudio Compañero(a) de trabajo
##           1654                293                190
##           Conocido(a)           Desconocido(a)           Ex_Pareja
##           2906                4080                6059
##           Familiar              Jefe                    Madre
##           10537               143                   3632
##           Otro                 Padre                    Pareja
##           4531                3220                13483
##           Profesor(a)         Sacerdote/Pastor         Servidor(a) público
##           156                 11                    87
##           Vecino(a)           <NA>
##           1332               1696
```

Convivencia con el agresor

Se convierte a NA los casos en que se representan la ausencia del datos con “ ”

Información de la atención/notificación

Atención integral en salud

Este grupo de variables corresponden a las atenciones en salud que se le realizaron a las víctimas. La atenciones relacionadas con profilaxis para VIH, HB, otras profilaxis, anticoncepción de emergencia, orientación IVE y recolección de evidencia medico legal solo se realizan en caso de violencias sexuales. Por lo tanto, en los casos que no son violencia sexual se asigna “No aplica” a las variables que las representa.

Condición final de la víctima al momento de la notificación (`con_fin_`)

Según los datos esta variable toma tres posibles valores: 0 = No sabe, no responde, 1 = Vivo, 2 = Muerto. Sin embargo, el formato de notificación 2024 indica que “0” solo aplica cuando se capte el caso por BAI (Brotes, Alertas e Incidencias) y se desconoce el dato, o para defectos congénitos cuando la unidad de medida es “0”. Dado que el evento de interés no es ninguno de los mencionados, se cambia los casos con “0” por NA.

Causa básica de defunción (`cbmte_`)

Esta variable corresponde al diagnóstico CIE-10 (Ver) que ocasionó la muerte de la víctima y que está relacionado con el evento de interés. Toma un valor si la variable `con_fin_` es igual a 2 (muerto), en caso contrario, se le asigna “No aplica” para no confundir con valores faltantes. Además, para los valores que no son un código válido se cambian a NA.

Valores faltantes

##	Column	total_na	total_empty	percent_na	percent_empty
## 1	hora_hecho	48867	0	90.48	0
## 2	estrato_	32503	0	60.18	0
## 3	armas	28146	0	52.11	0
## 4	que_cara	28146	0	52.11	0
## 5	que_cuello	28146	0	52.11	0
## 6	que_mano	28146	0	52.11	0
## 7	que_pie	28146	0	52.11	0
## 8	que_pliegu	28146	0	52.11	0
## 9	que_genita	28146	0	52.11	0
## 10	que_tronco	28146	0	52.11	0
## 11	que_miesup	28146	0	52.11	0
## 12	que_mieinf	28146	0	52.11	0
## 13	cla_gra	28146	0	52.11	0
## 14	ext_que	28146	0	52.11	0
## 15	lugar_hecho	12979	0	24.03	0
## 16	codigo_barrio	5880	0	10.89	0
## 17	zona_conf	5783	0	10.71	0
## 18	sexo_agre	5436	0	10.06	0
## 19	nombre_barrio	5416	0	10.03	0
## 20	codigo_comuna	5372	0	9.95	0
## 21	nombre_comuna	5372	0	9.95	0
## 22	cod_pais_r	4109	0	7.61	0
## 23	npais_resi	4109	0	7.61	0
## 24	npais_proce	4034	0	7.47	0
## 25	ac_anticon	3608	0	6.68	0
## 26	ac_ive	3608	0	6.68	0
## 27	sp_its	3398	0	6.29	0
## 28	prof_hep_b	3398	0	6.29	0
## 29	prof_otras	3397	0	6.29	0
## 30	evi_mlegal	3381	0	6.26	0
## 31	gp_mad_com	2073	0	3.84	0
## 32	gp_gestan	2002	0	3.71	0
## 33	parentezco_agresor	1696	0	3.14	0
## 34	gp_desplaz	1225	0	2.27	0
## 35	gp_discapa	1222	0	2.26	0
## 36	gp_migrant	1218	0	2.26	0
## 37	gp_carcela	1221	0	2.26	0
## 38	gp_pobicbf	1219	0	2.26	0
## 39	gp_psiquia	1218	0	2.26	0
## 40	gp_indigen	1215	0	2.25	0
## 41	gp_desmovi	1217	0	2.25	0
## 42	gp_vic_vio	1207	0	2.23	0
## 43	nmun_resi	102	0	0.19	0
## 44	cod_mun_r	68	0	0.13	0
## 45	nom_grupo_	54	0	0.10	0
## 46	cbmte_	43	0	0.08	0
## 47	gp_otros	34	0	0.06	0
## 48	cod_dpto_r	35	0	0.06	0
## 49	con_fin_	35	0	0.06	0
## 50	ndep_resi	35	0	0.06	0
## 51	cod_mun_o	20	0	0.04	0

## 52	nmun_proce	20	0	0.04	0
## 53	conv_agre	3	0	0.01	0
## 54	escenario	5	0	0.01	0
## 55	cod_dpto_o	1	0	0.00	0
## 56	area_	2	0	0.00	0
## 57	per_etn_	2	0	0.00	0
## 58	ndep_proce	1	0	0.00	0

Con respecto a la variable **sem_ges_**, que toman un valor solo si la víctima estaba embarazada, 206 registros no cuentan con un valor en ella

De acuerdo a lo anterior, son 515801 celdas NA y 0 celdas que fueron definidas como vacías poniendo “.”.

Para un total de 54010 registros con valores faltantes y celdas vacías, lo que corresponde al 100% de la base de datos. Sin embargo, como hay columnas relacionadas, algunas celdas de una columna pueden recibir un valor a partir de otra columna.

Relacionar información para rellenar campos vacíos

Barrio de residencia: Son 5880 casos donde se puede completar el código del barrio a partir del nombre. Por ejemplo:

```
## # A tibble: 5 x 3
##   codigo_barrio nombre_barrio      n
##   <chr>         <chr>         <int>
## 1 <NA>         Guayabal             1
## 2 <NA>         Ferrini              4
## 3 <NA>         El Rincón            1
## 4 <NA>         Olaya Herrera        1
## 5 <NA>         Juan XXIII La Quiebra 1
```

El número de NA disminuye a 5424

Comuna de residencia a partir de barrio:

```
## # A tibble: 0 x 5
## # i 5 variables: codigo_comuna <chr>, nombre_comuna <chr>, codigo_barrio <chr>,
## #   nombre_barrio <chr>, n <int>
```

No hay casos donde se puede completar información de comuna de residencia a partir de barrio.

Comuna de residencia:

```
## # A tibble: 1 x 3
##   codigo_comuna nombre_comuna      n
##   <chr>         <chr>         <int>
## 1 <NA>         <NA>             5372
```

No hay casos donde se pueda completar comuna de residencia entre sí.

Municipio de residencia:

```
## # A tibble: 3 x 3
##   cod_mun_r nmun_resi      n
##   <chr>      <chr>    <int>
## 1 05001      <NA>      11
## 2 05042      <NA>      23
## 3 <NA>      <NA>      68
```

Son 102 registros con código o nombre del municipio NA.

Municipio de residencia a partir de comuna:

```
## # A tibble: 15 x 5
##   cod_mun_r nmun_resi codigo_comuna nombre_comuna      n
##   <chr>      <chr>      <chr>      <chr>      <int>
## 1 <NA>      <NA>      01      Popular      8
## 2 <NA>      <NA>      02      Santa Cruz    3
## 3 <NA>      <NA>      04      Aranjuez      4
## 4 <NA>      <NA>      05      Castilla      2
## 5 <NA>      <NA>      06      Doce De Octubre 1
## 6 <NA>      <NA>      07      Robledo       3
## 7 <NA>      <NA>      08      Villa Hermosa  4
## 8 <NA>      <NA>      09      Buenos Aires  3
## 9 <NA>      <NA>      10      La Candelaria  2
## 10 <NA>      <NA>      12      La América     2
## 11 <NA>      <NA>      13      San Javier     5
## 12 <NA>      <NA>      15      Guayabal       3
## 13 <NA>      <NA>      60      Corregimiento de San Cristóbal 5
## 14 <NA>      <NA>      80      Corregimiento de San Antonio de Prado 1
## 15 <NA>      <NA>      <NA>      <NA>      22
```

Son 46 registros con información faltante del municipio de residencia que se pueden completar mediante la comuna

Departamento de residencia:

```
## # A tibble: 1 x 3
##   cod_dpto_r ndep_resi      n
##   <chr>      <chr>    <int>
## 1 <NA>      <NA>      35
```

No hay manera de completar código y nombre del departamento de residencia entre sí

Departamento de residencia a partir de municipio:

```
## # A tibble: 2 x 5
##   cod_dpto_r ndep_resi cod_mun_r nmun_resi      n
##   <chr>      <chr>      <chr>      <chr>    <int>
## 1 <NA>      <NA>      05001      Medellín  22
## 2 <NA>      <NA>      <NA>      <NA>     13
```

País de residencia:

```
## # A tibble: 1 x 3
##   cod_pais_r npais_resi      n
##   <dbl> <chr>      <int>
## 1      NA <NA>      4109
```

No hay manera de completar código y nombre del país de residencia entre sí

País de residencia a partir de departamento:

```
## # A tibble: 4 x 5
##   cod_pais_r npais_resi cod_dpto_r ndep_resi      n
##   <dbl> <chr>      <chr>      <chr>      <int>
## 1      NA <NA>      05      Antioquia    4094
## 2      NA <NA>      17      Caldas        1
## 3      NA <NA>      44      La Guajira    1
## 4      NA <NA>      <NA>      <NA>        13
```

Área de ocurrencia a partir de lugar:

```
## # A tibble: 1 x 3
##   area_lugar_hecho      n
##   <dbl> <chr>      <int>
## 1      NA <NA>        2
```

No hay manera de completar información sobre área del hecho

Municipio de ocurrencia:

```
## # A tibble: 7 x 5
##   cod_mun_o nmun_proce cod_dpto_o ndep_proce      n
##   <chr>      <chr>      <chr>      <chr>      <int>
## 1 <NA>      <NA>      05      Antioquia    12
## 2 <NA>      <NA>      13      Bolívar       1
## 3 <NA>      <NA>      27      Chocó         2
## 4 <NA>      <NA>      47      Magdalena     1
## 5 <NA>      <NA>      50      Meta          2
## 6 <NA>      <NA>      73      Tolima         1
## 7 <NA>      <NA>      <NA>      <NA>         1
```

No hay manera de completar código y nombre del municipio de ocurrencia entre sí

Municipio de ocurrencia a partir de lugar

```
## # A tibble: 10 x 4
##   cod_mun_o nmun_proce lugar_hecho      n
##   <chr>      <chr>      <chr>      <int>
## 1 <NA>      <NA>      Calasanz       1
## 2 <NA>      <NA>      Caribe         1
## 3 <NA>      <NA>      Florencia       1
```

```
## 4 <NA>      <NA>      Nueva Villa de La Iguaná      1
## 5 <NA>      <NA>      Robledo                        2
## 6 <NA>      <NA>      San Antonio de Prado          1
## 7 <NA>      <NA>      San Cristobal                1
## 8 <NA>      <NA>      Santa Fé                      1
## 9 <NA>      <NA>      Santo Domingo Savio No.1      1
## 10 <NA>     <NA>      <NA>                        10
```

Se asigna Medellín a todos los casos

Departamento de ocurrencia:

```
## # A tibble: 1 x 3
##   cod_dpto_o ndep_proce      n
##   <chr>      <chr>      <int>
## 1 <NA>      <NA>          1
```

No hay manera de completar código y nombre del departamento de ocurrencia entre sí

Departamento de ocurrencia a partir de municipio:

```
## # A tibble: 1 x 5
##   cod_dpto_o ndep_proce cod_mun_o nmun_proce      n
##   <chr>      <chr>      <chr>      <chr>      <int>
## 1 <NA>      <NA>      05001      Medellín      1
```

Solo es posible completar el primer caso

País de ocurrencia:

```
## # A tibble: 1 x 3
##   cod_pais_o npais_proce      n
##   <dbl> <chr>      <int>
## 1      170 <NA>      4034
```

Todos los casos se pueden completar a partir de **cod_pais_o**

País de ocurrencia a partir de departamento:

```
## # A tibble: 0 x 5
## # i 5 variables: cod_pais_o <dbl>, npais_proce <chr>, cod_dpto_o <chr>,
## #   ndep_proce <chr>, n <int>
```

No hay casos por completar.

Grupos poblacionales: según la ficha de notificación, si la víctima no pertenece a los grupos listados (**gp_discapa**, **gp_desplaz**, etc) se debe llenar con “Sí” la variable **gp_otros** para indicar que pertenece a otro grupo poblacional.

```
## $gp_discapa
##
##      1      2 <NA>
##   134 52654 1222
##
## $gp_desplaz
##
##      1      2 <NA>
##   165 52620 1225
##
## $gp_migrant
##
##      1      2 <NA>
##   419 52373 1218
##
## $gp_carcela
##
##      1      2 <NA>
##    21 52768 1221
##
## $gp_gestan
##
##      1      2 <NA>
##  1147 50861 2002
##
## $gp_indigen
##
##      1      2 <NA>
##    85 52710 1215
##
## $gp_pobicbf
##
##      1      2 <NA>
##   176 52615 1219
##
## $gp_mad_com
##
##      1      2 <NA>
##     5 51932 2073
##
## $gp_desmovi
##
##      1      2 <NA>
##     4 52789 1217
##
## $gp_psiquia
##
##      1      2 <NA>
##    78 52714 1218
##
```



```
## $gp_vic_vio
##
##      1      2  <NA>
## 1540 51263 1207
##
## $gp_otros
##
##      1      2  <NA>
## 51783 2193   34
```

Por lo tanto, si alguno de los grupos listados es NA y **gp_otros** tiene valor igual a 1 (Sí) se cambia ese NA por 2(No). Mientras que sí es Na **gp_otros** tiene valor igual a 2(No) se deja igual

```
## $gp_discapa
##
##      1      2  <NA>
##   134 53840   36
##
## $gp_desplaz
##
##      1      2  <NA>
##   165 53811   34
##
## $gp_migrant
##
##      1      2  <NA>
##   419 53558   33
##
## $gp_carcela
##
##      1      2  <NA>
##    21 53954   35
##
## $gp_gestan
##
##      1      2  <NA>
##  1147 52827   36
##
## $gp_indigen
##
##      1      2  <NA>
##    85 53895   30
##
## $gp_pobicbf
##
##      1      2  <NA>
##   176 53801   33
##
## $gp_mad_com
##
##      1      2  <NA>
##     5 53939   66
##
## $gp_desmovi
```

```
##
##      1      2  <NA>
##      4 53973    33
##
## $gp_psiquia
##
##      1      2  <NA>
##      78 53899    33
##
## $gp_vic_vio
##
##      1      2  <NA>
##     1540 52439    31
##
## $gp_otros
##
##      1      2  <NA>
##    51783  2193    34
```

Variable armas a partir de que__, cla__gra y ext__que: No se puede porque no hay registros vacíos en armas que tenga algún valor en que__

Crear nuevas variables de georeferenciación

Barrio (nombre): si **nombre__barrio** no es NA, la nueva variable toma su valor. En caso de ser NA, se la asigna a la nueva variable valor de **lugar__hecho**

Comuna (código): antes de crear el código del barrio se crea la variable de comuna, para que no generar errores cuando dos barrios se llamen igual

Comuna (nombre): teniendo los nuevos códigos de las comunas correctos, se asigna a cada uno de ellos el correspondiente nombre de la comuna de Medellín, en caso de no existir un registro para el código nuevo de comuna, y el nombre de comuna antiguo sí exista, se asigna ese.

Luego, aunque ya había sido creada la variable del código de comuna, se completa con los nombres que hay ahora.

Barrio (código): Finalmente se crea la variable que representa el código del barrio a partir del valor que toma la variable **barrio__nuevo**.

Municipio (nombre): se crea la nueva variable de municipio. Esta variable se crea a partir de **barrio__nuevo**, si el barrio es de Medellín, se asigna Medellín. Si el barrio es de un municipio diferente, se asigna el municipio correspondiente y sino es ninguno de los dos casos, se deja NA.

Luego de completar valores faltantes y crear las nuevas variables, se puede observar que disminuyó la cantidad de celdas vacías.

```
##              Column total_na total_empty percent_na percent_empty
## 1          hora_hecho    48867          0      90.48            0
## 2          estrato_      32503          0      60.18            0
```

## 3	armas	28146	0	52.11	0
## 4	que_cara	28146	0	52.11	0
## 5	que_cuello	28146	0	52.11	0
## 6	que_mano	28146	0	52.11	0
## 7	que_pie	28146	0	52.11	0
## 8	que_pliegu	28146	0	52.11	0
## 9	que_genita	28146	0	52.11	0
## 10	que_tronco	28146	0	52.11	0
## 11	que_miesup	28146	0	52.11	0
## 12	que_mieinf	28146	0	52.11	0
## 13	cla_gra	28146	0	52.11	0
## 14	ext_que	28146	0	52.11	0
## 15	lugar_hecho	18142	0	33.59	0
## 16	zona_conf	5783	0	10.71	0
## 17	sexo_agre	5436	0	10.06	0
## 18	codigo_barrio	5424	0	10.04	0
## 19	nombre_barrio	5416	0	10.03	0
## 20	codigo_comuna	5372	0	9.95	0
## 21	nombre_comuna	5372	0	9.95	0
## 22	ac_anticon	3608	0	6.68	0
## 23	ac_ive	3608	0	6.68	0
## 24	sp_its	3398	0	6.29	0
## 25	prof_hep_b	3398	0	6.29	0
## 26	prof_otras	3397	0	6.29	0
## 27	evi_mlegal	3381	0	6.26	0
## 28	cod_barrio_nuevo	2815	0	5.21	0
## 29	cod_comuna_nuevo	2786	0	5.16	0
## 30	comuna_nuevo	2777	0	5.14	0
## 31	barrio_nuevo	2712	0	5.02	0
## 32	municipio_nuevo	2712	0	5.02	0
## 33	parentezco_agresor	1696	0	3.14	0
## 34	gp_mad_com	66	0	0.12	0
## 35	nom_grupo_	54	0	0.10	0
## 36	cbmte_	43	0	0.08	0
## 37	gp_discapa	36	0	0.07	0
## 38	gp_gestan	36	0	0.07	0
## 39	gp_desplaz	34	0	0.06	0
## 40	gp_migrant	33	0	0.06	0
## 41	gp_carcela	35	0	0.06	0
## 42	gp_indigen	30	0	0.06	0
## 43	gp_pobicbf	33	0	0.06	0
## 44	gp_desmovi	33	0	0.06	0
## 45	gp_psiquia	33	0	0.06	0
## 46	gp_vic_vio	31	0	0.06	0
## 47	gp_otros	34	0	0.06	0
## 48	con_fin_	35	0	0.06	0
## 49	cod_mun_r	22	0	0.04	0
## 50	nmun_resi	22	0	0.04	0
## 51	cod_mun_o	10	0	0.02	0
## 52	cod_pais_r	13	0	0.02	0
## 53	cod_dpto_r	13	0	0.02	0
## 54	nmun_proce	10	0	0.02	0
## 55	npais_resi	13	0	0.02	0
## 56	ndep_resi	13	0	0.02	0

## 57	conv_agre	3	0	0.01	0
## 58	escenario	5	0	0.01	0
## 59	area_	2	0	0.00	0
## 60	per_etn_	2	0	0.00	0

Hecho esto queda un total de 54010 registros con celdas vacías, lo que corresponde al 100% de la base de datos. Es decir, se pueden utilizar 0 registros completos.

Ahora, algunas variables tienen más del 50% de los registros con celdas vacías, ya sea porque no se registró la información o porque esa variable no es considerada en todas las fichas de notificación del SIVIGILA. Como es el caso de **edad agresor**, **estrato_**, y **hora del hecho** que según lo investigado no se piden en fichas recientes.

Esas variables son:

```
## [1] "hora_hecho" "estrato_" "armas" "que_cara" "que_cuello"
## [6] "que_mano" "que_pie" "que_pliegu" "que_genita" "que_tronco"
## [11] "que_miesup" "que_mieinf" "cla_gra" "ext_que"
```

Al eliminar estas variables, se obtiene una base de datos con **53768 registros**.

Registros duplicados

```
## [1] 278
```

Finalmente, al eliminar los registros duplicados se obtiene una base de datos depurada con **53490 registros**, y las siguientes variables:

```
## [1] "fec_not" "sexo_" "cod_pais_o"
## [4] "cod_dpto_o" "cod_mun_o" "area_"
## [7] "tip_ss_" "per_etn_" "nom_grupo_"
## [10] "gp_discapa" "gp_desplaz" "gp_migrant"
## [13] "gp_carcela" "gp_gestan" "sem_ges_"
## [16] "gp_indigen" "gp_pobicbf" "gp_mad_com"
## [19] "gp_desmovi" "gp_psiquia" "gp_vic_vio"
## [22] "gp_otros" "cod_pais_r" "cod_dpto_r"
## [25] "cod_mun_r" "pac_hos_" "con_fin_"
## [28] "cbmte_" "actividad" "orient_sex"
## [31] "ident_gene" "consum_spa" "mujer_cabf"
## [34] "antec" "sust_vict" "sexo_agre"
## [37] "conv_agre" "zona_conf" "escenario"
## [40] "ambito_lug" "sp_its" "prof_hep_b"
## [43] "prof_otras" "ac_anticon" "ac_ive"
## [46] "ac_mental" "remit_prot" "inf_aut"
## [49] "evi_mlegal" "npais_proce" "ndep_proce"
## [52] "nmun_proce" "npais_resi" "ndep_resi"
## [55] "nmun_resi" "codigo_barrio" "codigo_comuna"
## [58] "nombre_barrio" "nombre_comuna" "edad"
## [61] "grupo_edad" "año_not" "lugar_hecho"
## [64] "def_naturaleza" "parentezco_agresor" "barrio_nuevo"
## [67] "cod_comuna_nuevo" "comuna_nuevo" "cod_barrio_nuevo"
## [70] "municipio_nuevo"
```

Importante 1: Si se seleccionan las filas con registros totalmente completos se tiene una base de datos con **23835** filas.

Importante 2:

##	2016	2017	2018	2019	2020	2021	2022	2023
##	2	3739	9512	11368	7933	9414	11466	56

Si se filtran los casos que sucedieron a partir del 2017, quedaría una base con **53488**

Conversión a factor

Se convierten las columnas a factor a excepción de edad y fecha de notificación

Orden de las columnas

Se establece un nuevo orden en la base de datos para mayor facilidad en el proceso de análisis.

Base de datos depurada

Se guarda como base final la base sin filtrar por año y con los valores faltantes para implementar métodos de imputación

Resumen

1. Analizando la fecha del hecho se observó que la base original tiene registros de casos del 1900 al 2022. Mientras que los años de notificación van desde 2016 hasta 2023. Es decir que el periodo de tiempo que se menciona en la descripción de MEData corresponde es a los años de notificación. Se nombró la base final con 1900_2022 para identificar los casos por el año del hecho
2. Se filtró la base inicial por personas que se identifican como mujeres o mujer trans y que los casos hayan sido notificados en Medellín, Colombia.
3. **Variables que se re-codificaron:**
 - Lugar de residencia
 - grupo étnico
 - zona del cuerpo en caso de quemadura
 - convivencia con el agresor
 - lugar de notificación
 - atención integral en salud
 - condición final de la víctima
 - causa básica de defunción
4. **Variables que se re-calcularon:**
 - edad
 - edad agrupada

5. **Variables que se unificaron:**

- lugar de procedencia con lugar de ocurrencia
- ocupación y actividad de la víctima
- variables relacionadas al barrio, vereda, localidad, centro poblado donde ocurrió el hecho
- modalidad de violencia
- parentesco el agresor con la víctima

6. **Variables con inconsistencias o problemáticas:**

- todas las fechas
- variables relacionadas con la edad de la víctima
- edad del agresor
- orientación sexual

7. **Variables que NO están en fichas actuales:**

- estrato de la víctima
- hora del hecho
- edad del agresor

8. **Variables que se eliminaron:** *inventario variables*

9. **Variables que no se modificaron:**

- tipo de seguridad social
- pertenencia étnica
- hospitalización
- consumo SPA
- persona jefatura de hogar
- antecedente de violencia
- presencia de sustancias
- escenario y ámbito del hecho

10. La base de datos después de los filtros, tratar las variables, quitar columnas con 50% o más de valores faltantes y duplicados, quedó compuesta por **53490 filas**. Las columnas se especifican en *inventario variables*. En esta base están registros con algunos NA correspondientes a las columnas con valores faltantes menos del 50% y a la columna de semana de gestación

Nota 1: Se dejaron los NA de la semana de gestación porque toma valores en casos específicos y dado al tipo de dato no es posible asignar un valor característico a estos casos.

Nota 2: Esta es la base final que se guarda en data/interim

11. Quitando los registros mencionados en el ítem anterior, la base final quedaría con las mismas columnas pero **23835 registros completos**.

Nota 1: Los únicos NA que se encontrarían son los presentes en la columna mencionada

12. Si se filtran los casos que sucedieron a partir del 2017, quedaría una base con **53488**