

Depuración información del portal de datos públicos de Medellín (MEData).

2024-11-13

Contents

Información de la base de datos	2
Lectura de la base de datos	2
Depuración de la base de datos	2
Filtros	2
Clasificación del caso	3
Nacionalidad	3
Datos epidemiológicos	4
Fechas	5
Información de la víctima	6
Información del hecho	12
Información del agresor	14
Información de la atención/notificación	15
Valores faltantes	16
Registros duplicados	20
Conversión a factor	20
Orden de las columnas	21
Base de datos depurada	21
Resumen	21

Información de la base de datos

La base de datos, titulada *Vigilancia Integrada de la Violencia de Género*, está alojada en el portal MEData (Ver). Este recurso recopila información sobre los casos sospechosos de violencia de género ocurridos en Antioquia, los cuales fueron reportados al SIVIGILA.

- **Última actualización:** 20 de septiembre de 2023.
- **Información sobre las variables:** Adicional al diccionario que aparece en MEData, el formato de notificación al SIVIGILA contiene indicaciones sobre muchas de las variables (Ver).

Lectura de la base de datos

Depuración de la base de datos

La base de datos está conformada por 118 variables, sin embargo, se elimina las siguientes variables por no ser de relevancia para el análisis:

1. Nombre de la Unidad Primaria Generadora de Datos(**nom__upgd**)
2. Código y nombre del evento (**cod__eve - nom__eve**)
3. Código asignado en el SGSSS a los prestadores de servicios de salud que se hayan registrado en el ‘Registro Especial de Prestadores de Servicios de Salud’ (**cod__pre**)
4. Código asignado en el SGSSS a los prestadores de servicios de salud que indica sede ó territorio (**cod__sub**)
5. Código Administradora responsable de la atención del paciente, asignado por MSP (**cod__ase**)
6. Número del certificado defunción (**cer__def__**)
7. fecha efectiva de digitación del registro o realizar un ajuste a un registro previo (**fec__aju__**)
8. Número de registros (**nreg**) - Estado de transformación de la notificación (**estadotran**)
9. Fuerza (**fm__fuerza**) - Código de la Unidad Militar según tabla de Unidades Militares (**fm__unidad**)
10. Código de la Grado Militar según tabla de Grados Militares (**fm__grado**)
11. Contexto de la notificación, sus categorías son: notificación rutinaria, búsqueda, activa Institucional, vigilancia intensificada, búsqueda activa Comunitaria, investigaciones (**Fuente**)

Filtros

El diccionario de la base de datos indica que hay variables del país, departamento y municipio de procedencia y del hecho. Lo considera como variables separadas para cada uno. Sin embargo, en la ficha solo se tiene un campo con el siguiente nombre: **“Departamento y municipio de procedencia/ocurrencia”** e indica que se refiere al lugar donde posiblemente el paciente adquirió o al cual se atribuye la exposición al agente o factor de riesgo que ocasionó el evento.

Se comprobó que estas variables son totalmente iguales, se eliminan las variables denominadas como procedencia:

Ahora bien, dado que el interés son los casos de violencia en mujeres que ocurren en Colombia se filtra la base para analizar solo estos casos. Según el formato de notificación 2024 cuando la variable **identidad de**

género (**ident_gene**) es igual a 2 corresponde a mujer y cuando es igual a 4 corresponde a mujer trans. Mientras que la variable **país de ocurrencia del caso** (**cod_pais_o**) igual a 170 representa a Colombia.

```
data <- data %>% filter((ident_gene == 2 | ident_gene == 4) & cod_pais_o == 170)
```

Se obtiene un total de 55556 registros, descartando 26467.

Luego, como la mayoría de casos ocurrieron en Medellín, se filtra por este municipio.

```
data <- data %>% filter(cod_mun_o == 1 & cod_dpto_o == 5)
```

Se obtiene un total de 55427 registros, descartando 26596.

Nota: Al realizar este filtro se van registros con niveles 8 (no se ve en las fichas) y 11 (Violencia sexual en conflicto armado) en la variable **nat_viose**. En total son 8 registros.

Clasificación del caso

La variable clasificación inicial del caso (**tip_cas**) puede tomar los siguientes valores: 1 = Sospechoso, 2 = Probable, 3 = Confirmado por Laboratorio, 4 = Confirmado por Clínica, 5 = Confirmado por Nexo Epidemiológico.

```
##      1
## 55427
```

Todos los casos son sospechosos. Sin embargo, las variables seguimiento y clasificación final del caso (**ajuste**) indica que la clasificación de algunos casos cambiaron.

```
##      0      7  NA's
## 50586 4830    11
```

El valor de **7** indica que se modificó algún campo de la ficha, los únicos que no se pueden modificar son código de evento, Upgd, numero de id, fecha de notificación.

Luego, la variable clasificación final (**clasificación_final**) indica que 5 de los registros sospechosos terminaron siendo probables.

```
##      1      2
## 55422      5
```

Dado que estas variables nos indican que la mayoría de casos no cambian de estado y los que sí, cambian a un estado similar, se decide eliminarlas.

Nacionalidad

Se cuenta con el código (**nacionali**) y nombre de la nacionalidad (**nombre_nacionalidad**), que corresponde al estado o nación que pertenece la víctima según su documento de identificación.

##	Afganistán	Anguila
##	1	1
##	Antillas Neerlandesas	Bangladesh
##	1	3
##	Bélgica	Bosnia Y Herzegovina
##	2	7
##	Brasil	Camerún
##	1	1
##	Canadá	Colombia
##	1	34706
##	Comoras	Costa Rica
##	7	1
##	Croacia	Cuba
##	1	1
##	Ecuador	España
##	2	3
##	Estados Unidos De América	Federación De Rusia
##	8	1
##	Francia	Isla De Navidad
##	1	1
##	Madagascar	Malta
##	1	1
##	México	Montserrat
##	5	1
##	Myanmar	Países Bajos
##	1	1
##	Panamá	Perú
##	1	4
##	Reino Unido	República Centroafricana
##	1	2
##	República Democrática Del Congo	República Dominicana
##	1	1
##	Sudáfrica	Surinam
##	1	1
##	Uruguay	Venezuela
##	1	900
##	NA's	
##	19754	

Sin embargo, en la última variable el 35.64% de los casos son NA. Dado que es un porcentaje alto y no hay manera de relacionar con **nacionali__** porque tienen la misma cantidad de NA, se decide eliminarla.

Datos epidemiológicos

La variable **año** corresponde al año asociado a la semana epidemiológica.

##	2016	2017	2018	2019	2020	2021	2022
##	2	4051	9948	11555	8239	9749	11883

La variable **semana** corresponde a la semana epidemiológica.

##	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
----	---	---	---	---	---	---	---	---	---	----	----	----	----	----	----	----

```
## 1667 756 923 957 1022 1075 1099 1107 1156 1045 1170 1061 797 1162 925 927
## 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32
## 1025 1093 1192 1172 1147 1095 1017 1128 1105 1056 1097 1126 1057 1104 1082 1041
## 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48
## 1044 1001 1148 1097 1147 1136 1063 1140 979 895 949 1038 1091 1042 1078 1063
## 49 50 51 52 53
## 1016 1048 982 973 111
```

El **periodo** corresponde a cada 4 semanas completas del calendario epidemiológico. Son 13 periodos al año. Sin embargo, esta variable está tomando el valor de 16 en 876 registros

```
## 1 2 3 4 5 6 7 8 9 10 11 12 13 16
## 4303 4303 4432 2935 4482 4387 4384 4284 4290 4486 3861 4274 4130 876
```

Esos registros corresponden al año 2022. Analizando con el calendario de este año, no existe periodo 16 y el periodo para esas semanas es el periodo número 4.

Estas variables según definición no deben coincidir con el año, semana, periodo calendario. Sin embargo, dado que no necesariamente corresponden al momento en que se dio el evento, sino que puede ser el momento de notificación, se decide descartas. Teniendo también en cuenta que ya se cuenta con la fecha exacta en que sucedió el hecho para extraer la información que se necesite.

Fechas

El formato inicial es dd/mm/yyyy pero al convertir a objeto Date se cambia al formato por defecto: yyyy-mm-dd.

Notificación (fec_not)

Fecha en la que se está informando el evento al siguiente nivel por cualquier mecanismo, en especial para los eventos de notificación inmediata.

Consulta (fec_con_)

Fecha en la que consultó el paciente.

Inicio de síntomas (ini_sin_)

Fecha del primer día en que el paciente inició síntomas.

Hospitalización (fec_hos_)

Fecha en la que el paciente fue hospitalizado como consecuencia del evento.

Defunción (fec_def_)

Fecha en la que el paciente fallece como consecuencia del evento.

Nacimiento (fecha__nto__)

Hecho (fec__hecho)

Fecha en que ocurrió el hecho o evento.

Condiciones

El formato de notificación 2024 proporciona para la sistematización del caso una serie de condiciones que debe cumplirse en estas variables:

- La fecha de notificación debe ser mayor a la fecha del hecho.

174 registros no cumplen esta condición. Luego de descartarlos, se obtiene un total de 55253.

- La fecha de notificación debe ser mayor o igual a la fecha de inicio de síntomas y a la fecha de consulta.

25 registros no cumplen esta condición. Luego de descartarlos, se obtiene un total de 55228.

- La fecha de inicio de síntomas NO debe ser superior a la fecha de consulta.

3 registros no cumplen esta condición. Luego de descartarlos, se obtiene un total de 55225.

- La fecha de hospitalización NO puede ser inferior a la fecha de consulta, ni a la fecha de notificación.

3444 registros no cumplen esta condición. Luego de descartarlos, se obtiene un total de 51781.

- La fecha de nacimiento debe ser inferior a todas las demás fechas.

495 registros no cumplen esta condición. Luego de descartarlos, se obtiene un total de 51286.

Información de la víctima

Edad de la víctima (edad__,uni__med__,grupo__edad__ciclo,grupo__edad__quinque)

La edad de la víctima se registra en diferentes medidas (**uni__med**): años(1), meses(2), días(3), horas(4), minutos(5). Existen algunos casos donde la unidad de medida es 0, sin embargo, de acuerdo a la ficha de notificación 2024: “La unidad de medida 0=‘no aplica’, **solo puede ser utilizada para el evento 215 defectos congénitos**, cuando el diagnóstico se realiza prenatal”. Por lo tanto, se decide eliminar estos registros.

```
data <- data %>% filter(uni_med_ != 0)
```

Se eliminan 8 registros, quedando una base de datos de 51278. También se encuentra que para algunos registros la unidad de medida son incorrectas.

Las variables **edad__hecho** y **edad__notif** se calcularon como la diferencia en tiempo entre la fecha de nacimiento y la fecha del hecho y notificación, respectivamente, según la unidad de medida. Luego, si se compara la edad original con las edades calculadas la diferencia es evidente, demostrando que la unidad de medida es incorrecta.

##	uni_med_	edad_	edad_hecho	edad_notif	fecha_onto_	fec_hecho	fec_not
## 1	5	6	3172320	3548160	2012-01-22	2018-02-02	2018-10-21
## 2	5	1	879840	881280	2016-08-01	2018-04-04	2018-04-05
## 3	4	6	55176	60336	2011-09-16	2018-01-01	2018-08-04
## 4	4	9	6744	6768	2017-10-09	2018-07-17	2018-07-18
## 5	3	2	992	1083	2016-02-12	2018-10-31	2019-01-30

Luego, comparando la edad original, la edad al momento del hecho y al momento de notificación, se puede observar que en la edad original coincide con las otras dos porque sucedió y se notificó el evento el mismo día. O la edad coincide con la edad al momento de notificar

##	Ambas Inconsistencia	Notificación	NA's
##	34962	2191	4845
			9280

Los registros clasificados como inconsistencia, son registros donde la edad original no coincide con ninguna de las calculadas. Por ejemplo:

##	uni_med_	edad_	edad_hecho	edad_notif	fecha_onto_	fec_hecho	fec_not
## 1	3	3	1	1	2022-09-16	2022-09-17	2022-09-17
## 2	3	3	1	1	2022-09-16	2022-09-17	2022-09-17
## 3	3	15	11	11	2022-07-24	2022-08-04	2022-08-04
## 4	2	8	1	6	2020-07-27	2020-09-06	2021-02-15
## 5	3	28	5	26	2020-06-04	2020-06-09	2020-06-30

Teniendo en cuenta las inconsistencias mostradas, que se puede deducir que la edad corresponde a la edad al momento de notificación, y que el objetivo es prevenir, se decide calcular la edad en años al momento del hecho.

Sin embargo, 14196 registros parecen tomar fechas genéricas en la fecha de nacimiento (**fecha_onto_**) y además, tiene 9280 NA.

##	uni_med_	edad_	edad_hecho	edad_notif	fecha_onto_	fec_hecho	fec_not
## 1	1	55	10	10	2009-01-01	2019-03-31	2019-04-01
## 2	1	71	34	34	1985-01-01	2019-03-31	2019-04-01
## 3	1	18	14	14	2005-01-01	2019-03-30	2019-04-01
## 4	1	38	24	24	1995-01-01	2019-03-29	2019-04-01
## 5	1	22	27	27	1992-01-01	2019-03-24	2019-04-01

Mientras que la fecha del hecho (**fec_hecho**) tiene 0 NA y al parecer también tiene 2845 filas con fechas genéricas

##	uni_med_	edad_	fecha_onto_	fec_hecho	fec_not
## 1	1	13	2005-01-18	2018-01-01	2018-09-26
## 2	1	16	2006-08-14	2016-01-01	2022-11-05
## 3	1	13	2008-10-20	2022-01-01	2022-03-05
## 4	1	76	1945-12-09	1982-01-01	2022-03-05
## 5	1	14	2006-07-03	2020-01-01	2020-09-28

Por los valores faltantes no se podrían calcular la edad al momento del hecho para 9280 registros y las fechas genéricas podrían sesgar el calculo de la edad

Para manejar estas situaciones se decide:

- Dado que la edad original de la mayoría de registros con fechas genéricas fue registrada en años, si se tiene este caso y la diferencia entre la edad original y la edad calculada es mayor a 1, se conserva la edad original.
- Si la fecha de nacimiento es genérica o NA y la fecha del hecho y notificación es igual, se conserva la edad original pasada a años.

Finalmente, se reduce a 7438 registros con NA.

Edad agrupada (grupo_edad_quinque - grupo_edad_cliclo)

Se comprobó que estas variables tienen los cálculos erróneos para algunas filas, pues, al realizar el cálculo de forma manual de la edad desde la fecha de nacimiento hasta la fecha del hecho (o notificación), en ninguno de los dos casos, corresponde al grupo que se le asigna en cada una de estas variables. Así, resulta más óptimo eliminarlas, para también garantizar que sea acorde a la nueva edad calculada.

Los niveles de estas variables (grupo_edad_quinque y grupo_edad_cliclo) son:

##	0-4	10-14	15-19	20-24	25-29	30-34	35-39	40-44
##	3190	7206	4954	5911	6233	5021	3738	2629
##	45-49	5-9	50-54	55-59	60-64	65-69	70-74	75-79
##	1964	4106	1821	1501	1069	709	494	313
##	80 y más							
##	419							

##	0-5	12-17	18-28	29-59	6-11	60 y más
##	4036	8564	12662	17833	5179	3004

En la primera agrupación los rangos son de 4 edades mientras que en el último no son de igual longitud.

En los boletines del INMLCF se presentan los análisis con la edad agrupada también en rango de 4 edades a excepción de la edad 15-19 que se divide en dos rangos. (*Ejemplo*). Teniendo en cuenta esto, se decide agrupar la edad de igual manera que lo hace el INMLCF.

```
data <- data %>% mutate(
  grupo_edad = case_when(
    edad >= 0 & edad <= 4 ~ "0-4",
    edad >= 5 & edad <= 9 ~ "5-9",
    edad >= 10 & edad <= 14 ~ "10-14",
    edad >= 15 & edad <= 17 ~ "15-17",
    edad >= 18 & edad <= 19 ~ "18-19",
    edad >= 20 & edad <= 24 ~ "20-24",
    edad >= 25 & edad <= 29 ~ "25-29",
    edad >= 30 & edad <= 34 ~ "30-34",
    edad >= 35 & edad <= 39 ~ "35-39",
    edad >= 40 & edad <= 44 ~ "40-44",
    edad >= 45 & edad <= 49 ~ "45-49",
    edad >= 50 & edad <= 54 ~ "50-54",
    edad >= 55 & edad <= 59 ~ "55-59",
    edad >= 60 & edad <= 64 ~ "60-64",
    edad >= 65 & edad <= 69 ~ "65-69",
    edad >= 70 & edad <= 74 ~ "70-74",
    edad >= 75 & edad <= 79 ~ "75-79",
```



```

    edad >= 80 ~ "80 y más",
    TRUE ~ NA_character_
  )
)

```

Nota: Esta variable queda con valores faltantes porque está construida con la edad calculada que también generó valores faltantes.

Nombre del país de residencia (npais_resi)

Se cambia la estructura de escritura

Nombre del departamento de residencia (ndep_resi)

La variable presentaba errores de escritura en algunos nombres de departamentos, como la ausencia de tildes y nombres incompletos, estos errores fueron corregidos asegurando la consistencia de los nombres de los departamentos. Además, habían algunos niveles que representaban entidades por fuera de Colombia, como “COJEDES” (Venezuela) y “PANAMÁ” (Panamá), que fueron asignados como NA, al igual que el nivel de “DEPTO DESCONOCIDO”. Por último, los niveles que correspondían a ciudades específicas, como “BOGOTA”, “CARTAGENA” y “BARRANQUILLA”, fueron reemplazados por el nombre del departamento al que pertenecen.

Nombre del municipio de residencia (nmun_resi)

La variable presentaba inconsistencias en los nombres de los municipios. Se reemplazaron los niveles que no tenían un nombre específico de municipio o que eran desconocidos por NA, así como aquellos que correspondían a países o ciudades fuera de Colombia. Además, algunas filas correspondientes al municipio de Bogotá incluían nombres de barrios o localidades, por lo que se estandarizó asignando únicamente el nombre de la ciudad.

Nombre comuna de residencia

Esta variable sirve para imputar datos faltantes del municipio

Estrato (estrato_)

Esta variable es información de la ficha de datos básicos que se debe registrar para cualquier evento que se reporta al SIVIGILA. Sin embargo, se encontró una ficha del 2016 donde no se solicita y otra de 2019 donde sí, lo que puede explicar porqué la gran cantidad de NA

```

##      1      2      3      4      5      6  NA's
## 2864 10233 6091  387   90   71 31542

```

Sexo (sexo_)

```

##      F      M
## 50498  780

```

Orientación sexual (orient_sex)

De acuerdo a las fichas de notificación 2015-2022 y el diccionario de la base de datos, los niveles de esta variable son: homosexual(1),bisexual(2),heterosexual(5) y asexual(6). Sin embargo, esta variable también toma valor 3 y 4.

```
##      1      2      3      4      5      6
##    532    739    10   4240 44789    968
```

Al notificar un caso se llena una ficha de datos básicos y una ficha relacionada al evento. Ambas fichas en las versiones recientes piden la orientación sexual. Sin embargo, la clasificación en la ficha de datos tiene una codificación diferente: heterosexual(1), gay/lesbiana(2), bisexual(3) y otra(4). Para evitar cruces se reduce a dos categorías: Orientación Sexual, Identidad y expresiones de género no hegemónicas (OSIEG no Hegemónicas), y Heterosexual.

Ocupación de la víctima (ocupacion_)

De acuerdo al diccionario en MEData la codificación de está variable corresponde a la *Clasificación Única de Ocupaciones para Colombia (CUOC)*. El valor que toma el código puede ser hasta de 5 dígitos, cada dígito asigna un adicional de precisión sobre la ocupación. Por ejemplo, “25120” corresponde a desarrolladores de software mientras que “251” es desarrolladores y analistas de software y multimedia.

Sin embargo, algunos registros no tienen ningún tipo de relación con la codificación.

```
##      ocupacion_
## 1    99999.01
## 2          LIM
## 3    99999.01
## 4    99999.01
## 5    99999.01
## 6    99999.01
## 7    99999.01
## 8    99999.01
## 9          C1
```

Entonces se verifica que los valores tomados en esta variable se encuentran en la clasificación mediante la siguiente base de datos que contiene las 676 ocupaciones posibles (código de 5 dígitos) y en caso que el valor de la variable no coincida con los códigos posibles se convierte el valor a NA.

Esta variable queda con 45798 celdas vacías. Pero puede servir para completar información de los niveles 26 (Otro) y 33 (Ninguna) de la variable **actividad**. Es importante resaltar que esta variable se pide en la ficha de datos básicos mientras que actividad en la ficha del evento.

Actividad

Esta variable es numérica pero se cambia a string para hacer la relación con **ocupación**

```
##      13      15      24      26      28      29      30      31      32      33
##      17       1  9645 16387 1771   110    21  9661   139 13526
```

```
data <- data %>%
  mutate(
    actividad = case_when(
      actividad == 13 ~ "Líderes(as) cívicos",
      actividad == 15 ~ "Maestro(a)",
      actividad == 24 ~ "Estudiante",
      actividad == 26 ~ "Otro",
      actividad == 28 ~ "Trabajador(a) doméstico(a)",
      actividad == 30 ~ "Campesino/a",
      actividad == 29 ~ "Persona en situación de prostitución",
      actividad == 31 ~ "Persona dedicada al cuidado del hogar",
      actividad == 32 ~ "Persona que cuida a otras",
      actividad == 33 ~ "Ninguna"
    )
  )
```

Son 4200 registros con valor “Otro” o “Ninguna” en **actividad** y que tienen valor en **ocupación**. Para evitar tantas categorías, se extrae el primer dígito que representa los 10 grupos principales de ocupaciones:

```
ocupaciones <- c(
  "0" = "Fuerzas militares",
  "1" = "Directores y gerentes",
  "2" = "Profesionales, científicos e intelectuales",
  "3" = "Técnicos y profesionales del nivel medio",
  "4" = "Personal de apoyo administrativo",
  "5" = "Trabajadores de los servicios y vendedores de comercios y mercados",
  "6" = "Agricultores y trabajadores calificados agropecuarios,forestales y pesqueros",
  "7" = "Oficiales, operarios, artesanos y oficios relacionados",
  "8" = "Operadores de instalaciones y máquinas y ensambladores",
  "9" = "Ocupaciones elementales"
)
```

Algunas categorías se cambian a su nombre equivalente en la CUOC:

- Maestro(a) a Profesionales, científicos e intelectuales
- Trabajador(a) doméstico(a) a Trabajador(a) doméstico(a)” a “Ocupaciones elementales
- Campesino/a a Agricultores y trabajadores calificados agropecuarios,forestales y pesqueros

Grupo étnico (nom_grupo_)

Esta variable toma valor si la variable **Pertenencia étnica (per_etn_)** es igual a 1 (indígena), en caso contrario, se asigna “No aplica”.

Semanas de gestación (sem_ges_)

Esta variable toma valor si la variable **gp_gestan** es igual a 1 (Sí). Además, se verifica que dicho valor sea entre 1 y 45 ya que es lo esperado en tiempo de gestación.

Información del hecho

Área y barrio

##	area_	localidad_	bar_ver_	cen_pobla_	vereda_
## 1	1	MEDELLIN	POPULAR		
## 2	1	SD	LOPEZ DE MESA		
## 3	1	<NA>	CARPINELO		
## 4	1	<NA>	LLANADITAS		
## 5	1	<NA>	LA COLINA		
## 6	1	SANTA CRUZ	SANTA CRUZ		
## 7	1	MEDELLIN SANTO DOMINGO SAVIO NO1			
## 8	2			ROBLEDO	
## 9	2			BELLO	
## 10	1	MEDELLIN	BELEN		

Con respecto a las variables **bar_ver_**, **vereda_**, **localidad_** y **cen_pobla_**, estas corresponden a la ubicación donde ocurrieron los hechos de violencia. Según las fichas de SIVIGILA, su uso depende de la variable **área_**, que clasifica el lugar del hecho en: (1) Cabecera municipal, (2) Centro poblado o (3) Rural disperso.

Cada variable tiene la siguiente función:

- **bar_ver_**: Barrio dentro de una cabecera municipal.
- **vereda_**: Vereda en un área rural dispersa.
- **localidad_**: Localidad en municipios sectorizados (como Medellín o Bogotá).
- **cen_pobla_**: Centro poblado en áreas rurales.

Con el fin de estandarizar la información, y manejar los datos faltantes, se realizaron algunos ajustes:

1. Limpieza de datos: Se reemplazaron por NA los valores que indicaban falta de información, tales como “SIN INFORMACIÓN”, “NO REGISTRA”, “DESCONOCIDO”, valores vacíos, entre otros.
2. Unificación de variables:
 - Se creó una nueva variable que fusiona **localidad_** y **bar_ver_**, dado que ambas se utilizan únicamente cuando **área_** = 1 (cabecera municipal).
 - Se combinó **vereda_** y **cen_pobla_**, asignando **vereda_** cuando **área_** = 3 (rural disperso) y **cen_pobla_** cuando **área_** = 2 (centro poblado).
3. Completado de valores faltantes:
 - Si **bar_ver_** estaba vacío en un área urbana (**área_** = 1), se completó con **cen_pobla_**, en caso de que esta última tuviera información.
4. Creación de la variable **lugar_hecho**:
 - Si el área es cabecera municipal (1), se asigna **bar_ver_** y, si está vacío, se usa **localidad_** / **cen_pobla_**.
 - Si el área es centro poblado (2), se usa **cen_pobla_**.
 - Si el área es rural disperso (3), se usa **vereda_**.
 - Si no hay información disponible, se asigna NA.
5. Eliminación de variables innecesarias:
 - Se eliminaron las variables originales (**bar_ver_**, **localidad_**, **cen_pobla_**, **vereda_**) después de construir la variable **lugar_hecho**.

Hora del hecho

Esta variable no se solicita en las versiones recientes de la ficha, lo que explica los 0 registros con NA.

Modalidad de la violencia (naturaleza y nat_viosex)

De acuerdo a las fichas de notificación existen dos grupos de modalidad: violencia no sexual y violencia sexual, cada una con diferentes tipos. Si la víctima sufrió violencia no sexual se registra el tipo en la variable **naturaleza** y si sufrió violencia sexual se registra el tipo en la variable **nat_viosex**.

Por facilidad en el análisis y evitando la mayor cantidad de celdas vacías posibles, se decide unificar la información de ambas variables en una variable llamada **def_naturaleza**.

Mecanismo utilizado para la agresión

Esta variable tiene 25652 NA.

Se observa que en todos los casos de violencia física se utilizó un mecanismo. También en algunos casos de violencia psicológica, abandono y otras violencias sexuales.

##		1	2	3	4	11	12	13	14	15	16
##	1	985	334	15052	962	60	12	14	13	6293	12
##	2	0	0	9	23	10	0	0	0	1812	0
##	3	0	0	0	0	0	0	0	0	31	0
##	4	0	0	0	0	0	0	0	0	0	0
##	5	0	0	0	0	0	0	0	0	0	0
##	6	0	0	0	0	0	0	0	0	0	0
##	7	0	0	0	0	0	0	0	0	0	0
##	10	0	0	0	0	0	0	0	0	0	0
##	12	0	0	0	0	0	0	0	0	0	0
##	14	0	0	1	0	0	0	0	0	3	0

Se tiene 25652 registros con valores faltantes en esta variable.

##	1	2	3	4	5	6	7	10	12	14
##	778	7077	4207	6108	1441	3056	113	12	1675	1185

Entonces si se decide que los casos donde la violencia sea física, y tenga NA en armas se podrían cambiar a otro mecanismo (15). Pero para los otros casos no sabemos si se uso o no un arma como para poner “No aplica”.

Se recuperarían 778 NA al hacer esta asignación.

Quemaduras

En la base de datos, las variables relacionadas con quemaduras (por ejemplo, que_cara, que_cuello, etc.) solo contienen información relevante cuando la categoría de la variable armas corresponde a “Quemaduras por fuego o llama” (12), “Quemaduras por ácido, álcalis, o sustancias corrosivas” (13) y “Quemadura con líquido hirviente” (14). Sin embargo, en los casos en que no hay quemaduras, estas variables contienen valores faltantes (NA), lo que puede generar dificultades en los análisis. Entonces, se transforman los valores NA en una categoría explícita como “No aplica”.

Información del agresor

Sexo del agresor (sexo_agre)

Esta variable toma los valores de vacíos y de “SD” en algunos registros, por lo tanto, se cambia a NA. Teniendo en cuenta que “SD” de acuerdo a los formatos de notificación significan ausencia del dato.

Edad del agresor (edad_agre)

```
## [1] 0 2 14 61 35 25 27 99 40 17 21 63 8 33 28 45 24 16 38 29 22 36 32 18 64
## [26] 58 23 31 39 30 52 34 15 10 48 19 56 20 53 49 5 60 65 46 44 37 59 26 50 42
## [51] 9 43 6 78 12 70 54 11 62 55 13 71 69 57 66 79 68 41 47 7 82 81 85 51 80
## [76] 77 76 72 67 75 73
```

Se ve que esta variable (cuya unidad de medida es años), contiene edades de 0 y 2 años para el agresor, lo cual parece ser una inconsistencia en la variable. Además se encontró que es el 92.067% de los registros que presentan este problema y de acuerdo con las fichas de notificación de violencia disponibles, la única ficha que incluye la pregunta de la edad del agresor es en el año 2015.

Por tanto los valores de 0 y 2 podrían corresponder a valores faltantes de los años restantes de notificaciones en las que no se pregunta esto. Así, la variable tiene bastantes valores faltantes, por lo tanto es necesario eliminarla del análisis.

Nota: Hay registros que se notificaron con valor en esta variable hasta 2018.

Relación del agresor con la víctima (r_fam_vic)

```
## 3 9 10 22 23 24 25 NA's
## 1 3126 2980 13218 6003 10043 15905 2
```

Relación del agresor con la víctima: no familiar (r_nofiliar)

```
## 1 2 3 4 6 7 8 9 10 11 12 13 NA's
## 142 1510 170 271 4592 1210 2725 1743 6077 138 7 79 32614
```

Esta variable toma el valor de 9 en algunos registros, de acuerdo a las fichas encontradas con las que se notifican los casos de violencia, este código corresponde a la respuesta “Sin información” sobre la relación no familiar que existe entre la víctima y el agresor. Así, este nivel se convierte en NA.

Unión de las variables de relación con el agresor

Las variables **r_fam_vic** (relación familiar) y **r_nofiliar** (relación no familiar) contienen información relacionada con el parentesco entre la víctima y el agresor. Por lo tanto, resulta útil unificar esta información en una sola variable llamada **parentezco_agresor**, con el propósito de simplificar y organizar los datos para facilitar futuros análisis.

En la variable **r_fam_vic**, el nivel 25 (“Ninguno”) indica que no existe una relación familiar con el agresor, y tiene una cantidad bastante grande de datos, alcanza a sumar casi el total de datos que hay en la variable de relación no familiar exceptuando los NA. Entonces, es razonable asumir que el parentesco (en nivel “Ninguno”) podría corresponder a alguno de los niveles presentes en la variable **r_nofiliar**. Para realizar esta unificación de manera adecuada, fue necesario recodificar los niveles de ambas variables. Esto se hizo para evitar duplicados o combinaciones incorrectas, ya que algunos niveles podrían compartir nombres similares pero referirse a descripciones diferentes.

La unificación de las variables se realizó aplicando la lógica de:

- Si `r_fam_vic` tenía un valor válido distinto de “Ninguno”, se priorizó ese valor.
- Si `r_fam_vic` era “Ninguno”, se utilizó el valor correspondiente de `r_nofiliar`.
- En los casos donde ambas variables eran NA, el resultado final también se dejó como NA.

Este proceso, además permitió reducir los NAs, que en ambas variables sumaban un total de 34359, y después de la transformación se reducen a 1696 para la nueva variable. Finalmente, se eliminan las variables originales `r_fam_vic` y `r_nofiliar`.

```
##
##           Amigo(a) Compañero(a) de estudio Compañero(a) de trabajo
##           1510                271                170
##           Conocido(a)          Desconocido(a)          Ex_Pareja
##           2725                3567                6003
##           Familiar              Jefe                  Madre
##           10043                138                  2980
##           Otro                  Padre                 Pareja
##           4409                3126                13219
##           Profesor(a)          Sacerdote/Pastor        Servidor(a) público
##           142                  7                    79
##           Vecino(a)             <NA>
##           1210                1679
```

Convivencia con el agresor

Se convierte a NA los casos en que se representan la ausencia del datos con “ ”

Información de la atención/notificación

Mes de reporte caso (`mes_caso`)

Esta variable podría ser una variable candidata a eliminar, pues no nos arriesgamos a que existan inconsistencias entre la fecha y el mes. Además tenemos algunos (aunque pocos valores faltantes). Una mejor opción es calcularla manualmente con la variable de la fecha. Al igual que el año y la semana

Nombre del departamento de notificación (`ndep_noti`)

Se cambia la estructura de escritura de las categorías.

```
## [1] "ANTIOQUIA"      ""              "CALDAS"        "SUCRE"
## [5] "ATLANTICO"      "NORTE SANTANDER" "QUINDIO"       "SANTANDER"
## [9] "ARAUCA"        "NARIÑO"        "CORDOBA"       "VALLE"
## [13] "META"          "CUNDINAMARCA"  "RISARALDA"     "BOYACA"
```

Nombre municipio de notificación (`nmun_noti`)

```
## [1] "MEDELLIN"      "BELLO"         "ITAGUI"
## [4] ""              "ENVIGADO"      "MANIZALES"
## [7] "SAMPUES"       "COPACABANA"    "CALDAS"
```

## [10]	"BARRANQUILLA"	"CUCUTA"	"GIRARDOTA"
## [13]	"QUIMBAYA"	"BARBOSA"	"CARMEN DE VIBORAL"
## [16]	"LA ESTRELLA"	"ARMENIA"	"SINCELEJO"
## [19]	"SABANETA"	"APARTADO"	"ARAUCA"
## [22]	"CONCORDIA"	"GUARNE"	"PASTO"
## [25]	"ARANZAZU"	"LA UNION"	"AGUADAS"
## [28]	"HISPANIA"	"GUARANDA"	"SOLEDAD"
## [31]	"LA CEJA"	"LA DORADA"	"BUCARAMANGA"
## [34]	"CAREPA"	"TIERRALTA"	"RIONEGRO"
## [37]	"CALI"	"TAMESIS"	"AMALFI"
## [40]	"CHIGORODO"	"VILLAVICENCIO"	"CHIA"
## [43]	"PEREIRA"	"PUERTO BOYACA"	"LA VIRGINIA"
## [46]	"BOLIVAR"		

Atención integral en salud

Este grupo de variables corresponden a las atenciones en salud que se le realizaron a las víctimas. La atenciones relacionadas con profilaxis para VIH, HB, otras profilaxis, anticoncepción de emergencia, orientación IVE y recolección de evidencia medico legal solo se realizan en caso de violencias sexuales. Por lo tanto, en los casos que no son violencia sexual se asigna “No aplica” a las variables que las representa.

Condición final de la víctima al momento de la notificación (con_fin_)

Según los datos esta variable toma tres posibles valores: 0 = No sabe, no responde, 1 = Vivo, 2 = Muerto. Sin embargo, el formato de notificación 2024 indica que “0” solo aplica cuando se capte el caso por BAI (Brotos, Alertas e Incidencias) y se desconoce el dato, o para defectos congénitos cuando la unidad de medida es “0”. Dado que el evento de interés no es ninguno de los mencionados, se cambia los casos con “0” por NA.

Causa básica de defunción (cbmte_)

Esta variable corresponde al diagnóstico CIE-10 (Ver) que ocasionó la muerte de la víctima y que está relacionado con el evento de interés. Toma un valor si la variable **con_fin_** es igual a 2 (muerto), en caso contrario, se le asigna “No aplica” para no confundir con valores faltantes. Además, para los valores que no son un código válido se cambian a NA.

Valores faltantes

##	Column	total_na	total_empty	percent_na	percent_empty
## 1	hora_hecho	46553	0	90.79	0
## 2	lugar_hecho	39753	0	77.52	0
## 3	estrato_	31542	0	61.51	0
## 4	armas	25652	0	50.03	0
## 5	que_cara	25652	0	50.03	0
## 6	que_cuello	25652	0	50.03	0
## 7	que_mano	25652	0	50.03	0
## 8	que_pie	25652	0	50.03	0
## 9	que_pliegu	25652	0	50.03	0
## 10	que_genita	25652	0	50.03	0
## 11	que_tronco	25652	0	50.03	0
## 12	que_miesup	25652	0	50.03	0
## 13	que_mieinf	25652	0	50.03	0

## 14	cla_gra	25652	0	50.03	0
## 15	ext_que	25652	0	50.03	0
## 16	fecha_anto_	9280	0	18.10	0
## 17	edad	7438	0	14.51	0
## 18	grupo_edad	7438	0	14.51	0
## 19	zona_conf	5731	0	11.18	0
## 20	sexo_agre	5398	0	10.53	0
## 21	nombre_comuna	5193	0	10.13	0
## 22	npais_resi	3771	0	7.35	0
## 23	ac_anticon	3287	0	6.41	0
## 24	ac_ive	3287	0	6.41	0
## 25	sp_its	3099	0	6.04	0
## 26	prof_hep_b	3099	0	6.04	0
## 27	prof_otras	3098	0	6.04	0
## 28	evi_mlegal	3084	0	6.01	0
## 29	ini_sin_	3015	0	5.88	0
## 30	parentezco_agresor	1679	0	3.27	0
## 31	gp_mad_com	1496	0	2.92	0
## 32	gp_gestan	1436	0	2.80	0
## 33	ndep_notif	907	0	1.77	0
## 34	nmun_notif	907	0	1.77	0
## 35	gp_discapa	684	0	1.33	0
## 36	gp_desplaz	683	0	1.33	0
## 37	gp_carcela	682	0	1.33	0
## 38	gp_migrant	676	0	1.32	0
## 39	gp_pobicbf	678	0	1.32	0
## 40	gp_desmovi	676	0	1.32	0
## 41	gp_psiquia	676	0	1.32	0
## 42	gp_indigen	673	0	1.31	0
## 43	gp_vic_vio	667	0	1.30	0
## 44	nmun_resi	88	0	0.17	0
## 45	ndep_resi	50	0	0.10	0
## 46	cbmte_	35	0	0.07	0
## 47	gp_otros	29	0	0.06	0
## 48	con_fin_	29	0	0.06	0
## 49	nom_grupo_	24	0	0.05	0
## 50	fec_con_	11	0	0.02	0
## 51	escenario	5	0	0.01	0
## 52	area_	2	0	0.00	0
## 53	per_etn_	2	0	0.00	0
## 54	conv_agre	2	0	0.00	0
## 55	nombre_barrio	0	2	0.00	0

Con respecto a las variables **fec_hos_** y **fec_def_**, que toman un valor solo si la víctima fue hospitalizada o falleció, 1 registros no cuentan con un valor **fec_hos_** y 7 en **fec_def_**. En el caso de **sem_ges_** son 198 registros.

De acuerdo a lo anterior, son 504695 celdas NA y 2 celdas que fueron definidas como vacías poniendo “.”.

Para un total de 51278 registros con valores faltantes y celdas vacías, lo que corresponde al 100% de la base de datos. Sin embargo, como hay columnas relacionadas, algunas celdas de una columna pueden recibir un valor a partir de otra columna.

Relacionar información para rellenar campos vacíos

Variable nmun_resi a partir de nombre_comuna: todas las comunas están dentro de Medellín, entonces se llenan los valores vacíos de municipio con “Medellín” para aquellos que tienen información en comuna.

Variable npais_resi a partir de ndep_resi:

Variable ndep_resi a partir de nmun_resi y npais_resi:

```
##      npais_resi ndep_resi  nmun_resi
## 1      <NA>      <NA>    Medellín
## 2      <NA>      <NA>      <NA>
## 3      <NA>      <NA>    Medellín
## 4      <NA>      <NA>    Medellín
## 5      <NA>      <NA>    Medellín
## 6      <NA>      <NA>    Medellín
## 7      <NA>      <NA>      <NA>
## 8      España      <NA> Mun[España]
## 9      <NA>      <NA>      <NA>
## 10     <NA>      <NA>    Medellín
```

Vemos que únicamente es posible imputar el departamento de residencia para aquellas observaciones a las cuales se les conoce el país de residencia y todos resultan ser extranjeros, entonces se adapta la misma estructura Mun[País]

Variable npais_resi a partir de nmun_resi:

```
##      npais_resi ndep_resi nmun_resi
## 1      <NA> Antioquia      <NA>
## 2      <NA>      <NA>      <NA>
## 3      <NA>      <NA>      <NA>
## 4      <NA> Antioquia      <NA>
## 5      <NA>      <NA>      <NA>
## 6      <NA>      <NA>      <NA>
## 7      <NA> Antioquia      <NA>
## 8      <NA>      <NA>      <NA>
## 9      <NA>      <NA>      <NA>
## 10     <NA>      <NA>      <NA>
```

Variable armas a partir de que_., cla_gra y ext_que: No se puede porque no hay registros vacíos en armas que tenga algún valor en que_

Se puede observar que disminuyó la cantidad de celdas vacías.

```
##      Column total_na total_empty percent_na percent_empty
## 1      hora_hecho  46553          0      90.79            0
## 2      lugar_hecho  39753          0      77.52            0
## 3      estrato_     31542          0      61.51            0
## 4      armas       25652          0      50.03            0
## 5      que_cara     25652          0      50.03            0
```

## 6	que_cuello	25652	0	50.03	0
## 7	que_mano	25652	0	50.03	0
## 8	que_pie	25652	0	50.03	0
## 9	que_pliegu	25652	0	50.03	0
## 10	que_genita	25652	0	50.03	0
## 11	que_tronco	25652	0	50.03	0
## 12	que_miesup	25652	0	50.03	0
## 13	que_mieinf	25652	0	50.03	0
## 14	cla_gra	25652	0	50.03	0
## 15	ext_que	25652	0	50.03	0
## 16	fecha_anto_	9280	0	18.10	0
## 17	edad	7438	0	14.51	0
## 18	grupo_edad	7438	0	14.51	0
## 19	zona_conf	5731	0	11.18	0
## 20	sexo_agre	5398	0	10.53	0
## 21	nombre_comuna	5193	0	10.13	0
## 22	ac_anticon	3287	0	6.41	0
## 23	ac_ive	3287	0	6.41	0
## 24	sp_its	3099	0	6.04	0
## 25	prof_hep_b	3099	0	6.04	0
## 26	prof_otras	3098	0	6.04	0
## 27	evi_mlegal	3084	0	6.01	0
## 28	ini_sin_	3015	0	5.88	0
## 29	parentezco_agresor	1679	0	3.27	0
## 30	gp_mad_com	1496	0	2.92	0
## 31	gp_gestan	1436	0	2.80	0
## 32	ndep_notif	907	0	1.77	0
## 33	nmun_notif	907	0	1.77	0
## 34	gp_discapa	684	0	1.33	0
## 35	gp_desplaz	683	0	1.33	0
## 36	gp_carcela	682	0	1.33	0
## 37	gp_migrant	676	0	1.32	0
## 38	gp_pobicbf	678	0	1.32	0
## 39	gp_desmovi	676	0	1.32	0
## 40	gp_psiquia	676	0	1.32	0
## 41	gp_indigen	673	0	1.31	0
## 42	gp_vic_vio	667	0	1.30	0
## 43	cbmte_	35	0	0.07	0
## 44	gp_otros	29	0	0.06	0
## 45	con_fin_	29	0	0.06	0
## 46	ndep_resi	32	0	0.06	0
## 47	nmun_resi	32	0	0.06	0
## 48	nom_grupo_	24	0	0.05	0
## 49	npais_resi	17	0	0.03	0
## 50	fec_con_	11	0	0.02	0
## 51	escenario	5	0	0.01	0
## 52	area_	2	0	0.00	0
## 53	per_etn_	2	0	0.00	0
## 54	conv_agre	2	0	0.00	0
## 55	nombre_barrio	0	2	0.00	0

Luego de rellenar las celdas vacías a partir de información relacionada queda un total de 51278 registros con celdas vacías, lo que corresponde al 100% de la base de datos. Es decir, se pueden utilizar 0 registros completos.

Ahora, algunas variables tienen más del 50% de los registros con celdas vacías, ya sea porque no se registró la información o porque esa variable no es considerada en todas las fichas de notificación del SIVIGILA. Como es el caso de **edad agresor**, **estrato__**, y **hora del hecho** que según lo investigado no se piden en fichas recientes.

Nota: La edad del agresor aparece hasta la ficha 2015 pero en esta base de datos hay valores para los años de ocurrencia hasta el 2018.

Esas variables son:

```
## [1] "hora_hecho" "lugar_hecho" "estrato_" "armas" "que_cara"
## [6] "que_cuello" "que_mano" "que_pie" "que_pliegu" "que_genita"
## [11] "que_tronco" "que_miesup" "que_mieinf" "cla_gra" "ext_que"
```

Al eliminar estas variables, se obtiene una base de datos con **49609 registros**.

Registros duplicados

```
## [1] 359
```

Finalmente, al eliminar los registros duplicados se obtiene una base de datos depurada con **49250 registros**. y las siguientes variables:

```
## [1] "fec_not" "sexo_" "area_"
## [4] "tip_ss_" "per_etn_" "nom_grupo_"
## [7] "gp_discapa" "gp_desplaz" "gp_migrant"
## [10] "gp_carcela" "gp_gestan" "sem_ges_"
## [13] "gp_indigen" "gp_pobicbf" "gp_mad_com"
## [16] "gp_desmovi" "gp_psiquia" "gp_vic_vio"
## [19] "gp_otros" "fec_con_" "ini_sin_"
## [22] "pac_hos_" "fec_hos_" "con_fin_"
## [25] "fec_def_" "fecha_anto_" "cbmte_"
## [28] "actividad" "orient_sex" "ident_gene"
## [31] "consum_spa" "mujer_cabf" "antec"
## [34] "sust_vict" "sexo_agre" "conv_agre"
## [37] "zona_conf" "fec_hecho" "escenario"
## [40] "ambito_lug" "sp_its" "prof_hep_b"
## [43] "prof_otras" "ac_anticon" "ac_ive"
## [46] "ac_mental" "remit_prot" "inf_aut"
## [49] "evi_mlegal" "npais_resi" "ndep_resi"
## [52] "nmun_resi" "ndep_notif" "nmun_notif"
## [55] "nombre_barrio" "nombre_comuna" "edad"
## [58] "grupo_edad" "def_naturaleza" "parentezco_agresor"
## [61] "semana_hecho" "mes_hecho" "año_hecho"
```

Importante: Si se seleccionan las filas con registros totalmente completos se tiene una base de datos con **24394 filas**.

Conversión a factor

Se convierten las columnas a factor a excepción de edad, semana del hecho, y fechas.

Orden de las columnas

Se establece un nuevo orden en la base de datos para mayor facilidad en el proceso de análisis.

Base de datos depurada

Resumen

1. Se filtró la base inicial por personas que se identifican como mujeres o mujer trans y que los casos hayan ocurrido en Medellín, Colombia.
2. **Variables que se re-codificaron:**
 - Lugar de residencia
 - grupo étnico
 - zona del cuerpo en caso de quemadura
 - convivencia con el agresor
 - lugar de notificación
 - atención integral en salud
 - condición final de la víctima
 - causa básica de defunción
3. **Variables que se re-calcularon:**
 - edad
 - edad agrupada
4. **Variables que se unificaron:**
 - lugar de procedencia con lugar de ocurrencia
 - ocupación y actividad de la víctima
 - variables relacionadas al barrio, vereda, localidad, centro poblado donde ocurrió el hecho
 - modalidad de violencia
 - parentesco el agresor con la víctima
5. **Variables con inconsistencias:**
 - todas las fechas
 - variables relacionadas con la edad de la víctima
 - edad del agresor
6. **Variables que NO están en fichas actuales:**
 - estrato de la víctima
 - hora del hecho
 - edad del agresor
7. **Variables que se eliminaron:** *inventario variables*

8. **Variables que no se modificaron:**

- tipo de seguridad social
- pertenencia étnica
- hospitalización
- consumo SPA
- persona jefatura de hogar
- antecedente de violencia
- presencia de sustancias
- escenario y ámbito del hecho

9. La base de datos después de los filtros, tratar las variables, quitar columnas con 50% o más de valores faltantes y duplicados, quedó compuesta por **49250 filas**. Las columnas se especifican en *inventario variables*. En esta base están registros con algunos NA correspondientes a las columnas con valores faltantes menos del 50% y a las columnas de semana de gestación, fecha de defunción y fecha de hospitalización.

Nota: Se dejaron los NA de estas tres variables porque toman valores en casos específicos y dado al tipo de dato no es posible asignar un valor característico a estos casos.

10. Quitando los registros mencionados en el ítem anterior, la base final quedaría con las mismas columnas pero **24394 registros completos**.

Nota: Los únicos NA que se encontrarían son los presentes en las tres columnas mencionadas.