

Depuración información reportada al SIVIGILA desde 2013 hasta 2023.

2025-07-02

Contents

Información de la base de datos	2
Lectura de la base de datos	2
Depuración de la base de datos	2
Filtros	3
Identificador (no obligatoria)	6
Clasificación del caso	6
Fechas	7
Información de la víctima	9
Información del hecho	23
Información del agresor	36
Información de la atención	37
Valores faltantes	46
Registros duplicados	51
Conversión a factor	52
Orden de las columnas	52
Base de datos depurada	52
Resumen	52

Información de la base de datos

Este reporte describe la depuración realizada a la información proporcionada por el Instituto Nacional de Salud de Colombia sobre los casos sospechosos o probables de violencia de género que fueron reportados al SIVIGILA durante 2013 y 2024.

- **Información sobre las variables:** se cuenta con un diccionario de datos que enviaron junto a las bases (Ver aquí). Este diccionario tiene variables de todos los eventos notificados al SIVIGILA, por lo tanto, el diccionario solo con las variables de interés se encuentra en *data/raw/SIVIGILA/diccionario_red.pdf*. Adicional, se cuenta con algunas de las fichas de notificación al SIVIGILA que contienen indicaciones sobre muchas variables, la más actualizada es la ficha de 2024 (Ver aquí).

Lectura de la base de datos

Los archivos originales enviados por el Instituto Nacional de Salud están en formato *xlsx*, sin embargo, dado su tamaño la memoria puede llenarse más fácilmente si se lee cada uno en este formato entonces se leyeron y guardaron en formato *rds*, asignando de una vez el tipo de dato a cada columna

La composición de las bases de datos es la siguiente:

```
## # A tibble: 11 x 3
##   year  n_columnas n_filas
##   <chr>      <int>   <int>
## 1 2013         105   42808
## 2 2014         106   61818
## 3 2015         106   72601
## 4 2016         105   93614
## 5 2017         111   98999
## 6 2018         133  109699
## 7 2019         144  118469
## 8 2020         144  103207
## 9 2021         115  116302
## 10 2022         113  140694
## 11 2023         113  158313
```

Se utiliza la función `clean_names()` del paquete **janitor** para limpiar y estandarizar los nombres de las variables de la base de datos. Esto con el fin de facilitar la manipulación de los datos y garantizar una estructura consistente para aplicar la misma lógica de depuración utilizada en la base de datos de MEDData. Luego, se cambia el tipo de las variables y se unen todas las bases.

Depuración de la base de datos

La base de datos resultante está conformada por 195 variables, sin embargo, se elimina las siguientes variables por no ser de relevancia para el análisis o no identificar que representan:

1. Nombre de la Unidad Primaria Generadora de Datos (**nom_upgd - nombre_upgd**)
2. Código y nombre del evento (**-cod_eve - evento - nombre_evento - cod_eve_old**)
3. Código asignado en el SGSSS a los prestadores de servicios de salud que se hayan registrado en el 'Registro Especial de Prestadores de Servicios de Salud' (**cod_pre**)

4. Código asignado en el SGSSS a los prestadores de servicios de salud que indica sede ó territorio (**cod_sub**)
5. Código Administradora responsable de la atención del paciente, asignado por MSP (**cod_ase**)
6. Número del certificado defunción (**cer_def**)
7. Fecha efectiva de digitación del registro o realizar un ajuste a un registro previo (**fec_aju**)
8. Número de registros (**nreg**)
9. Fuerza (**fm_fuerza**) - Código de la Unidad Militar según tabla de Unidades Militares (**fm_unidad**)
10. Código de la Grado Militar según tabla de Grados Militares (**fm_grado**)
11. Para uso interno. Versión del SIVIGILA con la que fue grabado o actualizado el registro (**version**)
12. Contexto de la notificación, sus categorías son: notificación rutinaria, búsqueda, activa Institucional, vigilancia intensificada, búsqueda activa Comunitaria, investigaciones (**Fuente**)
13. Estado de transformación de la notificación (**estadotran**)
14. No se identifican en el diccionario de datos o fuentes de información: **fec_arc_xl**, **confirmados**, **va_sispro**, **esc_vict**, **esc_agre**, **fact_preci**, **vulnerab**, **otro_vuln**, **grupos**, **otro_grup**, **sust_intx**, **canal_pers**, **tcampo**, **concat**, **calculo**, **consecutive_origen**, **est_f_caso**, **estado_final_de_caso**, **nom_est_f_caso**, **remit_aut**, **remit_just**, **grup_pob**, **sust_agr**, **sp_psic**
15. Las bases de datos del 2018, 2019 y 2020 contenían un conjunto de variables nombradas con el siguiente patrón x[#], en las cuales la mayoría de filas son NA. Dado que tampoco se logra identificar que representan, se eliminan.

Ahora bien, la variable **fecha_hora** solo aparecen en la base del 2021, toma como valor solo fechas, en ningún registro coincide con **fec_hecho** y tampoco sirve para completarla porque no hay registros donde tome valor y **fec_hecho** no. Por ende, se decide eliminarla. Al igual que, **inf_pac_ma**, **esc_agre**, **aten_medic** y **otra_asp**, que están presentes solo en la base de 2013. Y, **pob_lgtbi** que está presente solo en las bases de 2015, 2016 y 2017. Esta última variable se elimina dado a que en la ficha de estos años se preguntaba si pertenecía a esta población pero desde la ficha de 2018 se pregunta directamente por la orientación sexual e identidad de género.

Así, queda una base de datos de 1116524 filas y 113 columnas.

Filtros

Dado que el interés del estudio se centra en los casos de violencia en mujeres que ocurren en Colombia, se filtra la base por sexo o identidad de género femenino y lugar de ocurrencia.

Sexo

Esta variable se pide en la ficha de notificación de todos los años

```
##          F          M
## 878502 238022
```

Identidad género

Se sabe que al notificar un caso se debe llenar una ficha de datos básicos y una ficha específica del evento a notificar. De acuerdo a las fichas a las que se tiene acceso, esta variable aparece en la ficha de datos básicos luego del 2022 y en la ficha específica del evento a partir del año 2017 (inclusive). Su estructura es:

- **Ficha básica:** hombre (1), mujer (2), hombre trans (3), mujer trans (4), otra (5)
- **Ficha específica:** masculino (1), femenino (2), transgénero (3)

Año	Identidad género	Cantidad	Año__	Identidad género__	Cantidad__
2013	NA	42711	2020	2	80769
2014	NA	60270	2020	3	171
2015	NA	72407	2020	31	1
2016	NA	93844	2020	3108621882	1
2017	1	18472	2020	3142332301	1
2017	2	65217	2020	3209624163	1
2017	3	177	2020	44045	1
2017	4	310	2020	5	3
2017	5	924	2020	NA	6
2017	NA	13621	2021	1	23405
2018	1	21880	2021	2	92299
2018	2	87365	2021	3	143
2018	3	172	2021	9	2
2018	4	8	2022	1	29624
2018	43537	1	2022	2	112516
2018	5	21	2022	3	164
2018	NA	296	2023	1	32727
2019	1	24396	2023	2	124709
2019	2	95629	2023	3	190
2019	3	177	2024	1	165
2019	5	19	2024	2	520
2019	NA	1	2024	3	2
2020	1	21186	NA	NA	NA

Sin embargo, se puede observa que para años anteriores al 2022, la variable está tomando valores de 5 o 4. Tratando de tener consistencia con las fichas y de contar con la mayor cantidad posible de registros, se seleccionan los siguientes casos:

- Los casos notificados desde 2013-2016 y que el sexo sea femenino
- Los casos notificados desde 2017-2022 donde la víctima se identifique como mujer o sea de sexo masculino y se identifique como transgénero
- Los casos notificados en 2023-2024 y las víctimas se identifiquen como mujer o mujer trans
- Los casos donde no se conoce como se identifica la víctima pero que sea de sexo mujer

De esta manera, se pasaría de una base de 1116524 filas a 881459 filas.

Nota: Si se consideran los casos antes del 2023 donde `ident_gene == 4` se rescatarían solo 318 registros más.

País de ocurrencia

En cuanto a la información sobre el país de ocurrencia del hecho, se encuentran las siguientes variables:

- **cod_pais_o**
- **pais_ocurrencia**
- **npais_proce**

```
## # A tibble: 10 x 3
##   Año pais_ocurrencia      n
##   <dbl> <chr>          <int>
## 1  2013 <NA>           34319
## 2  2014 <NA>           48300
## 3  2015 <NA>           56721
## 4  2016 <NA>           72093
## 5  2017 <NA>           75712
## 6  2018 <NA>           87644
## 7  2019 <NA>           95682
## 8  2020 <NA>           80826
## 9  2021 <NA>           92346
## 10 2022 <NA>            1293
```

La variable **pais_ocurrencia** solo aparece en 2023 mientras que el **cod_pais_o** (código del país de ocurrencia) está presente para todos los años sin ningún valor NA.

```
##   032   068   076   120   132   152   170   174   188   192   214
##    1     1    53     1     1    20 878359     2     2     1     7
##  218   222   249   250   266   276   300    32   320   348   36
##  140     3     2     1     1     3     4     3     1     1     1
##  376   380   392     4   410   417   422   474   480   484   50
##    1     3     1     2     1     1     1     1     1    13     1
##  531   533   540    56   580   591   604   634   643    68   682
##    1     1     1     1     1    13    52     1     1     4     1
##  686    70   710   724   756    76   784   792   826   840   850
##    2     1     1    28     1   107     1     3     2    24     1
##   862   882
##  2576     1
```

Dado esto, se decide filtrar la base de datos para aquellos casos donde el valor de **cod_pais_o** sea igual a 170, lo que representa a Colombia.

Además, se encuentra que, aunque la mayoría de los casos corresponden a Colombia, existen algunos valores de **npais_proce** que corresponden a Venezuela y valores NA. Aunque la cantidad de casos fuera de Colombia es baja, se decide eliminar también estos registros para mantener la consistencia en la variable de ocurrencia, asegurando que solo se incluyan casos de Colombia.

```
##   COLOMBIA VENEZUELA    NA's
##    92313         13   786033
```

Así, luego de estas dos acciones se pasaría de una base de 881459 filas a 878346 filas. Como todos los casos corresponden a reportes hechos en Colombia, se eliminan las tres variables relacionadas pues no tienen variabilidad entre ellas.

Identificador (no obligatoria)

Esta variable no aparece en el diccionario de datos pero se asume por nombre que corresponde a la variable **NUM_CON** del diccionario y la cual corresponde a: “Se asigna un valor consecutivo para cada reporte generado por la misma UPGD en la misma semana por evento”. Al analizar si tiene valores repetidos se encontró que hay 0 registros con este valor repetido en la base. Por ende, se podría tomar como un identificador del registro en caso de ser necesario

Clasificación del caso

La variable clasificación inicial del caso (**tip_cas_**) puede tomar los siguientes valores: 1 = Sospechoso, 2 = Probable, 3 = Confirmado por Laboratorio, 4 = Confirmado por Clínica, 5 = Confirmado por Nexo Epidemiológico.

Nota: esta variable es obligatoria

```
##          1          2    NA's
## 878329      11         6
```

La mayoría de casos son sospechosos. Y solo 11 de ellos resultan como probables. Lo que indica que todos los casos fueron detectados de forma oportuna. Se evalúa la variable de seguimiento del caso (**ajuste**) para estudiar el comportamiento del proceso, pues se ve que algunos casos cambiaron:

```
##          0          2          6          7    9996    9997    NA's
## 714265      2          3 164072          1          1          2
```

Esta variable no obligatoria, se registra posterior de obtener resultados de laboratorio o análisis del caso y toma los valores de:

- 0 = No aplica (es el valor por defecto del sistema si el caso es nuevo o no ha sido ajustado)
- 3 = Confirmado por laboratorio
- 4 = Confirmado por clínica
- 5 = Confirmado por nexo epidemiológico
- 6= Descartado: indica que los casos fueron descartados, entonces no son estudio de violencia de género, por tanto se descartan de la base de datos.
- 7= Otra actualización:indica que se modificó algún campo de la ficha, los únicos que no se pueden modificar son código de evento, Upgd, numero de id, fecha de notificación.
- D = Descarte por error de digitacion

Dado lo anterior, y que el estado final del caso no brinda información adicional relevante para el análisis, se elimina los registros que fueron descartados y estas dos variables

```
##          0          7    NA's
## 714265 164072         6
```

Nota: En la base de datos de MEData aparece la variable **clasificación final** pero en esta base no, el diccionario indica que **ajuste** corresponde a seguimiento y clasificación final del caso, o sea, que indica también el estado final del caso.

Finalmente, se continua con una base de datos de 878343

Fechas

Se cuenta con las siguientes fechas:

- **Fecha de notificación (fec_not):** fecha en la que se está informando el evento al siguiente nivel por cualquier mecanismo, en especial para los eventos de notificación inmediata. **Obligatoria**
- **Consulta (fec_con):** fecha en la que consultó el paciente. **Según ficha 2024 Obligatoria pero en diccionario no**
- **Inicio de síntomas (ini_sin):** fecha del primer día en que el paciente inició síntomas. **Según ficha 2024 Obligatoria pero en diccionario no**
- **Hospitalización (fec_hos):** fecha en la que el paciente fue hospitalizado como consecuencia del evento. **Según ficha 2024 Obligatoria pero en diccionario no**
- **Defunción (fec_def):** fecha en la que el paciente fallece como consecuencia del evento. **Según ficha 2024 Obligatoria pero en diccionario no**
- **Nacimiento (fecha_nto):** fecha de nacimiento de la paciente. **No obligatoria**
- **Hecho (fec_hecho):** fecha en que ocurrió el hecho o evento. **Obligatoria**

A continuación, se presenta la composición de estas variables:

##	total_NA	fecha_min	fecha_max
## fec_not	"0"	"2013-01-01"	"2024-03-27"
## fec_con	"22"	"2007-01-01"	"2023-12-30"
## ini_sin	"59194"	"1900-01-06"	"2023-12-30"
## fec_hos	"747422"	"1900-01-02"	"2023-12-30"
## fec_def	"877520"	"1900-01-02"	"2023-12-28"
## fecha_nto	"18533"	"1900-01-02"	"2023-12-28"
## fec_hecho	"162"	"1899-12-30"	"2023-12-30"

Se observa que a pesar de que hay varias obligatorias, la única columna fecha que no tiene valores faltantes es **fec_not**. Además, las fechas con menor cantidad es **fec_con** y **fec_hecho**. Por lo tanto, se decide continuar el análisis con estas tres variables. Teniendo en cuenta también que las demás brindan la fecha de situaciones no tan relevantes para el interés del análisis o que se puede obtener su información desde otra variable, como es el caso de **fecha_nto** con edad de la víctima.

En estas tres fechas se encontró una gran cantidad de casos donde el mes es enero y el día 1:

```
## $fec_hecho
## [1] 12748
##
## $fec_con
## [1] 2896
##
## $fec_not
## [1] 2064
```

Puede ser que en muchos casos si hayan sucedido ese día del año pero revisando las bases originales, algunos de estos casos (pocos) corresponden a valores inconsistentes que tomaba el registro (números únicos o letras) y que al pasar a formato date se convirtieron en una fecha tipo [año]-01-01. **En la única fecha donde no pasa esto es en fec_not**. Entonces para revisar la cantidad verdadera de casos donde las fechas no parecen consistentes se calcula lo siguiente:

- Cantidad de registros donde **fec_hecho** es [año]-01-01 y no coincide con **fec_not**, porque si coinciden puede indicar que realmente sucedió y se notificó ese día del año

```
## [1] 11096
```

- Cantidad de registros donde **fec_not** es [año]-01-01 y no coincide con **fec_hecho**, porque si coinciden puede indicar que realmente sucedió y se notificó ese día del año

```
## [1] 409
```

- Cantidad de registros donde **fec_con** es [año]-01-01

```
## [1] 2896
```

Ahora bien, dado que se trata de cantidades pequeñas a comparación del total de registros, se decide continuar con estas variables, pero garantizando que tomen valores lógicos entre ellas para quitar el posible sesgo. Es por ello que se realizan las siguientes verificaciones según las indicaciones del diccionario de datos y fichas de notificación:

- La fecha del hecho debe ser anterior o igual a la fecha de consulta. Se encontraron 1042 casos que no cumplen esta condición. Por ejemplo:

```
## # A tibble: 10 x 4
##   fec_hecho fec_con   fec_not     n
##   <date>    <date>   <date>   <int>
## 1 2018-11-06 2018-11-01 2018-11-21     1
## 2 2020-11-29 2020-11-27 2020-11-30     1
## 3 2018-10-04 2018-10-03 2018-10-03     1
## 4 2019-11-18 2019-09-05 2019-11-18     1
## 5 2019-11-14 2019-11-12 2019-11-14     1
## 6 2020-10-09 2020-10-08 2020-10-08     1
## 7 2019-12-18 2019-12-17 2019-12-18     6
## 8 2016-06-12 2016-06-11 2016-06-11     1
## 9 2018-06-19 2018-06-01 2018-06-19     2
## 10 2019-11-01 2019-10-28 2019-11-01     1
```

Se eliminan estos registros quedando una base de 877301

- La fecha de consulta debe ser anterior o igual a la fecha de notificación. Se encontraron 10 casos que no cumplen esta condición

```
## # A tibble: 10 x 4
##   fec_hecho fec_con   fec_not     n
##   <date>    <date>   <date>   <int>
## 1 2013-01-01 2014-02-19 2013-02-19     1
## 2 2013-01-06 2014-02-25 2013-02-25     1
## 3 2013-02-11 2014-02-11 2013-02-11     1
## 4 2013-10-01 2014-02-25 2013-02-25     1
## 5 2013-11-16 2013-11-17 2013-11-16     1
## 6 2013-12-03 2014-02-08 2013-02-08     1
## 7 2014-01-04 2014-01-04 2013-01-04     1
## 8 2014-01-13 2014-02-12 2013-02-12     1
## 9 2014-02-06 2014-02-06 2013-02-06     1
## 10 2014-02-09 2014-02-09 2013-02-09     1
```

Se eliminan estos registros quedando una base de 877291

Información de la víctima

Edad de la víctima (obligatoria)

La edad de la víctima se registra en diferentes medidas (**uni_med**): años(1), meses(2), días(3), horas(4), minutos(5). Existen algunos casos donde la unidad de medida o la edad son 0:

```
## # A tibble: 3 x 5
##   uni_med edad con_fin origen    n
##   <chr>   <dbl> <chr>   <chr> <int>
## 1 0         0 1      2013    11
## 2 0         0 1      2014     3
## 3 0         0 1      2018    11
```

El diccionario de datos indica que se registra 0 en la edad solo para mortinatos o evento In Utero y en estos casos, debe asignarse por defecto en unidad de medida el mismo valor (cero). Además, la ficha de notificación 2024 agrega: “La unidad de medida 0=‘no aplica’, **solo puede ser utilizada para el evento 215 defectos congénitos**, cuando el diagnóstico se realiza prenatal”.

Dado esta inconsistencia en la información y el interés del estudio, se eliminan 25 estos registros, quedando una base de datos de 877266, donde la distribución de la edad es:

```
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   1.00  13.00   22.00   24.38  33.00  131.00
```

Luego, también se encuentra que para algunos registros la unidad de medida son incorrectas.

Para evidenciarlo se calculan las variables **edad_hecho** y **edad_notif** que son la diferencia en tiempo entre la fecha de nacimiento y la fecha del hecho y notificación, respectivamente, según la unidad de medida. Luego, si se compara la edad original con las edades calculadas la diferencia es evidente, demostrando que la unidad de medida es incorrecta. Por ejemplo:

```
## # A tibble: 10 x 7
##   uni_med edad edad_hecho edad_notif fecha_nto fec_hecho fec_not
##   <chr>   <dbl>   <dbl>   <dbl> <date>   <date>   <date>
## 1 2         9       35       35 2013-04-06 2016-03-29 2016-04-01
## 2 2         2       23       23 2013-08-18 2015-08-17 2015-08-18
## 3 2         4       56       56 2011-11-22 2016-07-31 2016-07-31
## 4 5         5         0      5760 2017-06-11 2017-06-11 2017-06-15
## 5 2         3       40       41 2014-06-18 2017-11-13 2017-12-05
## 6 2         1       29       29 2012-09-14 2015-02-15 2015-02-21
## 7 2         2       25       25 2014-12-08 2017-01-31 2017-01-31
## 8 2         1       19       19 2016-02-28 2017-10-06 2017-10-10
## 9 2         3       45       45 2013-01-24 2016-10-31 2016-10-31
## 10 2         6       77       77 2012-02-15 2018-07-19 2018-07-19
```

Dado que estos registros corresponden al 1.28% de la base de datos y volver a calcular la edad como la diferencia entre fecha nacimiento y fecha notificación o hecho, no es totalmente confiable por lo que se vio anteriormente, se decide conservar la edad que se registra en las bases y eliminar estos registros con inconsistencias

Se eliminan 112 registros, quedando una base de datos de 877154, donde la distribución de la edad es:

```
##   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   1.00  13.00   22.00   24.38  33.00  131.00
```

Luego, para un mejor manejo se pasa la edad original a años, donde la distribución de la edad es:

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      0.00   13.00   22.00   24.22   33.00   131.00
```

Nacionalidad (no obligatoria)

Se cuenta con el código (**nacionalidad**) y nombre de la nacionalidad (**nombre_nacionalidad**), que corresponde al estado o nación que pertenece la víctima según su documento de identificación.

Sin embargo, 391241 registros tienen información faltante en ambas variables, lo que corresponde a un 44.6% de la base de datos. A pesar de este porcentaje, se decide continuar con esta variable

Lugar de residencia

Según el diccionario de datos, las variables relacionadas al código DIVIPOLA de departamento y municipio son obligatorias

País: se cuenta con el código y el nombre del país donde reside la víctima al momento de la notificación. Por ejemplo:

```
## # A tibble: 10 x 3
##   cod_pais_r pais_residencia      n
##   <chr>      <chr>          <int>
## 1 768        TOGO              1
## 2 175        MAYOTTE             1
## 3 308        GRANADA              8
## 4 <NA>      <NA>          641409
## 5 484        MÉXICO              1
## 6 152        CHILE                1
## 7 32         ARGENTINA             2
## 8 760        REPÚBLICA ÁRABE SIRIA   2
## 9 862        VENEZUELA            34
## 10 706       SOMALIA              1
```

A pesar de tener tantos registros con valores faltantes en ambas variables, se comprobó que pueden ser llenados con información del departamento y municipio de residencia. Por lo tanto, se comienza verificando que los códigos sean correctos, asumiendo que siguen la norma ISO 3166-1 numérico (*Ver*)

```
## [1] NA      "170" "140" "862" "702" "270" "840" "76"  "218" "591" "174" "32"
## [13] "124" "484" "250" "470" "706" "826" "178" "570" "175" "705" "152" "308"
## [25] "520" "422" "760" "4"   "554" "50"  "180" "768" "604" "86"  "184" "222"
## [37] "275" "417"
```

Se encontraron varias inconsistencias de escrituras pero relacionadas al formato, por ejemplo, 76 cuando debe ser 076.

Luego de hacer el cambio de esas inconsistencias, se verifica que todos los códigos están correctamente relacionados con el país al que corresponden y se modifica también la escritura de algunos países

Departamento: `departamento_residencia` representa el nombre del departamento y `cod_dpto_r` su respectivo código. Para verificar la concordancia de los códigos y nombres se utiliza la base oficial de DIVIPOLA:

1. Se comienza analizando los departamentos que no se encuentran en la lista de DIVIPOLA:

```
## # A tibble: 20 x 3
##   cod_dpto_r departamento_residencia cantidad
##   <chr>      <chr>                  <int>
## 1 00        PROCEDENCIA DESCONOCIDA      1307
## 2 01        EXTERIOR                    375
## 3 08        ATLANTICO                  24587
## 4 1         EXTERIOR                    23
## 5 11        BOGOTA                  105695
## 6 13        BOLIVAR                  24477
## 7 15        BOYACA                   27253
## 8 18        CAQUETA                   8023
## 9 23        CORDOBA                  23272
## 10 27       CHOCO                   2350
## 11 44       GUAJIRA                  8215
## 12 54       NORTE SANTANDER         21889
## 13 63       QUINDIO                 16348
## 14 76       VALLE                  103601
## 15 8        ATLANTICO                   3038
## 16 88       SAN ANDRES                803
## 17 94       GUAINIA                   885
## 18 97       VAUPES                   1327
## 19 <NA>      1                      2
## 20 <NA>     11                      3
```

En la mayoría de los casos no se encuentran porque tienen diferencia de escritura. En los casos en que la víctima reside en el exterior, se cambia el valor de esta variable a la siguiente estructura: Depto[País]

2. Analizando que códigos no están en la lista. Se encontraron los siguientes:

```
## # A tibble: 10 x 3
##   cod_dpto_r departamento_residencia cantidad
##   <chr>      <chr>                  <int>
## 1 01        Depto[Canadá]                1
## 2 01        Depto[Isla Niue]              1
## 3 01        Depto[Togo]                   1
## 4 01        Depto[Nueva Zelanda]          1
## 5 01        Depto[Malta]                  1
## 6 01        Depto[Bangladesh]            1
## 7 01        Depto[Palestina]             1
## 8 01        Depto[Venezuela]            34
## 9 01        Depto[Reino Unido]           1
## 10 01       Depto[Kirguistán]           1
```

Para los casos 5 y 8 se cambia a 05 y 08 respectivamente. Para los casos donde **departamento_residencia** es un lugar del exterior se cambia a 0, indicando “No aplica”. Para los casos donde el departamento es NA se convierte código a NA y para los casos donde departamento es Bogotá, D.c. se cambia a 11, dado que el municipio indica que efectivamente corresponde a casos donde la víctima residía en Bogotá

3. Los casos donde hay discordancia entre el código y el nombre del departamento son:

```
## # A tibble: 0 x 3
## #   i 3 variables: cod_dpto_r <chr>, departamento_residencia <chr>,
## #     cantidad <int>
```

No hay discordancias. Entre los departamentos resultantes están:

```
## # A tibble: 10 x 2
##   departamento_residencia      n
##   <chr>                  <int>
## 1 Amazonas                3149
## 2 Antioquia              147178
## 3 Arauca                  4994
## 4 Archipiélago De San Andrés, Providencia Y Santa Catalina    803
## 5 Atlántico               27625
## 6 Bogotá, D.c.          105698
## 7 Bolívar                 24477
## 8 Boyacá                  27253
## 9 Caldas                  21507
## 10 Caquetá                 8023
```

Municipio: `municipio_residencia` representa el nombre del municipio y `cod_mun_r` su respectivo código. Este código está compuesto por los últimos tres dígitos del código Divipola para cada municipio

1. Primero se verifica que códigos no están en la lista oficial, se encontraron casos como:

```
## # A tibble: 10 x 2
##   cod_mun_r cantidad
##   <chr>      <int>
## 1 184         1
## 2 474         1
## 3 140         7
## 4 705         1
## 5 084         1
## 6 124         1
## 7 270         1
## 8 768         1
## 9 999        25
## 10 222         2
```

Se encontraron varias inconsistencias como:

- Valor 000 que corresponde a casos donde el valor en `municipio_residencia` indicaban el departamento pero que el municipio es desconocido, por ejemplo: * VALLE. MUNICIPIO DESCONOCIDO. En estos casos se cambia el valor de `cod_mun_r` a NA
- Valor 000 u otros, que corresponden a casos donde el valor en `municipio_residencia` es EXTERIOR. PAÍS DESCONOCIDO, EXTERIOR\[País:] o nombres de otros países. En estos casos se cambia el valor de `cod_mun_r` a 0
- Hay un caso donde `municipio_residencia` es Armenia pero el filtro indica que el código es incorrecto. Este caso no se le puede corregir el código porque no se sabe si se trata de Armenia de Antioquia o de Quindío

Nota: Una vez verificados los códigos, se transforma esta variable para que tome como valor el código completo (5 dígitos)

2. Los nombres de municipios que no se encuentran en la lista son, por ejemplo:

```
## # A tibble: 5 x 2
##   municipio_residencia cantidad
##   <chr>                <int>
## 1 CURUMANI              682
## 2 EXTERIOR_SANTA HELENA    1
## 3 SAN ANDRES            930
## 4 CHIQUINQUIRA          583
## 5 ANGELOPOLIS           125
```

Las inconsistencias se debe a escritura y a en los casos donde el municipio es un municipio del exterior. Entonces se corrige escritura para municipios de Colombia y para casos de residencia extranjera se cambia a Mun[País]

3. Verificar concordancia entre código y nombre

```
## # A tibble: 0 x 4
## # i 4 variables: cod_mun_r <chr>, municipio_residencia <chr>,
## #   nombre_municipio <chr>, cantidad <int>
```

No hay discordancias. Los siguientes son algunos de los municipios que quedan en la base:

```
## # A tibble: 5 x 2
##   municipio_residencia    n
##   <chr>                <int>
## 1 Roberto Payán         104
## 2 Ricaurte              547
## 3 Zipaquirá             3480
## 4 Yaguará               172
## 5 Pital                 419
```

Distrito especial: se crea esta variable para identificar los casos donde la víctima residía en uno de los distrito especiales de Colombia, los cuales son:

1. **Bogotá:** Distrito Capital.
2. **Barranquilla:** Distrito Especial, Industrial y Portuario.
3. **Santa Marta:** Distrito Turístico, Cultural e Histórico.
4. **Cartagena:** Distrito Turístico, Cultural e Histórico.
5. **Buenaventura:** Distrito Especial, Industrial, Portuario, Biodiverso y Ecoturístico.
6. **Riohacha:** Distrito Especial, Turístico y Cultural.
7. **Medellín:** Distrito Especial de Ciencia, Tecnología e Innovación.
8. **Mompox:** Distrito Especial Turístico, Cultural e Histórico.

9. **Barrancabermeja:** Distrito Especial Portuario, Industrial, Turístico y Biodiverso.
10. **Turbo:** Distrito Especial Portuario, Logístico, Turístico, Industrial y Comercial.
11. **Tumaco:** Distrito Especial, Industrial, Portuario, Biodiverso y Ecoturístico.
12. **Cali:** Distrito Especial, Deportivo, Cultural, Turístico, Empresarial y de Servicios.

Cuando esta variable toma valor 1 significa que se trata a un distrito especial, cuando toma valor 2 significa que no se trata de un distrito especial y cuando es No aplica es porque el lugar de residencia es en el exterior.

Estrato (no obligatoria)

```
##      1      2      3      4      5      6  NA's
## 237702 205831 60445  6585  1628  1710 363253
```

Esta variable es información de la ficha de datos básicos que se debe registrar para cualquier evento que se reporta al SIVIGILA. Sin embargo, no se encuentra información para los años 2013 al 2017, pero sí para los años posteriores lo que puede explicar porqué la gran cantidad de NA

```
##
##      2013  2014  2015  2016  2017  2018  2019  2020  2021  2022  2023  2024
## 1      0      0      0      0      0 27786 40472 35285 39890 45466 48629  174
## 2      0      0      0      0      0 21408 30803 27332 33914 43253 48903  218
## 3      0      0      0      0      0  5436  8309  7913 10121 12776 15808   82
## 4      0      0      0      0      0   659   924   763  1085  1506  1634   14
## 5      0      0      0      0      0   182   231   189   232   349   442    3
## 6      0      0      0      0      0   259   320   249   236   335   311    0
```

Sexo (obligatoria)

```
##      F      M
## 864931 12223
```

Identidad género (no obligatoria)

Según el diccionario de la base de datos, la variable de identidad de género (**ident_gene**) toma valores de: Masculino(1), Femenino(2) y Transgénero(3).

Según el filtro hecho en secciones anteriores, solo se cuenta con categoría femenino y transgénero, pues no se estudia la violencia de género hacia los hombres.

```
##      2      3  NA's
## 655051  285 221818
```

Orientación sexual (no obligatoria)

De acuerdo a las fichas de notificación y el diccionario de la base de datos, los niveles de esta variable son: homosexual(1),bisexual(2),heterosexual(5) y asexual(6). Sin embargo, esta variable también toma valor 3 y 4.

##	1	2	3	4	44316	5	6	NA's
##	6967	16256	212	60555	1	563944	7572	221647

Al notificar un caso se llena una ficha de datos básicos y una ficha relacionada al evento. Ambas fichas en las versiones recientes piden la orientación sexual. Sin embargo, la clasificación en la ficha de datos tiene una codificación diferente: heterosexual(1), gay/lesbiana(2), bisexual(3) y otra(4). Para evitar cruces se reduce a dos categorías:

- **Orientación Sexual, Identidad y expresiones de género no hegemónicas (OSIEG no Hegemónicas):** incluye los casos con valor 1,2,3 y 6
- **Heterosexual:** incluye los casos con valor 5
- Para los casos con valor 4 se deja igual, como Otra

##	Heterosexual	OSIEG no hegemónicas	Otra
##	563944	31007	60555
##	NA's		
##	221648		

Grupos poblacionales (no obligatorias)

Es un conjunto de variables no obligatorias en la ficha de notificación, que no tienen restricciones e indican si la víctima es persona en situación de discapacidad (**gp_discapa**), desplazada (**gp_desplaz**), migrante (**gp_migrant**), privada de la libertad (**gp_carcela**), gestante (**gp_gestan**), habitante de calle (**gp_indigen**), menor a cargo del ICBF (**gp_pobicfb**), madre comunitaria (**gp_mad_com**), desmovilizada (**gp_desmovi**), en centro psiquiátrico (**gp_psiquia**), víctima de violencia (**gp_vic_vio**) o perteneciente a otro grupo (**gp_otros**). Cada variable toma el valor de 1 (sí) o 2 (no).

```
## $gp_discapa
##
##      1      2  <NA>
##  5353 871796      5
##
## $gp_desplaz
##
##      1      2  <NA>
## 10332 866817      5
##
## $gp_migrant
##
##      1      2  <NA>
## 17613 859536      5
##
## $gp_carcela
##
##      1      2  <NA>
##  1350 875799      5
##
## $gp_gestan
##
##      1      2  <NA>
##  53615 823534      5
```

```

##
## $gp_indigen
##
##      1      2    <NA>
## 1716 875433      5
##
## $gp_pobicfb
##
##      1      2    <NA>
## 4271 872878      5
##
## $gp_mad_com
##
##      1      2    <NA>
## 796 876353      5
##
## $gp_desmovi
##
##      1      2    <NA>
## 441 876708      5
##
## $gp_psiquia
##
##      1      2    <NA>
## 1958 875191      5
##
## $gp_vic_vio
##
##      1      2    <NA>
## 26187 850962      5
##
## $gp_otros
##
##      1      2    <NA>
## 781219 95930      5

```

Sin embargo, en las bases de datos de 2014-2017 se encontraron otras variables: **priv_liber**, **desmov_rei**, **nna_snb**, **vic_confl**, las cuales por su composición y nombre se puede pensar que representan lo mismo que las variables **gp_carcela**, **gp_desmovi**, **gp_pobicfb** y **gp_vic_vio**, respectivamente.

Además, se encontró que en la ficha del evento del 2015, se pregunta sobre estos grupos poblacionales pero en la ficha del evento 2018 ya no se pide. Mientras que viendo las versiones de la ficha básica disponible, también se pide información sobre grupos poblacionales en todos los años, es decir, hubo años en que se pedía dos veces la misma información, una por tipo de ficha. Esto explica porque en algunos casos estas variables y las variables **gp__** toman valor al tiempo.

```

## $desmov_rei
##
##      1      2    <NA>
## 198 142045 734911
##
## $nna_snb
##
##      1      2    <NA>

```



```
##      837 141396 734921
##
## $priv_liber
##
##      1      2    <NA>
##    168 142065 734921
##
## $otra_situa
##
##      1      2    <NA>
##   70793 106621 699740
##
## $vic_confli
##
##      1      2    <NA>
##   1398 140835 734921
```

Por lo anterior, se verificó si habían valores faltantes en las variables **gp__** que se pudieran completar con estas variables, pero no. Son NA en los mismos casos. Pero se identificó que en algunos casos estas variables son 1 y su semejante **gp__** es 2. Entonces se modifica el valor de **gp__** para estos casos:

- **Población privada de la libertad:**

```
## # A tibble: 7 x 3
##   priv_liber gp_carcela      n
##   <chr>      <chr>    <int>
## 1 1          1          25
## 2 1          2         143
## 3 2          1         296
## 4 2          2       141769
## 5 <NA>       1        1029
## 6 <NA>       2       733887
## 7 <NA>      <NA>         5
```

- **Víctimas desmovilizadas:**

```
## # A tibble: 7 x 3
##   desmov_rei gp_desmovi      n
##   <chr>      <chr>    <int>
## 1 1          1         19
## 2 1          2        179
## 3 2          1        105
## 4 2          2      141940
## 5 <NA>       1         317
## 6 <NA>       2      734589
## 7 <NA>      <NA>         5
```

- **Población infantil a cargo del ICBF:**

```
## # A tibble: 7 x 3
##   nna_snbfp gp_pobicfb      n
##   <chr>      <chr>    <int>
```

```
## 1 1      1      251
## 2 1      2      586
## 3 2      1      556
## 4 2      2     140840
## 5 <NA>    1      3464
## 6 <NA>    2     731452
## 7 <NA>   <NA>      5
```

- **Víctima de violencia armada:**

```
## # A tibble: 7 x 3
##   vic_confli gp_vic_vio      n
##   <chr>      <chr>    <int>
## 1 1      1      548
## 2 1      2      850
## 3 2      1     3878
## 4 2      2    136957
## 5 <NA>    1     21761
## 6 <NA>    2    713155
## 7 <NA>   <NA>      5
```

Luego, la variable **otra_situa** puede servir para completar **gp_otros**. Solo está en la base de 2014-2017 y si vemos las fichas en estos años hay la opción de seleccionar “otro”. Se hace el mismo cambio que en las variables anteriores

```
## # A tibble: 7 x 3
##   otra_situa gp_otros      n
##   <chr>      <chr>    <int>
## 1 1      1     62365
## 2 1      2     8428
## 3 2      1     94127
## 4 2      2     12494
## 5 <NA>    1    624727
## 6 <NA>    2     75008
## 7 <NA>   <NA>      5
```

Finalmente, según la ficha de notificación, si la víctima no pertenece a los grupos listados (**gp_discapa**, **gp_desplaz**, etc) se debe llenar con "Sí" la variable **gp_otros** para indicar que pertenece a otro grupo poblacional.

Por lo tanto, si todos los grupos son 2 se cambia la variable **gp_otros** a 1. Pero en caso de que al menos un grupo sea 1 o NA, se deja igual **gp_otros**

Semanas de gestación (no obligatoria): esta variable toma valor si la variable **gp_gestan** es igual a 1 (Sí). Además, se verifica que dicho valor sea entre 1 y 45 ya que es lo esperado en tiempo de gestación.

Madre cabeza de familia (obligatoria): las variables **mujer_cabf** y **persona_con_jefatura_de_hogar** contienen información sobre si la mujer es madre cabeza de familia o no. Para tener esta información de manera más precisa, se realiza una combinación de ambas variables en una sola, con el objetivo de generar una variable única que represente esta condición:

- **Variable mujer_cabf:**

```
##      1      2  NA's
## 26639 183818 666697
```

- Variable `persona_con_jefatura_de_hogar`:

```
##      1      2 3152184127      44108      NA's
## 88133      500793      1      1      288226
```

Entonces se completa `mujer_cabf` usando los valores de `persona_con_jefatura_de_hogar`

```
## # A tibble: 2 x 3
##   mujer_cabf persona_con_jefatura_de_hogar      n
##   <chr>      <chr>                      <int>
## 1 <NA>      1                        88133
## 2 <NA>      2                        500793
```

Pertenencia étnica (obligatoria): De acuerdo al diccionario de datos, indica la pertenencia de la víctima a alguna étnica que es considerada de interés para eventos en salud pública. Los valores que toma son: 1 = Indígena, 2 = ROM/Gitano, 3 = Raizal, 4 = Palenquero, 5 = Negro/Mulato/Afro Colombiano, 6 = Otro

```
##      1      2      3      4      5      6  NA's
## 21664 2793 1297 484 31587 819324      5
```

Luego, la variable `nom_grupo` corresponde al grupo indígena al que pertenece la víctima en caso de que `pertenencia étnica(per_etn)` sea igual a 1 (indígena). Por lo tanto, para evitar NA falsos, en caso contrario, se asigna “No aplica”. Además, se corrige la escritura de algunos niveles para evitar repeticiones

```
##      Nasa      Wayuu      Embera Chami      Pastos
##      1930      1190      1173      967
##      Zenu      Tikuna      Awa      Embera Katio
##      673      526      509      505
##      Sikuni      Embera      Cubeo      Paez
##      503      458      387      245
## Misak O Guambiano      Inga      Uwa      Pijao
##      221      187      179      168
##      Arhuaco      Guahibo      Guayabero      Yukpa
##      161      143      138      134
##      Uitoto      Piapoco      Yanacona      Achagua
##      132      101      100      92
##      Curripaco      Tucano      Macahuan      Desano
##      86      82      79      78
##      Cocama      Puinave      Kokonuko      Totoro
##      73      73      71      71
##      Nukak      Kamentsa      Tuyuca      Guanano
##      69      66      45      44
##      Kankuamo      Barasano      Siriano      Bora
##      44      43      35      34
##      Wiwa      Macuna      Yagua      Saliba
##      34      33      33      32
##      Yucuna      Hitnu      Murui      Guambiano
##      32      31      31      27
```

##	Piratapuyo	Amorua	Ambalo	Kizgo
##	27	26	25	25
##	Tatuyo	Kichwa	Kogui	Muruy
##	25	24	24	23
##	Yuriti	Muisca	Piaroa	Carapana
##	23	21	21	20
##	Chimila	Cuiba	Tanimuca	Andoque
##	16	16	16	15
##	Coreguaje	Eperara Siapidara	Polindara	Embera Dobida
##	15	15	15	14
##	Motilon Bari	Wanano	Witoto	Camentsa
##	14	14	14	13
##	Kofan	Letuama	Wounaan	Miraa
##	13	13	13	11
##	Mokana	Cabiyari	Waunan	Baniva
##	11	10	10	9
##	Taiwano	Quillacinga	Siona	Matapi
##	9	8	7	6
##	Cuna	Yukuna	Carijona	Nukak Maku
##	5	5	4	4
##	Tamas	Kamsa	Masiguare	Muinane
##	4	3	3	3
##	Ocaina	Tanimuka	Hitno	Karapana
##	3	3	2	2
##	Miraña	Nunuya	(Other)	NA's
##	2	2	17	864443

Nota: es importante tener en cuenta que **nom_grupo** aparece en la ficha de datos básicos y en estas bases solo toma valores a partir del año de notificación 2018

Consumidora de SPA (obligatoria): de acuerdo al diccionario de datos, esta variable es obligatoria e indica si la víctima estaba en situación o condición de vulnerabilidad por ser persona consumidora de (SPA)

##	0	1	2	7300000	NA's
##	1	16374	777063	1	83715

Ocupación de la víctima (obligatoria)

De acuerdo al diccionario esta variable indica la ocupación de la víctima a partir de la codificación establecida en el decreto 654 del Ministerio de Trabajo y la resolución 0771 del 2021. Tanto en el decreto como en la resolución se establece la *Clasificación Única Ocupaciones para Colombia (CUOC)* que es una adaptación de la *Clasificación Internacional Uniforme de Ocupaciones(CIUO-88)*, la cual es utilizada a nivel internacional para clasificar las ocupaciones de manera estandarizada.

El valor que toma el código puede ser de hasta 5 dígitos, con cada dígito añadiendo un nivel de precisión sobre la ocupación. El **primer dígito** indica el **gran grupo** o sector de ocupación. El **segundo y tercer dígito** proporcionan una **subdivisión** dentro de la categoría. El **cuarto dígito** indica el **grupo primario** de la ocupación y el **quinto dígito** define de manera más precisa la **ocupación específica** dentro de esa subdivisión.

Por ejemplo:

- 2 corresponde a profesionales, científicos e intelectuales

- 25 incluye a profesionales de tecnología de la información y las comunicaciones
- 251 abarca el grupo más general de Desarrolladores y analistas de software y multimedia.
- 2512 corresponde a Desarrolladores de software y aplicaciones
- 25120 corresponde a Desarrolladores de software

##	9996	9997	9999	99999.05	99999.04	9998	99999.07	9622
##	227504	196305	176913	36393	31514	27777	25199	11166
##	5149	9950	99999.06	96220	99999.01	5141	5132	5221
##	11003	10507	5931	4440	3491	3071	3021	2966
##	9994	6111	5249	9210	5341	9995	4123	5220
##	2567	2495	2361	2016	1885	1793	1489	1355
##	4222	3339	4211	4416	3221	9629	2330	52210
##	1224	1213	1118	1102	1089	1070	1062	1061
##	9412	7549	5320	6112	3414	75490	3429	2421
##	1025	1018	961	949	919	837	819	808
##	9155	2411	2221	4113	5122	4419	9953	44199
##	799	779	762	753	751	728	715	700
##	3343	5142	9221	9129	6114	2611	9520	5230
##	696	689	670	639	628	606	602	597
##	5169	4120	9993	6113	5131	2312	99999.03	52230
##	567	564	557	547	546	528	527	511
##	1412	4223	5223	2313	5243	2226	5342	42299
##	503	501	497	483	479	475	473	472
##	3341	2412	51620	51690	9133	53291	5120	9115
##	471	460	460	458	458	448	444	426
##	5121	5212	5222	5329	2230	4229	51410	9114
##	410	404	404	385	377	377	367	366
##	5246	2341	4190	7119	26110	3322	1420	51310
##	347	339	336	325	311	305	296	296
##	4121	61140	(Other)	NA's				
##	290	286	38522	5				

Sin embargo, en algunos registros el valor que está tomando esta variable no tienen ningún tipo de relación con la codificación. En estos casos los valores se convierten a NA

```
## # A tibble: 12 x 2
##   ocupacion      n
##   <chr>      <int>
## 1 9994        2567
## 2 9995        1793
## 3 9996       227504
## 4 9997       196305
## 5 9998        27777
## 6 9999       176913
## 7 99999.01     3491
## 8 99999.03      527
## 9 99999.04     31514
##10 99999.05     36393
##11 99999.06      5931
##12 99999.07     25199
```

Luego, se observa que algunos códigos no tienen los dígitos completos. Dado que se cuenta con una base auxiliar con las 676 ocupaciones posibles (código de 5 dígitos), se buscan los valores de nuestra base que no coinciden o no tiene similitud con la lista de códigos oficiales

```
## # A tibble: 330 x 2
##   ocupacion      n
##   <chr>      <int>
## 1 0120         11
## 2 0130         11
## 3 0220          5
## 4 0230         42
## 5 0240          8
## 6 110          14
## 7 1100         10
## 8 1110          6
## 9 1121         10
## 10 1122         12
## # i 320 more rows
```

Estos códigos se convierten en NA, a excepción de los valores 110, 1100 210 y 2100, ya que por la lectura de los datos puede que se haya omitido el cero inicial. De ser así, de acuerdo a la codificación pueden corresponder a **oficiales y suboficiales de las Fuerzas Militares**, respectivamente. A estos casos se cambian su valor para que tenga el dígito inicial

Así, esta variable queda con 785099 celdas vacías. Pero puede servir para completar información de los niveles 26 (Otro) y 33 (Ninguna) de la variable **actividad**. Es importante resaltar que esta variable se pide en la ficha de datos básicos mientras que actividad en la ficha del evento.

Actividad (obligatoria)

De acuerdo al diccionario, la variable **actividad** toma los valores de: (13) Líderes(as) cívicos, (24) Estudiante, (26) Otro, (28) Trabajador(a) domestico(a), (29) Persona en situación de prostitución, (30) Campesino/a, (31) Persona dedicada al cuidado del hogar, (32) Persona que cuida a otras y (33) Ninguna.

```
##      1      13      15      16      17      24      26      28      29      30      31
##      2    711    728    605    136 215810 291387 32860 1776 6176 124396
##     32     33 43813      8   NA's
##   3926 120555      1    168 77917
```

Sin embargo, se observa que está tomando valores como 8,15,16, 17, que corresponde a reciclador(a), maestro(a),servidor(a) público y fuerza pública, respectivamente, según fichas de notificación más antiguas. Estos casos se cambian a valor (26) **Otro** por no tener una categoría semejante en los niveles definidos en el diccionario, y los valores inconsistentes como 1 y 43813 se cambian a NA

Adicional a esta variable, se encuentran 3 más que pueden ayudar a completar actividad. Estas variables están presentes en la base del 2013 y toman como valores 1 o 2 para indicar si la víctima es o no la respectiva actividad, pero con esta información se asigna el valor correspondiente a la variable **actividad**, ya que esta última variable no está presente en el año 2013:

- **ama_de_cas**

```
##      1      2   NA's
## 42545 99688 734921
```

- **tra_sexual**

```
##      1      2  NA's
##  545 141785 734824
```

- **campesino**

```
##      1      2  NA's
##  7473 137073 732608
```

La cantidad de casos en los que se completó información porque **actividad** era NA y alguna de las otras variables tomaba un valor es:

```
## [1] 2437
```

Luego, son 75124 registros con valor “Otro”, “Ninguna” o NA en **actividad** y que tienen valor en **ocupación**. Por lo tanto, se puede completar entre sí. Pero hay que tener en cuenta que **actividad** tiene actividades que pueden estar incluídas dentro de algún grupo de los representados en la variable **ocupacion**:

- Líderes cívicos en (11140) dirigentes de organizaciones con un interés específico (partidos políticos, sindicatos y organizaciones sociales)
- Trabajador(a) doméstico(a) en (91110) personal de servicio doméstico
- Persona en situación de prostitución en (51690) otros trabajadores de servicios personales no clasificados en otras ocupaciones
- Campesino/a en (6) Agricultores y trabajadores calificados agropecuarios, forestales y pesqueros
- Personas que cuidan a otros en (532) trabajadores de los cuidados personales en servicios de salud

Entonces lo que se hace es que en los casos donde **actividad** es NA, **otro** o **ninguna** y está tomando alguno de estos valores en **ocupacion**, se asigna a **actividad** su equivalente en **ocupacion**. Por ejemplo: si **ocupacion** es 51690 se asigna a **actividad** 29.

Nota: esta acción se hace pensando en que las categorías ya definidas en **actividad** son relevantes bajo el contexto del problema entonces puede influir en los resultados si al completar generalizamos con categorías como las definidas en el primer dígito de **ocupacion**

Ahora, en caso de que **ocupacion** no tenga equivalente en las categorías **actividad**, se deja el valor de **ocupacion** pero antes para evitar muchas más categorías, se extrae de cada código el primer dígito para trabajar únicamente con el gran grupo de la clasificación de ocupaciones y luego se cambia el valor de **actividad** por el nombre del grupo

Finalmente, se cambia cada categoría de **actividad** por el nombre del indicativo correspondiente y se elimina la variable **ocupacion**

Información del hecho

Lugar de procedencia/ocurrencia del hecho

Se refiere al lugar donde posiblemente el paciente adquirió o al cual se atribuye la exposición al agente o factor de riesgo que ocasionó el evento. Según el diccionario de datos, las variables relacionadas a la codificación DIVIPOLA son obligatorias

Departamento: se cuenta tanto con el código como con el nombre

```
##      00      01      05      08      11      13      15      17      18      19      20
##      30      16 147166 27621 105891 24716 27355 21609 8057 23929 17984
##      23      25      27      41      44      47      50      52      54      63      66
## 23395 66264 2503 40539 8261 14745 15798 29861 21984 16351 21688
##      68      70      73      76      81      85      86      88      91      94      95
## 44009 14033 17855 103352 5025 10018 7698 818 3047 886 1785
##      97      99
##     1329     1536
```

```
##              1              11              2
##              2              1              2
##              Amazonas          ANTIOQUIA          ARAUCA
##              3047              147166              5025
##              ATLANTICO          BOGOTA              BOLIVAR
##              27621              105886              24716
##              BOYACA              CALDAS              CAQUETA
##              27355              21609              8057
##              CASANARE          CAUCA              CESAR
##              10018              23929              17984
##              CHOCO              CORDOBA          CUNDINAMARCA
##              2503              23395              66264
##              EXTERIOR          GUAINIA              GUAJIRA
##              16              886              8261
##              GUAVIARE          HUILA              MAGDALENA
##              1785              40539              14745
##              META              NARIÑO          NORTE SANTANDER
##              15798              29861              21984
## PROCEDENCIA DESCONOCIDA          PUTUMAYO          QUINDIO
##              30              7698              16351
##              RISARALDA          SAN ANDRES          SANTANDER
##              21688              818              44009
##              SUCRE              TOLIMA              VALLE
##              14033              17855              103352
##              VAUPES              VICHADA
##              1329              1536
```

Se comienza modificando la escritura de los niveles y cambiando a NA el nivel “DEPTO DESCONOCIDO”

Luego, se verifica la consistencia de las variables mediante la codificación DIVIPOLA

1. Al analizar que códigos no están en la lista, se encontraron los siguientes:

```
## # A tibble: 2 x 3
##   cod_dpto_o departamento_ocurrencia Cantidad
##   <chr>      <chr>                  <int>
## 1 00      <NA>                      30
## 2 01      Exterior                16
```

Estos casos se convierten a NA, incluyendo los casos donde **departamento_ocurrencia** es exterior porque ya se filtró la base de manera que solo hayan casos que ocurrieron en Colombia. Entonces este valor no es consistente

2. Los departamentos que no se encuentran en la lista son:

```
## # A tibble: 3 x 3
##   cod_dpto_o departamento_ocurrencia    n
##   <chr>      <chr>                  <int>
## 1 11        <NA>                      5
## 2 <NA>      Exterior                  16
## 3 <NA>      <NA>                      30
```

Se cambian los casos donde el departamento es del exterior por NA

Municipio: se cuenta tanto con el código como con el nombre. El código está compuesto por los últimos tres dígitos del código Divipola para cada municipio.

La variable **municipio_ocurrencia** correspondiente al nombre tomaba en algunos casos nombres de departamento o que indicaban desconocimiento del municipio (Ej. * CHOCO. MUNICIPIO DESCONOCIDO), por ende, se cambian estos últimos casos a NA.

Luego, se verifica la concordancia de los códigos y nombres con ayuda de la codificación Divipola:

1. Al analizar que códigos no están en la lista, se encontraron por ejemplo:

```
## # A tibble: 10 x 5
##   cod_mun cod_mun_o municipio_ocurrencia departamento_ocurrencia    cantidad
##   <chr>   <chr>      <chr>                  <chr>                  <int>
## 1 17000   000        <NA>                  Caldas                  16
## 2 97000   000        <NA>                  Vaupés                  2
## 3 95000   000        <NA>                  Guaviare                1
## 4 63000   000        <NA>                  Quindío                26
## 5 15000   000        <NA>                  Boyacá                  14
## 6 44000   000        <NA>                  La Guajira             12
## 7 52000   000        <NA>                  Nariño                 21
## 8 27000   000        <NA>                  Chocó                   34
## 9 73000   000        <NA>                  Tolima                  24
## 10 88000   000        <NA>                  Archipiélago De San Andrés, ~ 4
```

La mayoría de códigos que no coinciden con los códigos de la lista, corresponden a casos donde no se conoce el municipio, por ende, se cambia a NA. Al igual que los casos del municipio extranjero, que debe tratarse de un error porque ya se filtró la base para tener solo los casos de Colombia. Por otro lado, el caso de **Belén De Bajira** es inconsistente porque ese código y nombre aparecen diferente en la base auxiliar, se cambia estos casos a como aparece en esta. Y los casos de **Mapiripana** se encontró que corresponde a un centro poblado del municipio de Barrancominas, por ende, se cambia el valor de estos casos por el nombre y código del municipio

Nota: Una vez verificados los códigos, se transforma esta variable para que tome como valor el código completo (5 dígitos)

2. Los nombres de municipios que no se encuentran en la lista son:

```
## # A tibble: 406 x 3
##   cod_mun_o municipio_ocurrencia cantidad
##   <chr>      <chr>                  <int>
## 1 05036     Angelopolis             120
```

```
## 2 05040 Anori 364
## 3 05042 <NA> 1043
## 4 05044 Anza 105
## 5 05101 Bolivar 596
## 6 05107 Briceno 230
## 7 05113 Buritica 205
## 8 05120 Caceres 248
## 9 05142 Caracoli 75
## 10 05148 Carmen De Viboral 1381
## # i 396 more rows
```

La mayoría de inconsistencias se debe a escritura entonces se corrige escritura y los casos donde se especifica que no se conoce el municipio se convierten a NA

3. Verificar concordancia entre código y nombre

```
## # A tibble: 0 x 4
## # i 4 variables: cod_mun_o <chr>, municipio_ocurrencia <chr>,
## # nombre_municipio <chr>, cantidad <int>
```

No hay discordancias.

Distrito especial: se crea esta variable para identificar los casos que ocurrieron en uno de los distritos especiales de Colombia, los cuales son:

1. **Bogotá:** Distrito Capital.
2. **Barranquilla:** Distrito Especial, Industrial y Portuario.
3. **Santa Marta:** Distrito Turístico, Cultural e Histórico.
4. **Cartagena:** Distrito Turístico, Cultural e Histórico.
5. **Buenaventura:** Distrito Especial, Industrial, Portuario, Biodiverso y Ecoturístico.
6. **Riohacha:** Distrito Especial, Turístico y Cultural.
7. **Medellín:** Distrito Especial de Ciencia, Tecnología e Innovación.
8. **Mompox:** Distrito Especial Turístico, Cultural e Histórico.
9. **Barrancabermeja:** Distrito Especial Portuario, Industrial, Turístico y Biodiverso.
10. **Turbo:** Distrito Especial Portuario, Logístico, Turístico, Industrial y Comercial.
11. **Tumaco:** Distrito Especial, Industrial, Portuario, Biodiverso y Ecoturístico.
12. **Cali:** Distrito Especial, Deportivo, Cultural, Turístico, Empresarial y de Servicios.

Cuando esta variable toma valor 1 significa que se trata a un distrito especial y cuando toma valor 2 significa que no se trata de un distrito especial.

Área: con respecto a la variable **area**, corresponden a la ubicación donde ocurrieron los hechos de violencia. Según las fichas de SIVIGILA las categorías corresponden a: (1) Cabecera municipal, (2) Centro poblado o (3) Rural disperso.

```
##      1      2      3
## 694135 68223 114796
```

Hora del hecho (obligatoria)

Es de tipo character, hasta 2017 toma valores coherentes con hora. En 2018 toma decimales y en el resto toma valores boolean o NA. Se atribuye a que a partir de cierta versión no se pide la hora lo que explica los 576215 registros con NA. Lo cual corresponde al siguiente porcentaje de la base de datos

```
## [1] 65.69143
```

Al corresponder a un porcentaje muy alto de NA se elimina esta variable, pues no son demasiados datos por imputar.

Modalidad de violencia (no obligatoria)

De acuerdo al diccionario existen dos grupos de modalidad: violencia no sexual y violencia sexual, cada una con diferentes tipos. Si la víctima sufrió violencia no sexual se registra el tipo en la variable **naturaleza** y si sufrió violencia sexual se registra el tipo en la variable **nat_viosex**

- **Violencia no sexual:** 1= Violencia Física, 2= Violencia Psicológica, 3= Negligencia y Abandono

```
##      1      10      11 11001      12      2      3 32606      4 44068 44110
## 449176      35      84      1 5024 85529 97376      1 47665      1      1
##      5      6      7      8      9 NA's
## 2189 4622 180 45      5 185220
```

- **Violencia sexual:** 5 = Acoso sexual, 6 = Acceso carnal, 7 = Explotación sexual, 10 = Trata de personas, 12= Actos sexuales, 14 = Otras violencias sexuales, 15 = Mutilación Genital

```
##      10      12      14      15      2      4 43813 44068 44110      5      6
## 155 31889 20199 112      1 66189      1      1      1 20482 45398
##      7 NA's
## 759 691967
```

Lo primero que se observa es que las variables están tomando valores que no son indicativos entonces se convierten a NA. También se encontraron indicativos que no están definidos en el diccionario como: 4,8,9,11. Gracias a las fichas de años anteriores, se identifica que 4=abuso sexual y 11=violencia sexual en conflicto armado, entonces se convierten estos casos a 6 y 14 respectivamente. Para los demás casos no se pudo determinar que representa el indicativo entonces se convierten a NA

Luego, por facilidad en el análisis y evitando la mayor cantidad de celdas vacías posibles, se decide unificar la información de ambas variables en una variable llamada **def_naturaleza**.

Mecanismo o arma (no obligatoria)

Según el diccionario de datos la variable **armas** indica el mecanismo utilizado en la agresión y es dependiente si la variable “Modalidad” es 1 = Violencia física. Sin embargo, en esta base se encuentran otras variables que parecen representar la misma característica: **otra_arma, otro_mec, cual_o_mec, arma y mecanismo_utilizado_para_la_agresion**

```
## $armas
## [1] NA  "15" "13" "3"  "1"  "10" "4"  "2"  "14" "8"  "11" "12" "5"  "7"  "6"
## [16] "9"  "16"
```

```

##
## $otra_arma
## [1] NA "PALOS" "INSULTOS" "GOLPES"
## [5] "golpes" "PALMADAS" "OBJETO" "GOLPES-INSULTO"
## [9] "EMPUJON" "nr" "PUÑOS" "PUÑO"
## [13] "SIN E INFORMACI" "puños" "PUÑOS Y PATADA" "NO INDICA"
## [17] "patadas" "NO" "MORDISCOS" "GOLPES Y AGARR"
## [21] "RELAC SEXUAL" "golpe" "puño" "ninguna"
## [25] "AMENAZAS" "PIDRAS" "GOLPE" "CACHETADA"
## [29] "NO REPORTA" "INSULTO" "ABANDONO" "Golpes"
## [33] "coco" "MANO" "SIN ARMAS" "fuerza"
## [37] "AHORCANDO" "INSULTOS HUMI" "INSULTOS PUÑO" "MANOS"
## [41] "ALCOHOL" "COREA" "PUÑETAZOS" "SD"
## [45] "golpes manos" "NINGUNO" "ESCOBA" "LOS BRAZOS"
## [49] "LA MANO" "golpe contuso" "cachetada" "ARAÑAZO"
## [53] "LAS MANOS" "las manos" "PATADA" "LOS DIENTES"
## [57] "na" "insultos" "GOLPE CON MANO" "golpe a mano"
## [61] "GOLPE CON OBJE" "correa" "MACHETE" "PATADAS"
## [65] "amenazas" "NOVIASGO" "CABEZASO" "puño insultos"
## [69] "ninguno" "noviasgo" "TIRONES" "PSICOLOGICA"
## [73] "los brazos" "CORTOPUNZANTE" "cuchillo" "NOVIAZGO"
## [77] "manos" "SUST CALIENTE" "noviazgo" "INSULTOS- AMEN"
## [81] "punta pie" "agresion verba" "CORDON PARA A" "EMPUJON E INSU"
## [85] "BOTELLA" "FUERZA" "GOLPES CON PU" "GAS PIMIENTA"
## [89] "NINGUNA" "AMENAZA" "GOLPES- GRITOS" "BORDE DE LA CA"
## [93] "GOLPES PUÑOS" "FUERZA FISICA" "GOLPES MANO" "SIN INFORMACIO"
## [97] "CONTUSION" "insultos amena" "no informa" "puños golpes"
## [101] "DESCONOCIDO-CO" "UN PALO" "mano" "EMPUJON ESCALE"
## [105] "no" "DESCONOCIDA" "puños y patada" "CELULAR"
## [109] "Objeto" "maltratos verb" "golpes insult" "PUÑOS PATADAS"
## [113] "SIN DATOS" "apreton manos" "PIEDRA" "bate"
## [117] "GOLPES ARUÑOS" "ARAÑAZOS AMEN" "GOLPES MANOS" "golpe en cara"
## [121] "NA" "SIN DATO" "NO APLICA" "recibe objeto"
## [125] "CORREA" "AMENZAS" "contundente" "ARAÑAZOS Y PEÑ"
## [129] "signos de trau" "LA AMARRAN Y L" "PELLIZCOS" "CABEZA"
## [133] "GOLPES Y PATAD" "BRAZOS" "LANZA POR ESCA" "cabeza y brazo"
## [137] "UNA PUERTA" "las piernas" "GOLTES" "INSULT-HUMILLA"
## [141] "HUMILLACIONES" "INSULTOS AMENA" "GOLPE EN CARA" "puñoshumillac"
## [145] "GOLPÈS" "GOLPES - AMENA" "NEGLIGENCIA" "ARAÑAZOS"
## [149] "UÑAS" "PIE PATADAS" "insulto" "INSULTOS-AMENA"
## [153] "INSULTOS AMEN" "pie" "GOLPES Y PUÑOS" "LA MANO"
## [157] "AGRESION PUÑOS" "UNA PATADA" "JALONES" "la mano"
## [161] "29" "INSULTOS AME" "PALO" "goles fisicos"
## [165] "No aplica" "insultos y hum" "VERBAL" "brazos"
## [169] "insultos amen" "golpe pie y ma" "trapo" "ahorcamiento"
## [173] "golpès" "golpes-insulto" "TACO DE BILLAR" "pie y mano"
## [177] "PUÑETAZO" "3" "MANO PERFORADA" "AGRECIION FISIC"
## [181] "ZURRIAGO" "palo" "MANOS Y IES" "SACUDIDA A DES"
## [185] "PIES Y MANOS" "GRITOS GOLPES" "uñas" "CON LA MANO"
## [189] "7" "FISICA" "golpes pie y m" "MALTRATO"
## [193] "CACHETADAS Y E" "PIES" "CORREAS Y CHAN" "NO REGISTRA"
## [197] "ARRASTRE" "FISICO" "GOLPES Y EMPUJ" "OBJETOS"
## [201] "EMPUJONES" "sin dato" "ELEMENTOS DE C" "PATADAS Y CACH"
## [205] "VEHICULO" "marihuana" "CUCHILLO" "NO RESGISTRA"

```

## [209]	"NO REGISTRA"	"verbal"	"amenazas e ins"	"INSULTO HUMIL"
## [213]	"NO REGISTRA NI"	"TABLA DE MOLER"	"entierro arena"	"PUÑOS Y ARAÑON"
## [217]	"cachetadas"	"PUÑOS ARAÑAZO"	"ACCIDENTE DE T"	"insult amenaz"
## [221]	"PALMADAS Y GOL"	"contundete-puñ"	"GOLPES E INSUL"	"GOLPES PERSONA"
## [225]	"BOTELLAZO"	"PALOS Y CORREA"	"UNA LLAVES"	"golpesamenaza"
## [229]	"PUÑOS-GOLPES"	"GOLPES PUÑOS"	"golpes- palo"	"GOLPES PATADA"
## [233]	"UÑAs-GOLPES"	"GOLPES-PATADAS"	"CON UN PALO"	"GOLPERS-PATADA"
## [237]	"GOLPES Y PATA"	"GOLPE N CARA"	"CORREAZOS"	"GOLPE CON LA M"
## [241]	"fisico"	"GOLPES AMENAZA"	"FÌSICA"	"fisica"
## [245]	"PUÑO CERRADO"	"presion con la"	"arma fuego"	"ZAPATO"
## [249]	"empujoncachet"	"GOLPES EMPUJAR"	"sin informacio"	"MANO PUÑOS"
## [253]	"4"	"empujon"	"ACCI BICICLETA"	"SIN IDENTIFICA"
## [257]	"2"	"manos y uñas"	"puñetazo"	"TROMPA MALTRA"
## [261]	"NO ARMAS"	"SEDUCCION"	"AMENAZASINSUL"	"MANGUERA"
## [265]	"no armas golpe"	"NIGUNA"	"trauma cara"	"PLATO PLASTICO"
## [269]	"AMENAZAS INSUL"	"GOLPES FISICOS"	"ASESO CARNAL"	"enamoramiento"
## [273]	"SOLO VIOLENCIA"	"FISICO PUÑO"	"ESTRUJONES"	"bofetada"
## [277]	"PERSECUCION"	"CORREA ZAPATO"	"15"	"INSULTOS HUMIL"
## [281]	"MORBOSIDAD"	"CONTUNDENTE"	"INSLTOS"	"NO ESPECIFICO"
## [285]	"OTROS"	"222"	"XXX"	"xxx"
## [289]	"AGRESIONES"	"INSULTOS GOLPÈ"	"GOLPES PATADAS"	"NO SE ESTABLEC"
## [293]	"GOLPES EN CABE"	"AGRESION VERBA"	"golpes e insul"	"INSULTOSAMENA"
## [297]	"MANGUERA CALIE"	"GOLPES CON MAN"	"MADERA"	"CABLE"
## [301]	"s"	"GOLPESPUÑOS"	"FUNDA MACHETE"	"arañazo"
## [305]	"acido"	"PUÑO EN NARIZ"	"PALO CUCHARA"	"GOLPE PUÑO"
## [309]	"correazos"	"TRAUMAS MULTIP"	"PUNOS"	"MORDIDA"
## [313]	"no se tiene in"	"GOLPE DIRECTO"	"Puño"	"I"
## [317]	"GOLPES DIRECTO"	"INSULTOS UMIL"	"insumos cocina"	"TIJERAS"
## [321]	"VARILLA"	"MOTOCICLETA"	"INSULTO AMENA"	"NO LA DIJO"
## [325]	"manos puños"	"no aplica"	"palabras soece"	"DESCUIDO"
## [329]	"PATADAS Y PUÑO"	"PUÑOSPATADAS"	"GOLPE-PATADA"	"PUÑO Y PATADAS"
## [333]	"puños patada"	"ARMA CORTO SON"	"AGRESION FISIC"	"PIEDRAS-PUÑOS"
## [337]	"palabras"	"SIN DATRO"	"LESION PERSONA"	"VIOLENCIA FISI"
## [341]	"TABLA DE MADER"	"BATE DE BEISBO"	"VERBAL Y FISIC"	"PIEDRAS"
## [345]	"13"	"persuacion"	"PARED GOLPE"	"GOLPE CON PALO"
## [349]	"sicologico"	"GOLPE TUBO PVC"	"123"	"LOS PUÑOS"
## [353]	"automovil"	"ULTRAJE"	"MANOS Y PIES"	"zandalia"
## [357]	"INSULTOS HUM"	"violencia psic"	"OBJETO CONTUNF"	"OBJETO CONTUND"
## [361]	"PUÑETAZOS PATA"	"SIN INFORMACIÓ"	"AMENAZAS INSU"	"arma cortopunz"
## [365]	"PALO DE MADERA"	"INSULTOS Y HUM"	"AL PARECER"	"HALO EL CABELL"
## [369]	"Sin Dato"	"fuerza fisica"	"FISICAS"	"Insultos"
## [373]	"SURRIAGO CORR"	"SIN DATO"	"golpes punos"	"DISCUSION FAMI"
## [377]	"NO RESPONDE"	"igolpes"	"ARMA BLACA"	"con un palo"
## [381]	"PUÑOS Y ARAÑAZ"	"ABLACION"	"objetos"	"CACHETADAS"
## [385]	"TORCEDURA"	"AMENASA"	"PUNTA PIE"	"NO SABE NO RES"
## [389]	"Golpe con corr"	"Palmadas"	"GOLPÈ CON PALO"	"UNA PICADORA"
## [393]	"golpes con pie"	"PATADAS PUÑOS"	"JALONEOS"	"cabeza"
## [397]	"mordedura"	"GOLPES EMBARAZ"	"golpes cara"	"GOLPE CARA"
## [401]	"RASGUÑO"	"Palmada en la"	"golpes abdomen"	"golpes vientre"
## [405]	"golpe en brazo"	"PALAMADAS"	"puños patadas"	"ARUÑONES"
## [409]	"MALTRATO PSICO"	"TIRA OBJETOS"	"PUÑOS GOLPES"	"utencilios cas"
## [413]	"PUÑOS EN CARA"	"golpes en cara"	"PUNTAPIES"	"CONPALOS GOLPE"
## [417]	"insultos- humi"	"SIN"	"violencia fisi"	"GARROTAZOS"
## [421]	"GOLPE OBJETO"	"AGRSOR"	"CASTIGO FISICO"	"MANOSEO"

## [425]	"INSULTOS UMIL"	"maltratofisico"	"VERBALES"	"GOLPES FISICO"
## [429]	"RETENCION"	"CUCHARON"	"AGUA CALIENTE"	"GOLPES CON LA"
## [433]	"puños manos"	"GOLPE CON UTEN"	"MANO Y PUÑO"	"MADERO Y CORRE"
## [437]	"DESNUTRICION"	"ABORTIVO"	"golpe con corr"	"insulto humill"
## [441]	"ab fisico sexu"	"insultos-fisic"	"perrero"	"golpe celular"
## [445]	"DESCONOCIDO"	"CABALLO"	"lesion fisica"	"otro"
## [449]	"LE TIRO EL CAB"	"CINTURON"	"PATADAS GOLPE"	"NO CONF"
## [453]	"AHORCAMIENTO"	"TRAUMA CON MOT"	"agresion fisis"	"presión psicol"
## [457]	"insultos humil"	"PUÑOS INSULTOS"	"LA FUERZA"	"EXTREMIDADES"
## [461]	"INSULTO AMEN"	"INSULTO HUMILL"	"ARMA CORTO PPP"	"soga"
## [465]	"ESCOPOLAMINA"	"CUCHILLO PEIN"	"CHANICLETA"	"MANOS UÑAS"
## [469]	"VIOL FISICA"	"puños insulto"	"iINSULTOS HUM"	"PUÑO PATADA"
## [473]	"REPELADO"	"CRISIS FAMILIA"	"APRETON"	"PALO DE ESCOBA"
## [477]	"manguera"	"MALTRATO FISIC"	"NELI ENTRATAMI"	"humillacion"
## [481]	"PUNTAPIE"	"SOMETIMIENTO C"	"GOLPIZAS"	"INSULTO AMENAS"
## [485]	"NO HUBO ARMAS"	"GOLPE PUÑO"	"SIN INFORMACII"	"golpes - puños"
## [489]	"REVOLVER"	"NO INFORMA"	"GOLPE CON PUÑO"	"APLICACION TB"
## [493]	"GRABILA"	"PUÑOPATADA"	"patadasempujo"	"empujones"
## [497]	"PROPIO CUERPO"	"amenazas insu"	"SOSPECHA ABUSO"	"AGRESION VERVA"
## [501]	"CORTOCONTUNDEN"	"NO ESPECIFICA"	"Cuerpo del vic"	"puño patadas"
## [505]	"QUEMADURA CO A"	"NO INFORMACIÓN"	"puños en el ro"	"LECHE MALTERNA"
## [509]	"CUERPO DEL AGR"	"Puños"	"PROPIO CUERP"	"ahorcam contun"
## [513]	"atropellamient"	"propio cuerpo"	"GOLPES INTENTO"	"VENENO"
## [517]	"planificacion"	"GOLPE-INSULTOS"	"TRAUMA"	"NO ESPEFICA"
## [521]	"GESTANTE"	"empujones golp"	"apretujon"	"parte del cuer"
## [525]	"verbal y sicol"	"MALTRATO VERBA"	"FISICAY VERBAL"	"PUÑO Y PIE"
## [529]	"CUERPO"	"AMENAZACUCHILL"	"5"	"ARAÑAZOS ESTRU"
## [533]	"PARTE DEL CUER"	"INSULTO AMENAZ"	"CIGARRILLO"	"insultos-humil"
## [537]	"PUÑETAZO PATAD"	"tabla"	"desconocida"	"LA CORREA"
## [541]	"GOLPES INSULTO"	"ESTRUJON"	"agresion fisic"	"NO DESEADO"
## [545]	"ABLASION"	"NO HAY DATO"	"GOLPES EN MANO"	"NO MENCIONA"
## [549]	"veneno"	"PUÑOS Y GOLPES"	"EXP SUSTANCIA"	"MANGUERAS Y LA"
## [553]	"AMENAZA DE MUE"	"muro"	"ABANDONO TOTAL"	"SIND ATO"
## [557]	"REJOS"	"CABEZA Y PUÑO"	"LE TIRO MOTO"	"CONTUNDENTE PU"
## [561]	"ABLACION CLITO"	"UN PLATO Y LAS"	"INSULTOS AMENZ"	"GOLPE PARED"
## [565]	"EMPUJON Y CAYO"	"INSULTOS Y GOL"	"casco de moto"	"FUERZA CORPORA"
## [569]	"laceraciones"	"puñetazos"	"INSULTOS GOLP"	"GOLPES Y INSUL"
## [573]	"ABUSO"	"misoprostol"	"puños cachetad"	"INSULTOSHUMIL"
## [577]	"SILLA"	"golpes contund"	"INSULTOSGOLPE"	"ABORTO"
## [581]	"trompada"	"DESCONOCIDOS"	"CYTOTEC"	"caidas insult"
## [585]	"CONTROL REMOTO"	"puños-arañazos"	"no definido"	"GOLPE PUÑOS"
## [589]	"CAIDAS"	"insultoshumil"	"SUS LIQUIDA DE"	"ACTO CONSENTID"
## [593]	"insultos amem"	"Empujon"	"SIN DERECHO A"	"mal trato"
## [597]	"abandono"	"mano abierta"	"corto contunde"	"no datos"
## [601]	"golpes puños"	"maniobras abor"	"LAPICERO CHUZO"	"machete piedr"
## [605]	"PUÑO EN POMULO"	"miembros super"	"ABORTO PROVOCA"	"rodillazos en"
## [609]	"CORRE PUÑOS"	"GOLPES CON UN"	"amenasas amena"	"UÑAS PATADA"
## [613]	"INSULTOS -GOLP"	"TORSION EXTREM"	"zapato"	"ALCHOL"
## [617]	"Golpe- Insulto"	"PLANCHA"	"FORSEJEO"	"golpe contuden"
## [621]	"CON CABLE"	"CON TODO"	"AGUA HERVIDA"	"golpeada"
## [625]	"DINERO"	"NO HAY ARMAS"	"negligencia"	"EMPUJADA"
## [629]	"CASCO MOTO"	"AGRESIONFISICA"	"abandonosocial"	"golpes manos"
## [633]	"violencia gest"	"neligencia"	"CONFLICTOS ENT"	"nada"
## [637]	"CON EL PUÑO"	"MANO PUÑO"	"APRETON Y SACU"	"MANO CERRADA"

```

## [641] "PATADAS -PUÑOS" "CONTUNDENTE CA" "CORREAPUÑOS" "control remoto"
## [645] "UÑAS DE LAS MA" "BARILLA PLATI" "golpe con puño" "no registra"
## [649] "MORDEDURAS" "GOLPES PUÑO" "GOLPE EN LA CA" "puños cachet"
## [653] "NN" "CONTUSIONES" "CACHETA" "INTENTO PEGAR"
## [657] "golpes amenaza" "contusiones" "CC" "aruñazos"
## [661] "indiferencia" "PATADAS PUÑOS" "ABUSO SEXUAL" "TACON ZAPATO"
## [665] "amenzas" "puños cabeza y" "u;as" "manos y pies"
## [669] "Ccontundente" "amenazasinsul" "HUMILLAINSULTA" "insultos humi"
## [673] "AMENASAS" "desconocido" "MANIPULACION" "estrujon"
## [677] "PUÑO MULETA" "COCAINA" "PLANCHA SE QUE" "arma de fuego"
## [681] "GOLPEADA A PUÑ" "ContundentInsu" "xx" "AHORCAMIENTOCA"
## [685] "AGARRA FUERTE" "CASCO DE MOTO" "ABANDONO NEGLI" "MANOS RASGUÑOS"
## [689] "APRIETA MANDIB" "GOLPES EN SUEL" "ARUÑETAZOS" "GOLPESARAÑAZO"
## [693] "CORREA CABLE" "PUÑOS - PIE" "GOLPES CON CAB" "CONTRA REJA"
## [697] "PTADAS Y PUÑOS" "LADRILLO Y PUÑ" "PUERTA" "caida auto"
## [701] "insultos-amen" "TIRARLE DEL PE" "machete" "las uñas"
## [705] "NO REFIERE" "correa o chami" "MISOPROSTOL" "CASTIGOS"
## [709] "ZARANDEO" "golpes y grito" "PATADA HALAR E" "GOLPES-PUÑOS"
## [713] "GOLPES Y GRITO" "SUST IRRITANT"
##
## $otro_mec
## [1] NA "1" "2" "3" "4"
##
## $cual_o_mec
## [1] NA "ABANDONO" "VIOLENCIA PSIC" "TUZARLE EL CAB"
## [5] "MALTRATO FISIC" "CONFLICTO FAMI" "TEMOR SEGUN MA" "contundente"
## [9] "INSU-HUMI-AMEN" "gritos" "INSUL-HUM-AMEN" "VIOLENCIA FISI"
## [13] "INSU-HUM-AMEN" "INSU-HUM-AMENA" "INSULT-AMENAZA" "PUÑO"
## [17] "INSULTO-HUMILL" "INSU-AMENA" "INSULTO-AMENAZ" "sin dato"
## [21] "NO APOYO ECONO" "INSUL-HUMI-AME" "AMENAZACUCHILL" "negligencia"
## [25] "caidas" "AGRESION FISIC" "EXHIBICIONISMO" "NEGLIGENCIA"
## [29] "fuerza" "AMENAZAS" "INSULTOS" "GOLPES"
## [33] "OFRECIMIENTO D" "QUE ME MATA" "chantaje viole" "chantajes"
## [37] "NINGUNO" "GOLPE" "ROBO" "VERBAL Y SICOL"
## [41] "insultos" "DIFAMACIONES" "SIN DATO" "chantaje"
## [45] "INSULTOS Y HUM" "12" "1-2-3" "ins-humi-amen"
## [49] "ARMA CORTANTE" "PRIVACION DE A" "1 23" "INCOMPRENSION"
## [53] "DAÑO DE ROPA Y" "132" "insultos-amen" "AMENAZA"
## [57] "golpes" "INSUAMENAHUM" "PROYECTIL ARMA" "INSHUMIAMEN"
## [61] "INSU-AMEN-HUMI" "INSUL - AMENAZ" "INSULT y AMENA" "INSUL y AMENAZ"
## [65] "manipulacion g" "INSULTOS-HUMIL" "INSUL-GOLPE" "agresivo"
## [69] "NO RESPONDE" "21:30" "06:00" "12:00"
## [73] "18:00" "15:00" "TENSION" "1 Y 3"
## [77] "IGNORA" "OTROS" "DESCUIDO" "AHORCAMIENTO"
## [81] "CONTUNDENTE" "CUBIERTA" "VARIOS" "TODAS LAS ANT"
## [85] "TODAS LAS ANTE" "TODAS" "TODAS ANTERIOR" "TODAS ANT"
## [89] "NO APLICA" "NINGUNA" "TODAS LAS ANTR" "TODAS LAS ATER"
## [93] "NA" "MIEDO" "PUÑOS PATADAS" "VIOLENCIA"
## [97] "MACHETE" "IDEACION" "golpe" "MAL PSICOLOGI"
## [101] "APUÑALO" "correa - surri" "CERVEZA" "golpe con puño"
## [105] "LATIGAZOS" "intoxicacion" "CACHETADAS" "NAVAJA"
## [109] "CORTANTE" "AGRESIONES VER" "ninguno" "DESCONOCIDO"
## [113] "SOCOLOGICO" "CAIDA INSULTO" "abandono" "INSULTOSHUMIL"
## [117] "SICOLOGICO" "MALTRATO" "PALABRAS" "maltrato verba"

```

```
## [121] "verbalmente"      "palabras"      "INSULTO"      "DESCNOCIDO"
## [125] "GRITOS"           "UTILIZA MACHET" "CARTA DE AMOR" "SIN INFORMACIO"
## [129] "NELIGENCIA"       "VERBAL"        "INSULTOS HUMIL" "VILENCIA FISIC"
## [133] "puños"            "AMENAZA PERTUR" "AMENAZAS INSUL" "ABANDONO FLIAR"
## [137] "palos y puños"    "CONSU DROGAS"  "ABUXO SEXUAL"  "mordedura"
## [141] "INDUCCION A DR"   "SEDUCCION"     "maltrato gesta" "AUTOINFLINGIDO"
## [145] "RIÑAS - PADRES"   "LE DAÑA PERTE" "drogadicta lac" "AMENAZA ARMA"
## [149] "INTERNET"         "CASCO UNA MOTO" "PRIVACION CONT" "insultos golpe"
## [153] "GOLPES ESPALDA"   "RECHAZO"       "CAIDAS"        "violen gestaci"
## [157] "AUTORITARISMO"    "PSICOLOGICO"   "COACCION"      "TODOS"
## [161] "cortantecorto"    "PROBLEMAAS"    "MORDEDURA"    "no colabora co"
## [165] "CONSUMO DE SPA"   "EXPOSI AGRESIO" "insultos humil" "otros"
## [169] "amenaza muerte"   "presencia de p" "EXPUL VIVIENDA" "PRESION SEXUAL"
## [173] "manipulacion"     "pobre respaldo" "ENTRE ADULTOS"  "COND SOC INADE"
## [177] "quemadura x so"   "POCO APOYO MAM" "PSICOLOGICA"
##
## $arma
## [1] NA      "2"      "3"      "4"      "15"     "1"      "11"     "12"     "16"     "13"     "14"
##
## $mecanismo_utilizado_para_la_agresion
## [1] NA      "4"      "15"     "3"      "2"      "1"      "11"
## [8] "13"     "16"     "14"     "12"     "7300000"
```

Se observa que la variable **armas** está tomando valores en NA y valores inconsistentes según el diccionario: 5,6,7,8,9 y 10. Por ejemplo:

```
## # A tibble: 10 x 7
##   armas arma cual_o_mec      otra_arma otro_mec mecanismo_utilizado_par~1      n
##   <chr> <chr> <chr>      <chr>      <chr>      <chr>      <int>
## 1 <NA> <NA> VIOLENCIA FISI <NA>      4      <NA>      2
## 2 <NA> <NA> TODOS      <NA>      4      <NA>      1
## 3 <NA> 13 <NA>      <NA>      <NA>      <NA>     31
## 4 <NA> <NA> fuerza      <NA>      4      <NA>      1
## 5 <NA> <NA> cortantecorto <NA>      4      <NA>      1
## 6 <NA> <NA> CORTANTE      <NA>      4      <NA>      1
## 7 <NA> <NA> SIN DATO      <NA>      4      <NA>      2
## 8 <NA> <NA> INSULT y AMENA <NA>      4      <NA>      1
## 9 <NA> <NA> INSU-HUM-AMEN <NA>      4      <NA>      6
## 10 <NA> <NA> 06:00      <NA>      2      <NA>      1
## # i abbreviated name: 1: mecanismo_utilizado_para_la_agresion
```

Sin embargo, ninguna de las otras variables toma valor en estos casos inconsistentes como para reemplazar información. Entonces lo que se hace es que se completa información para los casos de NA en **armas** con el valor de las demás variables, a excepción de **cual_o_mec**, porque en los casos en que esta última variable toma valor también toma valor **otro_mec** y esa sí está en la codificación requerida. A su vez, se garantiza que **armas** tome valor solo si la modalidad de violencia es 1, en caso contrario, se pone “No aplica”

Quemaduras (no obligatoria): este conjunto de variables deben tomar valor en caso de que el mecanismo de agresión haya sido 12 = Quemaduras por fuego o llama, 13 = Quemaduras por ácido, álcalis, o sustancias corrosivas y 14 = Quemadura por líquido hirviendo. La mayoría de variables indican la parte de la quemadura (**que_**), y las demás, el grado (**cla_gra**) y extensión (**ext_que**) de la misma.

```
## $que_cara
```



```

##
##      1      2  44071  44112 7300000  <NA>
##    812  52202      1      1      1  824137
##
## $que_cuello
##
##      1      2  43813  <NA>
##    440  52575      1  824138
##
## $que_mano
##
##      0      1      2  <NA>
##      1    468  52547  824138
##
## $que_pie
##
##      1      2  27355  <NA>
##    176  52839      1  824138
##
## $que_pliegu
##
##      0      1      2  <NA>
##      2    114  52902  824136
##
## $que_genita
##
##      1      2  72521  89950  <NA>
##    133  52883      1      1  824136
##
## $que_tronco
##
##      0      1      2  <NA>
##      1    853  52165  824135
##
## $que_miesup
##
##      1  14268      2  <NA>
##    743      1  52274  824136
##
## $que_mieinf
##
##      1      2  <NA>
##    534  52485  824135

```

Se observa que hay casos donde las variables están tomando valores inconsistentes, estos casos se cambian a NA

También, se observa que en los casos en que no hay quemaduras, estas variables contienen valores faltantes (NA), lo que puede generar dificultades en los análisis. Entonces, se transforman los valores NA en una categoría explícita como “No aplica”. Y a su vez, se garantiza que estas variables tomen valor únicamente en los mecanismos de agresión correctos

Lo mismo se hace con la variable **cla_gra**, se cambia a “No aplica” los casos donde el mecanismo no es 12,13 o 14. Esta variable toma los siguientes valores: 1 = primer grado, 2 = segundo grado y 3 = tercer grado

```
##      1      2      3  NA's
##    474    1725    59 874896
```

Finalmente, se encontró que la variable **ext_que** está tomando valores inconsistentes. Los valores que debe tomar son 1 = menor o igual a 5%, 2 = 6%-14%, 3 = mayor o igual a 15%. Se cambia estos valores a NA y se garantiza que esta variable solo tenga valor cuando mecanismo sea 12,13 o 14

```
##      1      2      3    31  NA's
##    866    1124    270     1 874893
```

Escenario (obligatoria)

Corresponde al lugar donde ocurrió la agresión. Toma valores como: 1 = Vía Pública, 2 = Vivienda, 3 = Establecimiento educativo, 4 = Lugar de trabajo, 7 = Otro, 8 = Comercio y áreas de servicios (Tienda, centro comercial, etc), 9 = otros espacios abiertos (bosques, potreros, etc), 10 = Lugares de esparcimiento con expendio de alcohol, 11 = Institución de salud y 12 = Área deportiva y recreativa.

```
##      1     10     11     12     2     3     4     5     6     7     8
## 107703  7200  3185  1173 657013 12740  6257  1304   141 62206  7191
##      9  NA's
## 10975    66
```

Se observa que esta variable toma valores 5 y 6 que no aparecen definidos en el diccionario ni fichas de notificación.

Adicional, la base de datos tiene otra variable (**otro_esce**) que aparentemente representa esta característica y no aparece definida en el diccionario:

```
## DESCONOCIDO      SIN DATO      MOTEL      HOTEL      HOSPITAL desconocido
##      117      98      55      52      50      44
##      FINCA SIN INFORMAC      sin dato      POTRERO      hospital      CASA
##      44      33      31      30      29      27
##      CPN CASA AGRESOR      SIN DATOS      casa      MONTE      motel
##      25      23      20      19      19      19
##      CLINICA RESIDENCIA      hotel sin informac      TIENDA      CAMPO
##      18      18      16      16      15      14
##      CONTROL      no dato      NO SABE      consulta      NA      NO DATO
##      14      14      14      13      13      13
##      cpn      SD      CAFETAL CASA DEL AGR CENTRO MEDIC      NINGUNO
##      12      11      9      9      9      9
##      2      CALLE casa agresor      finca      HOGAR NO ESPECIFIC
##      8      8      8      8      8      8
##      RIO      RURAL      CENTRO CENTRO DE SA CONSULTORIO      DISCOTECA
##      8      8      7      7      7      7
##      PARQUE      SALUD      ZONA RURAL      CASA AMIGA CENTRO SALUD      CONSULTA
##      7      7      7      6      6      6
##      IPS      na NO RECUERDA NO REFIERE NO SE SABE RESTAURANTE
##      6      6      6      6      6      6
##      sin datos SIN INF VEREDA AREA RURAL CARRETERA CASA VECINA
##      6      6      6      5      5      5
##      CASA VECINO clinica NO APLICA NO DICE NO REGISTRA OTRO
##      5      5      5      5      5      5
```

```
## UBA ENVIGADO      VEHICULO      vereda      zona rural      BAR      CAMINO
##          5          5          5          5          4          4
## CAMPO ABIERT casa abuela  CASA ABUELA  CASA NOVIO      COLEGIO      DESCONOCE
##          4          4          4          4          4          4
##          FIESTA      GESTACION      GUARDERIA      ips      NEGLIGENCIA      no recuerda
##          4          4          4          4          4          4
## NO RESPONDE      PLAYA      potrero      salud      TELEFONO      TROCHA
##          4          4          4          4          4          4
##          VIENTRE      ABANDONO      (Other)      NA's
##          4          3          796      875049
```

Se observa que esta última variable no está normalizada, por ende, se utilizará para completar información de la variable **escenario**. Al analizar los casos donde **escenario** es 5, 6 y NA, se obtiene:

```
## # A tibble: 5 x 3
##   escenario otro_esce      n
##   <chr>      <chr>    <int>
## 1 5          <NA>    1304
## 2 6          <NA>    141
## 3 <NA>      1         1
## 4 <NA>      2         6
## 5 <NA>      <NA>     59
```

Solo se podría recuperar información para 7 casos. Entonces se completa esta información y los casos con valor 5 y 6 se cambia a NA

Luego, se elimina la variable **otro_esce**

Ámbito lugar (obligatoria)

Representa el ámbito de la violencia según lugar de ocurrencia. Puede tomar valores como: 1 = Escolar, 2 = Laboral, 3 = Institucional, 4 = Virtual, 5 = Comunitario, 6 = Hogar y 7 = Otros ámbitos. Es una variable obligatoria

```
##      1      2      3      4      5      6      7      NA's
## 10695 12703 4381 1844 33976 463772 128192 221591
```

Presencia de alcohol o sustancias (obligatoria)

En la base de datos se encuentran dos variables que indican si había presencia de alcohol u otra sustancia en la víctima: **sust_vict** y **presencia_de_alcohol_u_otra_sustancia_en_la_victima**. La primer variable tiene el nombre que aparece en el diccionario de datos y es obligatoria

```
## # A tibble: 9 x 3
##   sust_vict presencia_de_alcohol_u_otra_sustancia_en_la_victima      n
##   <chr>      <chr>                                          <int>
## 1 1          <NA>                                          16692
## 2 2          <NA>                                          265998
## 3 M          <NA>                                           7
## 4 <NA>      0                                           1
## 5 <NA>      1                                          28830
## 6 <NA>      2                                          560093
```

## 7 <NA>	3114939261	1
## 8 <NA>	3123952779	1
## 9 <NA>	<NA>	5531

Se observa que hay 28653 casos que toma valor sí(1) y 556310 no(2) en **presencia_de_alcohol_u_otra_sustancia_en_la_victima** pero NA en **sust_vict**, entonces se completará esta última variable con ellos. Las inconsistencias se cambian a NA

Luego, se elimina la variable **presencia_de_alcohol_u_otra_sustancia_en_la_victima**

Atecedente de violencia (obligatoria)

Indica si la persona ha sido violentada con anterioridad. Es una variable obligatoria.

##	0	1	2	3	4	43880	5	6	NA's
##	2	172777	704316	1	2	1	1	3	51

Los valores con inconsistencia se cambian a NA

Hecho dentro del conflicto armado (obligatoria)

Representa si el caso se dio en el marco del conflicto armado

##	1	2	44000	44097	E	M	V	NA's
##	19735	851928	1	1	2	2	1	5484

Los valores con inconsistencia se cambian a NA

Información del agresor

Es importante mencionar que en las bases de datos proporcionadas no hay información respecto al parentesco con la víctima, como sí la hay en MEData y se piden en las fichas de notificación.

Edad agresor (obligatoria)

##	0	1	2	5	6	7	8	9	10	11	12
##	586445	5	13245	363	130	142	193	171	1211	596	1224
##	13	14	15	16	17	18	19	20	21	22	23
##	2177	3350	4316	5975	7350	8367	7312	10361	7303	9084	9181
##	24	25	26	27	28	29	30	31	32	33	34
##	8943	11536	8243	8088	9489	6893	15302	5391	7603	6731	6255
##	35	36	37	38	39	40	41	42	43	44	45
##	9607	5868	5235	6544	4366	9977	2847	4548	3512	2711	5322
##	46	47	48	49	50	51	52	53	54	55	56
##	2592	2534	3046	2093	4986	1391	2046	1667	1570	1914	1339
##	57	58	59	60	61	62	63	64	65	66	67
##	1051	1147	765	2153	452	714	590	561	784	360	378
##	68	69	70	71	72	73	74	75	76	77	78
##	392	197	745	141	238	179	192	253	149	98	127
##	79	80	81	82	83	84	85	86	87	88	89
##	68	195	52	64	45	51	50	42	28	23	22
##	90	91	92	93	94	95	96	97	98	99	
##	45	5	3	6	7	5	3	3	8	6028	

Se ve que esta variable (cuya unidad de medida es años), contiene edades muy bajas para el agresor, lo cual parece ser una inconsistencia en la variable. Incluso solamente analizando la proporción de edades iguales a 0 es de 66.858% de los registros que presentan este problema y de acuerdo con las fichas de notificación de violencia disponibles, no en todas se hace esta pregunta.

Por tanto los valores de 0 o de edades muy pequeñas podrían corresponder a valores faltantes de los años restantes de notificaciones en las que no se pregunta esto. Así, la variable tiene bastantes valores faltantes, por lo tanto es necesario eliminarla del análisis.

Sexo (no obligatoria)

```
##      21792 3218244774      38240      F      I      M      SD
##          1          1          1    163110    1073    694021    4244
##      NA's
##    14703
```

Se observa que tres registros están tomando valores numéricos, estos casos puede corresponder a fechas en la base original y que al cargar se convirtieron en número. Además, se encuentran registros con valor **SD**, que pueden significar “Sin dato”. En todos los casos se convierte a NA

Convivencia con la víctima (obligatoria)

Esta variable indica si la víctima tenía o no convivencia con el agresor

```
##      1      2  78783  NA's
## 433088 412620      1 31445
```

Solo se encuentra un registro con un valor inconsistente, se cambia a NA

Información de la atención

Lugar de notificación

Según el diccionario de datos, las variables relacionadas al código DIVIPOLA de departamento y municipio son obligatorias

Departamento: **departamento_notificacion** representa el nombre del departamento donde se notificó el caso y **cod_dpto_n** su respectivo código. Para verificar la concordancia de los códigos y nombres se utiliza la base oficial de DIVIPOLA:

1. Se comienza analizando los departamentos que no se encuentran en la lista de DIVIPOLA:

```
## # A tibble: 18 x 3
##   cod_dpto_n departamento_notificacion cantidad
##   <chr>      <chr>                    <int>
## 1 08        ATLANTICO                    27852
## 2 11        BOGOTA                      106965
## 3 13        BOLIVAR                       24329
## 4 15        BOYACA                       27424
## 5 18        CAQUETA                       7940
```

##	6	23	CORDOBA	23417
##	7	27	CHOCO	1821
##	8	44	GUAJIRA	8107
##	9	54	NORTE SANTANDER	21829
##	10	63	QUINDIO	16536
##	11	76	VALLE	104526
##	12	88	SAN ANDRES	805
##	13	94	GUAINIA	895
##	14	97	VAUPES	1309
##	15	9996	0	1
##	16	<NA>	001	1
##	17	<NA>	11	2
##	18	<NA>	44093	1

En la mayoría de los casos no se encuentran porque tienen diferencia de escritura. Y en los demás, se trata de números que en caso de no corresponder a la codificación, se convierten a NA

2. Analizando que códigos no están en la lista. Se encontraron los siguientes:

```
## # A tibble: 3 x 3
##   cod_dpto_n departamento_notificacion cantidad
##   <chr>      <chr>                    <int>
## 1 9996      <NA>                        1
## 2 <NA>      Bogotá, D.c.                      2
## 3 <NA>      <NA>                          2
```

Solo se encontró un caso donde el código no está en la lista oficial, se cambia a NA

3. Los casos donde hay discordancia entre el código y el nombre del departamento son:

```
## # A tibble: 0 x 3
## # i 3 variables: cod_dpto_n <chr>, departamento_notificacion <chr>,
## #   cantidad <int>
```

No hay discordancias.

Municipio: **municipio_notificacion** representa el nombre del departamento y **cod_mun_n** su respectivo código. Este código está compuesto por los últimos tres dígitos del código Divipola para cada municipio

1. Primero se verifica que códigos no están en la lista oficial, se encontraron los siguientes:

##	#	A tibble:	4 x 4
##	cod_mun_n	municipio_notificacion	departamento_notificacion cantidad
##	<chr>	<chr>	<chr> <int>
##	1	S	3102038727 <NA> 1
##	2	<NA>	11 <NA> 1
##	3	<NA>	11001 Bogotá, D.c. 2
##	4	<NA>	44093 <NA> 1

Ese valor inconsistente se cambia a NA

2. Se verifica que nombres no están en la lista oficial. Por ejemplo:

```
## # A tibble: 10 x 4
##   cod_mun_n municipio_notificacion departamento_notificacion cantidad
##   <chr>      <chr>                  <chr>                  <int>
## 1 25843     UBATE                      Cundinamarca           1407
## 2 27135     CANTON DE SAN PABLO (MANAGRU) Chocó                   8
## 3 27006     ACANDI                      Chocó                   33
## 4 13620     SAN CRISTOBAL               Bolívar                 87
## 5 41668     SAN AGUSTIN                 Huila                   1497
## 6 23189     CIENAGA DE ORO              Córdoba                 750
## 7 25817     TOCANCIPA                   Cundinamarca           1860
## 8 15368     JERICO                      Boyacá                  61
## 9 15839     TUTAZA                      Boyacá                  8
## 10 15820    TOPAGA                      Boyacá                  85
```

La mayoría de inconsistencias corresponden a diferencia en escritura, por lo tanto, se modifica la escritura igual a la lista oficial

3. Verificar concordancia entre código y nombre

```
## # A tibble: 0 x 4
## # i 4 variables: cod_mun_n <chr>, municipio_notificacion <chr>,
## #   nombre_municipio <chr>, cantidad <int>
```

No hay discordancias.

Distrito especial Se crea esta variable para identificar los casos donde la víctima notificó en uno de los distrito especiales de Colombia, los cuales son:

1. **Bogotá:** Distrito Capital.
2. **Barranquilla:** Distrito Especial, Industrial y Portuario.
3. **Santa Marta:** Distrito Turístico, Cultural e Histórico.
4. **Cartagena:** Distrito Turístico, Cultural e Histórico.
5. **Buenaventura:** Distrito Especial, Industrial, Portuario, Biodiverso y Ecoturístico.
6. **Riohacha:** Distrito Especial, Turístico y Cultural.
7. **Medellín:** Distrito Especial de Ciencia, Tecnología e Innovación.
8. **Mompox:** Distrito Especial Turístico, Cultural e Histórico.
9. **Barrancabermeja:** Distrito Especial Portuario, Industrial, Turístico y Biodiverso.
10. **Turbo:** Distrito Especial Portuario, Logístico, Turístico, Industrial y Comercial.
11. **Tumaco:** Distrito Especial, Industrial, Portuario, Biodiverso y Ecoturístico.
12. **Cali:** Distrito Especial, Deportivo, Cultural, Turístico, Empresarial y de Servicios.

Cuando esta variable toma valor 1 significa que se trata a un distrito especial, y cuando toma valor 2 significa que no se trata de un distrito especial.

Tipo de seguridad social (obligatoria)

Representa el tipo de régimen en salud, donde: C = contributivo, S = subsidiado, P = excepción, E = especial, N = no asegurado e I = indeterminado/pendiente

```
##      C      E      I      N      P      S  NA's
## 333191  3350  31506  40936  10664  457502    5
```

Datos epidemiológicos (obligatorias)

La base cuenta con una variable que presenta la semana epidemiológica (**semana**) y su respectivo año (**año**)

- **semana:**

```
##      01      02      03      04      05      06      07      08      09      1      10      11      12
## 13747  8295  9116  9541  10469  10449  10732  10527  11515  3660  17598  17587  15943
##      13      14      15      16      17      18      19      2      20      21      22      23      24
## 15057 15811 15908 15861 16096 17094 17326  3860 18154 16991 17256 17166 16486
##      25      26      27      28      29      3      30      31      32      33      34      35      36
## 16732 16264 16671 16990 16935  4847 17314 17391 16680 17192 17261 18043 18681
##      37      38      39      4      40      41      42      43      44      45      46      47      48
## 18345 19159 18419  4985 18430 17687 17200 17674 17263 17054 17010 17109 16826
##      49      5      50      51      52      53      6      7      8      9  NA's
## 17088  5420 16444 15478 15881  2367  5781  6170  5953  6157    8
```

- **año:**

```
##      2013      2014      2015      2016      2017      2018      2019      2020      2021      2022      2023
## 34356  49511  56809  71827  75721  86966  92922  80989  92308 110895 124850
```

De acuerdo a lo investigado la semana epidemiológica se determina a partir de la fecha del hecho o notificación según el sistema o estudio. Sin embargo, en las fuentes de información disponible no se especifica. Por ende, buscando ser consistentes, se decide eliminar estas variables y quedarse con la variable **fec_not**, que hasta el momento parece ser la mejor opción para temporalidad

Hospitalización (no obligatoria)

Indica si la víctima requirió hospitalización

```
##      1      2  NA's
## 130799 746350    5
```

Atención en salud mental (obligatoria)

Indica si la víctima recibió o no atención en salud mental

```
##      1      2      24      31  NA's
## 418079 453541    1    1  5532
```

Se cambia a NA los casos donde la variable toma valores diferentes a 1 y 2

Laboratorios (no obligatoria)

En la base se encuentran tres variables que representan si se realizó o no un examen de laboratorio específico: Profilaxis ITS-VIH (**sp_its**), Hepatitis B (**prof_hep_b**) y Profilaxis Otras ITS (**prof_otras**). Sin embargo, estas variables aplican únicamente para los casos donde la modalidad de violencia sea 6 = Acceso carnal, 7 = Explotación sexual, 10 = Trata de personas y 14 = Otras violencias sexuales. Por ejemplo,

- **Profilaxis ITS-VIH:**

```
## # A tibble: 10 x 3
##   sp_its def_naturaleza    n
##   <chr>  <chr>          <int>
## 1 1      7              256
## 2 1     15              2
## 3 2      1          13756
## 4 2     10           142
## 5 2     14          17999
## 6 1      6          50584
## 7 2      3          12834
## 8 <NA> 12          33956
## 9 2     15           110
## 10 <NA> 7              7
```

- **Hepatitis B:**

```
## # A tibble: 10 x 3
##   prof_hep_b def_naturaleza    n
##   <chr>      <chr>          <int>
## 1 2          14          18313
## 2 1          10           43
## 3 1          15           2
## 4 <NA>       2          81121
## 5 1          5           115
## 6 2          6         111989
## 7 <NA>       14           50
## 8 <NA>       7           44
## 9 1          1           4
## 10 <NA>      10           6
```

- **Profilaxis Otras ITS:**

```
## # A tibble: 10 x 3
##   prof_otras def_naturaleza    n
##   <chr>      <chr>          <int>
## 1 <NA>       6          10952
## 2 <NA>      12          33955
## 3 <NA>       3          84608
## 4 2          15           109
## 5 1          15           3
## 6 1          14          1839
## 7 2          12          2948
## 8 2          14         18394
## 9 2          1         12379
## 10 <NA>      5          20795
```

Se cambia a NA los valores incorrectos y a “No aplica” los casos de violencia diferente a los mencionados

Anticoncepción de emergencia (no obligatoria)

Esta variable **ac_anticon** indica si la víctima requirió anticoncepción de emergencia. Aplica únicamente para los casos donde la modalidad de violencia sea 6 = Acceso carnal, 7 = Explotación sexual, 10 = Trata de personas y 14 = Otras violencias sexuales

```
## # A tibble: 28 x 3
##   ac_anticon def_naturaleza     n
##   <chr>      <chr>         <int>
## 1 1          1             922
## 2 1          10             27
## 3 1          14            1275
## 4 1          2             301
## 5 1          3             78
## 6 1          5             78
## 7 1          6            33507
## 8 1          7             182
## 9 2          1            69367
## 10 2         10             158
## # i 18 more rows
```

Se cambia a NA los valores incorrectos y a “No aplica” los casos de violencia diferente a los mencionados

Orientación (no obligatoria)

Esta variable **ac_ive** indica si la víctima recibió orientación para Interrupción Voluntaria del Embarazo (IVE). Aplica únicamente para los casos donde la modalidad de violencia sea 6 = Acceso carnal, 7 = Explotación sexual, 10 = Trata de personas y 14 = Otras violencias sexuales

```
## # A tibble: 28 x 3
##   ac_ive def_naturaleza     n
##   <chr>  <chr>         <int>
## 1 1       1             2208
## 2 1       10             49
## 3 1       14            2262
## 4 1       2             514
## 5 1       3             159
## 6 1       5             210
## 7 1       6            48177
## 8 1       7             302
## 9 2       1            68079
## 10 2      10             136
## # i 18 more rows
```

Se cambia a NA los valores incorrectos y a “No aplica” los casos de violencia diferente a los mencionados

Informe a autoridades competente (obligatoria)

El diccionario de datos especifica que la variable que indica si se informó a la autoridad competente es **inf_aut** y las fichas que se entiende por autoridad competente a: policía judicial (URI, CTI), fiscalía, policía nacional.

Sin embargo, en la base de datos del 2013 se encontraron dos variables adicionales que pueden estar relacionadas con **inf_aut** dado el nombre que llevan: **inf_autpj** y **inf_autfis**

```
## # A tibble: 12 x 4
##   inf_aut inf_autpj inf_autfis     n
##   <chr>   <chr>   <chr>   <int>
## 1 1      1      1         2
## 2 1      1      2        32
## 3 1      2      1         6
## 4 1      2      2        29
## 5 1      <NA>   <NA>   450881
## 6 2      <NA>   <NA>  426143
## 7 3      <NA>   <NA>         1
## 8 5      <NA>   <NA>         1
## 9 B      <NA>   <NA>         1
##10 P      <NA>   <NA>         4
##11 p      <NA>   <NA>         1
##12 <NA>   <NA>   <NA>        53
```

Aún así, se observa que cuando las dos variables toman valores, **inf_aut** toma valor de 1 (sí) porque alguna de las otras dos toma valor de 1 (sí). Lo que da a entender que **inf_aut** es más general y realmente no se necesita la unión de las tres variables. Solo hay 32 casos donde **inf_autpj** y **inf_autfis** son 2 (No) y **inf_aut** es 1 (Sí), se decide dejarlo así teniendo en cuenta que puede tratarse de que no reportaron a esas autoridades sino a otra.

Luego, se convierte a NA los valores **inf_aut** que no son correctos y se elimina entonces las otras dos variables

Ahora bien, el diccionario de datos indica que la variable obligatoria **remit_prot** toma como valor si la víctima fue remitida o no a protección. Pero en la base también se encuentra otra variable llamada **r_protect**

```
## # A tibble: 11 x 3
##   remit_prot r_protect     n
##   <chr>     <chr>   <int>
## 1 1      1         11
## 2 1      2         4
## 3 1      <NA>   348808
## 4 2      1         1
## 5 2      2        10
## 6 2      <NA>  452877
## 7 31     <NA>         1
## 8 5      <NA>         2
## 9 <NA>   1       13473
##10 <NA>   2       20823
##11 <NA>   <NA>   41144
```

Se encontró que los casos con valor en **r_protect** corresponde a casos de la base del 2013, pero algunos de estos también están tomando valor en **remit_prot**. Se decide conservar la variable **remit_prot** pero

eliminando los valores incorrectos, y cambiando los casos al valor de **r_protec** cuando esta última variable no es NA. Luego, se elimina la variable **r_protec**

Recolección evidencia medicina legal (no obligatoria)

```
## # A tibble: 30 x 3
##   def_naturaleza evi_mlegal      n
##   <chr>          <chr>    <int>
## 1 1              1        6570
## 2 1              2       84356
## 3 1             <NA>    358250
## 4 10             1         32
## 5 10             2        147
## 6 10             <NA>        11
## 7 12             1        234
## 8 12             2       7656
## 9 12             <NA>    29023
## 10 14            1       1799
## # i 20 more rows
```

Esta variable indica si se recolectó o no evidencia médico legal y solo se realiza en caso de violencias sexuales, en opciones 6, 7, 10, 14 y 15, según el diccionario de datos. Por lo tanto, en los casos que no son violencia sexual se asigna “No aplica” y se cambia a NA el caso con valor de 3.

Se observa también que hay casos que no fueron violencia sexual pero indican que sí se recogió evidencia, ante estos casos se dejan tal cual

Condición final de la víctima al momento de la notificación (obligatoria)

Según los datos esta variable toma tres posibles valores: 0 = No sabe, no responde, 1 = Vivo, 2 = Muerto. Sin embargo, el formato de notificación 2024 indica que “0” solo aplica cuando se capte el caso por BAI (Brotes, Alertas e Incidencias) y se desconoce el dato, o para defectos congénitos cuando la unidad de medida es “0”. Dado que el evento de interés no es ninguno de los mencionados, se cambia los casos con “0” por NA.

Causa básica de defunción (no obligatoria): Esta variable corresponde al diagnóstico CIE-10 (Ver) que ocasionó la muerte de la víctima y que está relacionado con el evento de interés. Toma un valor si la variable **con_fin** es igual a 2 (muerto), el diccionario indica que en este caso es obligatorio registrar esta información

```
## [1] NA      "R571" "S129" "8888" "R961" "R456" "S212" "I469" "D649" "J159"
## [11] "Z719" "X934" "E43X" "Q079" "S019" "B948" "P95X" "S218" "T794" "X990"
## [21] "R092" "W669" "S271" "S119" "A419" "S066" "A09X" "R98X" "T740" "R090"
## [31] "G936" "R579" "R578" "E43"  "S270" "R570" "Y229" "T742" "I219" "P243"
## [41] "K591" "A049" "I461" "T019" "T602" "I613" "M341" "S063" "B829" "J690"
## [51] "D696" "J22"  "S211" "W708" "E46"  "T141" "T600" "Y226" "W230" "J969"
## [61] "A09"  "W325" "R529" "X998" "Z540" "W320" "O038" "T149" "R942" "X994"
## [71] "A010" "S067" "G002" "G409" "W690" "Y871" "W661" "E440" "D62X" "9999"
## [81] "W340" "P072" "S062" "A059" "W737" "P942" "S311" "Y246" "W666" "O359"
## [91] "C959" "X930" "Y070" "J189" "Y350" "E46X" "X950" "X991" "T659" "S097"
## [101] "S219" "J81X" "O420" "X999" "T063" "S021" "A418" "S008" "T060" "P369"
## [111] "X954" "J942" "T146" "S099" "X938" "T317" "I609" "S260" "T789" "J46X"
## [121] "E149" "T200" "T749" "W168" "I509" "C168" "X958" "C189" "W328" "S069"
```

```
## [131] "S118" "P123" "W698" "O85X" "G934" "T71X" "M154" "P210" "I618" "E640"
## [141] "Z000" "S065" "P209" "O269" "X955" "S098" "J960" "R58X" "Q254" "X931"
## [151] "S317" "P363" "S061" "P549" "T536" "J80X" "I460" "J449" "J441" "T001"
## [161] "T010" "W160" "R99X" "W304" "W841" "I616" "T000" "V892" "T97X" "R060"
## [171] "S020" "G92X" "W229" "S198" "Y079" "T901" "X918" "R960" "J219" "W341"
## [181] "G932" "Y364" "Y009" "R69X" "Y091" "I64X" "K768" "S064" "S210" "Y000"
## [191] "B012" "K729" "S029" "P052" "Z614" "6" "T272" "J069" "B361" "I313"
## [201] "P368" "W660" "P073" "A412" "O06X" "S279" "Y899" "X700" "W738" "T319"
## [211] "B24X" "W650" "Y057" "I612" "R95X" "Y357" "I620" "I252" "W709" "J158"
## [221] "2" "S117" "J129" "E119" "K564" "1" "Y330" "A009" "Y360" "O95X"
## [231] "I409" "E40X" "E15X" "T75" "J22X" "P249" "J039" "J180" "Y210" "A05"
## [241] "V295" "A050" "O03X" "J440" "R64X" "O001" "S399" "O065" "X935" "S028"
## [251] "T930" "Y244" "Y061" "9998" "Y099" "P783" "T910" "Z711" "O149" "S202"
## [261] "S02" "E878" "W678" "W780" "K52" "W748" "I272" "R651" "T07X" "T650"
## [271] "W730" "T008" "I400" "Y339" "P93X" "8139" "P505" "S65" "W260" "R572"
## [281] "S272" "E271" "B509"
```

Primero, se verifica que códigos no son válidos utilizando como apoyo una base que contiene los códigos oficiales

```
## # A tibble: 20 x 2
##   cbmte      n
##   <chr> <int>
## 1 0001      1
## 2 1        1
## 3 2        1
## 4 6        1
## 5 8139      1
## 6 8888     52
## 7 9998      1
## 8 9999     31
## 9 A05       1
## 10 A09      3
## 11 E43      5
## 12 E46      5
## 13 J22      1
## 14 K52      1
## 15 O03X     1
## 16 O06X     1
## 17 S02      1
## 18 S65      1
## 19 T75      1
## 20 <NA> 876403
```

Se convierten estos valores a NA porque no hay manera de corregirlos sin sesgar.

```
## # A tibble: 266 x 3
##   con_fin cbmte      n
##   <chr>   <chr> <int>
## 1 1      <NA> 875973
## 2 2      A009      1
## 3 2      A010      1
## 4 2      A049      1
```

```
## 5 2      A050      1
## 6 2      A059      1
## 7 2      A09X     10
## 8 2      A412      1
## 9 2      A418      1
## 10 2     A419     17
## # i 256 more rows
```

Luego, en los casos en que **con_fin** (**condición final**) es igual a 1 (vivo), se cambia el valor de **cbmte** por “No aplica” para evitar inconsistencias y valores faltantes que realmente no son

Valores faltantes

Para analizar los valores faltantes es necesario excluir la variable **sem_ges** porque es un evento que depende de otro evento, entonces tendrá mucha información faltante que no necesariamente lo sea, solo que por ser variable numérica no es posible asignar un valor a los casos que no aplican sin que se vea afectado el análisis posterior de esta variable

##	Column	total_na	percent_na	total_empty	percent_empty
## 1	cod_pais_r	641409	73.124	0	0
## 2	pais_residencia	641409	73.124	0	0
## 3	nacionalidad	391241	44.603	0	0
## 4	nombre_nacionalidad	391241	44.603	0	0
## 5	estrato	363253	41.413	0	0
## 6	ident_gene	221818	25.288	0	0
## 7	orient_sex	221648	25.269	0	0
## 8	ambito_lug	221591	25.262	0	0
## 9	consum_spa	83717	9.544	0	0
## 10	mujer_cabf	77771	8.866	0	0
## 11	actividad	71928	8.200	0	0
## 12	remit_prot	41147	4.691	0	0
## 13	conv_agre	31446	3.585	0	0
## 14	evi_mlegal	22709	2.589	0	0
## 15	sexo_agre	18950	2.160	0	0
## 16	prof_hep_b	11144	1.270	0	0
## 17	prof_otras	11144	1.270	0	0
## 18	nom_grupo	8983	1.024	0	0
## 19	sust_vict	5541	0.632	0	0
## 20	ac_mental	5534	0.631	0	0
## 21	zona_conf	5491	0.626	0	0
## 22	cla_gra	4700	0.536	0	0
## 23	ext_que	4698	0.536	0	0
## 24	que_cara	4664	0.532	0	0
## 25	que_cuello	4663	0.532	0	0
## 26	que_mano	4663	0.532	0	0
## 27	que_pie	4663	0.532	0	0
## 28	que_pliegu	4662	0.531	0	0
## 29	que_genita	4662	0.531	0	0
## 30	que_tronco	4660	0.531	0	0
## 31	que_miesup	4661	0.531	0	0
## 32	que_mieinf	4659	0.531	0	0
## 33	armas	3597	0.410	0	0
## 34	municipio_residencia	2729	0.311	0	0

## 35	cod_mun_r	2662	0.303	0	0
## 36	dist_esp_r	2662	0.303	0	0
## 37	cod_dpto_r	1607	0.183	0	0
## 38	departamento_residencia	1607	0.183	0	0
## 39	escenario	1504	0.171	0	0
## 40	ac_anticon	1481	0.169	0	0
## 41	ac_ive	1481	0.169	0	0
## 42	cod_mun_o	1135	0.129	0	0
## 43	municipio_ocurrencia	1135	0.129	0	0
## 44	dist_esp_o	1135	0.129	0	0
## 45	cbmte	540	0.062	0	0
## 46	sp_its	389	0.044	0	0
## 47	con_fin	359	0.041	0	0
## 48	fec_hecho	162	0.018	0	0
## 49	def_naturaleza	98	0.011	0	0
## 50	antec	61	0.007	0	0
## 51	inf_aut	61	0.007	0	0
## 52	departamento_ocurrencia	51	0.006	0	0
## 53	cod_dpto_o	46	0.005	0	0
## 54	fec_con	21	0.002	0	0
## 55	tip_ss	5	0.001	0	0
## 56	per_etn	5	0.001	0	0
## 57	gp_discapa	5	0.001	0	0
## 58	gp_desplaz	5	0.001	0	0
## 59	gp_migrant	5	0.001	0	0
## 60	gp_carcela	5	0.001	0	0
## 61	gp_gestan	5	0.001	0	0
## 62	gp_indigen	5	0.001	0	0
## 63	gp_pobicfb	5	0.001	0	0
## 64	gp_mad_com	5	0.001	0	0
## 65	gp_desmovi	5	0.001	0	0
## 66	gp_psiquia	5	0.001	0	0
## 67	gp_vic_vio	5	0.001	0	0
## 68	gp_otros	5	0.001	0	0
## 69	cod_dpto_n	5	0.001	0	0
## 70	cod_mun_n	5	0.001	0	0
## 71	pac_hos	5	0.001	0	0
## 72	dist_esp_n	5	0.001	0	0
## 73	departamento_notificacion	3	0.000	0	0
## 74	municipio_notificacion	3	0.000	0	0

Con respecto a la variable **sem_ges_**, que toman un valor solo si la víctima estaba embarazada, 23784 registros no cuentan con un valor en ella

De acuerdo a lo anterior, son 3588873 celdas NA y 0 celdas que fueron definidas como vacías poniendo “.”.

Para un total de 661855 registros con valores faltantes y celdas vacías, lo que corresponde al 75.45% de la base de datos. Sin embargo, como hay columnas relacionadas, algunas celdas de una columna pueden recibir un valor a partir de otra columna.

Relacionar valores

Código municipio de residencia a partir del nombre

```
## # A tibble: 1 x 4
##   cod_mun_r municipio_residencia departamento_residencia    n
##   <chr>      <chr>                <chr>                <int>
## 1 <NA>      Armenia                <NA>                2
```

Estos casos no se pueden completar porque no se conoce el departamento y en Colombia hay dos municipios con el mismo nombre

Nombre del municipio de residencia a partir del código

```
## # A tibble: 7 x 4
##   cod_mun_r municipio_residencia departamento_residencia    n
##   <chr>      <chr>                <chr>                <int>
## 1 0          <NA>                Depto[Isla Niue]         1
## 2 0          <NA>                Depto[Islas Cook]        1
## 3 0          <NA>                Depto[Kirguistán]        1
## 4 0          <NA>                Depto[Nueva Zelanda]     1
## 5 0          <NA>                Depto[Somalia]           1
## 6 0          <NA>                Depto[Territorio Británico Del Océano Índico] 1
## 7 0          <NA>                <NA>                    63
```

Se asigna a estos casos donde la víctima residía en el extranjero un valor con la siguiente estructura: Mun[\#] donde # representa el país definido en **departamento_residencia**

Código de departamento de residencia a partir de código municipio

```
## # A tibble: 36 x 4
##   cod_dpto_r cod_mun_r municipio_residencia    n
##   <chr>      <chr>      <chr>                <int>
## 1 <NA>      0          Mun[Afganistán]         3
## 2 <NA>      0          Mun[Albania]             2
## 3 <NA>      0          Mun[Anguila]             1
## 4 <NA>      0          Mun[Australia]           2
## 5 <NA>      0          Mun[Bangladesh]          4
## 6 <NA>      0          Mun[Belice]              1
## 7 <NA>      0          Mun[Bolivia]             3
## 8 <NA>      0          Mun[Brasil]              32
## 9 <NA>      0          Mun[Catar]               1
## 10 <NA>     0          Mun[Chile]               4
## # i 26 more rows
```

Todos los casos corresponden a residencia en el extranjero entonces se asigna el valor 0

Nombre del departamento de residencia a partir de municipio

```
## # A tibble: 36 x 4
##   cod_dpto_r departamento_residencia municipio_residencia    n
##   <chr>      <chr>                <chr>                <int>
## 1 0          <NA>                Mun[Afganistán]         3
## 2 0          <NA>                Mun[Albania]             2
## 3 0          <NA>                Mun[Anguila]             1
```



```
## 4 0      <NA>      Mun[Australia]      2
## 5 0      <NA>      Mun[Bangladesh]    4
## 6 0      <NA>      Mun[Belize]        1
## 7 0      <NA>      Mun[Bolivia]       3
## 8 0      <NA>      Mun[Brasil]        32
## 9 0      <NA>      Mun[Catar]         1
## 10 0     <NA>      Mun[Chile]         4
## # i 26 more rows
```

Se asigna a estos casos donde la víctima residía en el extranjero un valor con la siguiente estructura: Depto[\#] donde # representa el país definido en **municipio_residencia**

Código país de residencia a partir de código departamento

```
## # A tibble: 34 x 3
##   cod_pais_r cod_dpto_r     n
##   <chr>      <chr>    <int>
## 1 <NA>       0         296
## 2 <NA>      05       107444
## 3 <NA>      08       20069
## 4 <NA>      11       64175
## 5 <NA>      13       18239
## 6 <NA>      15       21087
## 7 <NA>      17       16459
## 8 <NA>      18        6071
## 9 <NA>      19       18047
## 10 <NA>     20       14734
## # i 24 more rows
```

La mayoría de casos donde **cod_pais_r** es NA, corresponden a casos donde la víctima residía en Colombia, se cambia los valores faltantes al código 170. Los demás valores son casos de residencia en el exterior entonces se asigna el código correspondiente al país que se indica en **departamento_residencia**

Nombre del país de residencia a partir del código

```
## # A tibble: 36 x 3
##   cod_pais_r pais_residencia     n
##   <chr>      <chr>    <int>
## 1 004      <NA>         3
## 2 008      <NA>         2
## 3 036      <NA>         2
## 4 050      <NA>         4
## 5 068      <NA>         3
## 6 076      <NA>        32
## 7 084      <NA>         1
## 8 152      <NA>         4
## 9 170      <NA>      639802
## 10 174     <NA>        13
## # i 26 more rows
```

Código municipio de ocurrencia

```
## # A tibble: 1 x 3
##   cod_mun_o municipio_ocurrencia      n
##   <chr>      <chr>              <int>
## 1 <NA>      <NA>              1135
```

No se puede completar porque tanto código como nombre de municipio son NA a la vez

Nombre de municipio de ocurrencia a partir de código

```
## # A tibble: 0 x 5
## # i 5 variables: cod_mun_o <chr>, municipio_ocurrencia <chr>,
## #   departamento_ocurrencia <chr>, dist_esp_o <chr>, n <int>
```

Se asigna el valor correspondiente a los códigos

Nombre departamento de ocurrencia a partir de código

```
## # A tibble: 1 x 4
##   cod_mun_o cod_dpto_o departamento_ocurrencia      n
##   <chr>      <chr>      <chr>              <int>
## 1 11001      11          <NA>              5
```

Los únicos casos para completar corresponden a **cod_mun_o**, es decir, se asigna Bogotá, D.c. a **departamento_ocurrencia**

Código municipio de notificación a partir de nombre municipio

```
## # A tibble: 1 x 3
##   cod_mun_n municipio_notificacion      n
##   <chr>      <chr>              <int>
## 1 <NA>      Bogotá, D.c.              2
```

Se asigna a estos casos el valor de 11001

Código departamento notificación a partir de código municipio y nombre departamento

```
## # A tibble: 1 x 4
##   cod_dpto_n cod_mun_n municipio_notificacion      n
##   <chr>      <chr>      <chr>              <int>
## 1 <NA>      11001      Bogotá, D.c.              2
```

Variable de distrito especial de notificación a partir de nombre de municipio Luego de completar valores faltantes y crear las nuevas variables, se puede observar que disminuyó la cantidad de celdas vacías.

		Column	percent_na_before	percent_na_after
## 1	cod_pais_r		73.124	0.157
## 2	pais_residencia		73.124	0.157
## 3	municipio_residencia		0.311	0.310
## 4	cod_mun_r		0.303	0.303
## 5	cod_dpto_r		0.183	0.149

## 6	departamento_residencia	0.183	0.157
## 7	cod_mun_o	0.129	0.129
## 8	municipio_ocurrencia	0.129	0.129
## 9	departamento_ocurrencia	0.006	0.005
## 10	cod_dpto_o	0.005	0.005
## 11	cod_dpto_n	0.001	0.000
## 12	cod_mun_n	0.001	0.000
## 13	departamento_notificacion	0.000	0.000
## 14	municipio_notificacion	0.000	0.000

Hecho esto queda un total de 441092 registros con celdas vacías, lo que corresponde al 50.29% de la base de datos. Es decir, se pueden utilizar 436062 registros completos.

Registros duplicados

```
## [1] 0
```

Finalmente, al eliminar los registros duplicados se obtiene una base de datos depurada con **877154 registros**, y las siguientes variables:

## [1] "consecutive"	"fec_not"
## [3] "sexo"	"cod_dpto_o"
## [5] "cod_mun_o"	"area"
## [7] "tip_ss"	"per_etn"
## [9] "gp_discapa"	"gp_desplaz"
## [11] "gp_migrant"	"gp_carcela"
## [13] "gp_gestan"	"gp_indigen"
## [15] "gp_pobicfb"	"gp_mad_com"
## [17] "gp_desmovi"	"gp_psiquia"
## [19] "gp_vic_vio"	"gp_otros"
## [21] "cod_dpto_r"	"cod_mun_r"
## [23] "cod_dpto_n"	"cod_mun_n"
## [25] "fec_con"	"pac_hos"
## [27] "con_fin"	"cbmte"
## [29] "departamento_ocurrencia"	"municipio_ocurrencia"
## [31] "departamento_residencia"	"municipio_residencia"
## [33] "departamento_notificacion"	"municipio_notificacion"
## [35] "antec"	"sexo_agre"
## [37] "conv_agre"	"armas"
## [39] "sust_vict"	"fec_hecho"
## [41] "escenario"	"zona_conf"
## [43] "ac_mental"	"sp_its"
## [45] "prof_hep_b"	"prof_otras"
## [47] "ac_anticon"	"ac_ive"
## [49] "inf_aut"	"remit_prot"
## [51] "origen"	"actividad"
## [53] "consum_spa"	"mujer_cabf"
## [55] "que_cara"	"que_cuello"
## [57] "que_mano"	"que_pie"
## [59] "que_pliegu"	"que_genita"
## [61] "que_tronco"	"que_miesup"
## [63] "que_mieinf"	"cla_gra"

```
## [65] "ext_que"           "evi_mlegal"
## [67] "orient_sex"        "ident_gene"
## [69] "ambito_lug"        "nacionalidad"
## [71] "nombre_nacionalidad" "sem_ges"
## [73] "nom_grupo"         "estrato"
## [75] "cod_pais_r"        "pais_residencia"
## [77] "edad_"             "dist_esp_r"
## [79] "dist_esp_o"        "def_naturaleza"
## [81] "dist_esp_n"
```

Importante 1: Si se seleccionan las filas con registros totalmente completos se tiene una base de datos con 436062 filas.

Conversión a factor

Se convierten las columnas a factor a excepción de fecha de notificación, fecha del hecho y fecha de consulta

Orden de las columnas

Se establece un nuevo orden en la base de datos para mayor facilidad en el proceso de análisis.

Base de datos depurada

Se guarda como base final la base con los valores faltantes para implementar métodos de imputación

Resumen

1. Luego de juntar las bases, se filtró la base resultante por sexo e identidad de género de la víctima dado que no se pide identidad de género en todas las fichas, seleccionando los siguientes casos:
 - Los casos notificados desde 2013-2016 y que el sexo sea femenino
 - Los casos notificados en 2017-2022 donde la víctima se identifique como mujer o sea de sexo masculino y se identifique como transgénero
 - Los casos notificados en 2023-2024 y las víctimas se identifiquen como mujer o mujer trans
 - Los casos donde no se conoce como se identifica la víctima pero que sea de sexo mujer Además, se seleccionaron los casos que ocurrieron ÚNICAMENTE en Colombia

Además, se filtraron los casos donde fecha del hecho, consulta y notificación son consistentes entre sí

2. Analizando la fecha del hecho se observó que la base filtrada tiene casos de 1899 al 2023. Mientras que los años de notificación van desde 2013 hasta 2024.
3. Se cuenta con la variable **consecutive**, una variable que puede servir de identificador de caso en caso de ser necesario ya que no tiene valor repetido entre los registros
4. Es importante mencionar que en las bases de datos proporcionadas no hay información respecto al parentesco con el agresor (r_nofiliar, r_fam_vic) y localidad/centro poblado/vereda/barrio donde ocurrió el caso (localidad, cen_poblada, vereda, bar_ver). La primer característica aparece en MEData y las fichas de notificación mientras que las tres últimas aparece en MEData y fichas de notificación pero no en el diccionario.

5. La base de datos después de los filtros, tratar las variables y duplicados, quedó compuesta por **877154 filas**. Las columnas se especifican en *inventario variables*. En esta base hay registros con algunos NA correspondientes a las columnas con valores faltantes menores del 50% y a la columna de semana de gestación

Nota 1: Se dejaron los NA de la semana de gestación porque esta variable toma valores en un caso específico y dado al tipo de dato no es posible asignar un valor característico a estos casos.

Nota 2: Esta es la base final que se guarda en data/interim con el nombre de *SIVIGILA_debugged*

6. Si se quitan los registros con NA, la base final quedaría con las mismas columnas pero **436062 registros completos**.

Nota 1: Los únicos NA que se encontrarían son los presentes en la columna **sem_ges**

7. **Variables con mayor cantidad de NA** (< 50% registros):

- orientación sexual
- ámbito de lugar
- identidad de género
- nacionalidad
- estrato

8. De la información de georreferenciación: lugar de residencia víctima, ocurrencia hecho y notificación caso, la información más completa es el lugar de notificación

9. **Variables que se crearon:**

- origen: indica el registro a cuál base de datos de las proporcionadas pertenece
- Se crearon tres variables (dist_esp_r, dist_esp_o, dist_esp_n), las cuales indican si el municipio en que residía la víctima, ocurrió el hecho y fue notificado, respectivamente, corresponde a un municipio que es considerado distrito especial de Colombia.

10. **Variables que se re-codificaron:**

- grupo étnico
- zona del cuerpo en caso de quemadura
- lugar de notificación, residencia y ocurrencia
- variables relacionadas con la atención en salud
- condición final de la víctima y causa básica de defunción
- orientación sexual

11. **Variables que se re-calcularon:**

- edad: se convirtió a años

12. **Variables que se unificaron:**

- ocupación y actividad de la víctima
- modalidad de violencia sexual y no sexual

13. **Variables con inconsistencias o problemáticas:**

- variables relacionadas con la edad de la víctima: se arregla
- edad del agresor: termina eliminándose por NA
- orientación sexual: se re-codifica para arreglarla

14. **Variables que NO están en todas las fichas:**

- **estrato de la víctima:** esta variable no se elimina porque la cantidad de NA no supera el 50% de los registros. Se encontró una ficha del 2016 donde no se solicita y otra de 2019 donde sí, lo que explica esta cantidad de NA. El total de registros solo con NA en estrato es 27711 registros, es decir, si NO se considera trabajar con estrato se tendría 463773 registros completos.
- **nacionalidad de la víctima:** esta variable no se elimina porque la cantidad de NA no supera el 50% de los registros. Se encontró una ficha del 2019 de datos básicos donde se pide esta información pero en la previas no. El total de registros solo con NA en nacionalidad es 69730 registros, es decir, si NO se considera trabajar con estrato se tendría 505792 registros completos.
- **hora del hecho:** se eliminó por cantidad de NA, esta cantidad se debe a que a partir del 2018 no se solicita esta información
- **edad del agresor:** tenía gran cantidad de NA, por lo tanto, se eliminó. Esto dado a que esta información se dejó de pedir a partir del año 2018
- **nombre del grupo étnico:** solo toma valores a partir del 2018, en años posteriores es NA o “No aplica”. Esto se debe a que según las fichas que se tienen, a partir del año 2018 la ficha de datos básicos solicita indicar el nombre del grupo si la víctima tiene alguna pertenencia étnica.

15. **Variables que se eliminaron:** *inventario variables*

16. **Variables a las que no se les hizo modificaciones relevantes o solo se completaron con variables de igual representación:**

- tipo de seguridad social
- pertenencia étnica y nombre del grupo indígena
- hospitalización
- consumo SPA
- persona jefatura de hogar
- antecedente de violencia
- presencia de alcohol o sustancias
- escenario y ámbito del hecho

17. **Variables no obligatorias según diccionario:**

- Seguimiento y clasificación final del caso (Ajuste)
- nacionalidad
- estrato
- identidad de género y orientación sexual
- grupos poblaciones y variables auxiliares
- modalidad de violencia
- mecanismo o arma y variables auxiliares
- sexo agresor
- hospitalización
- recolección evidencia medicina legal
- causa básica de defunción
- laboratorios
- anticoncepción de emergencia
- orientación IVE
- fecha de consulta